Machine learning en empresas reales

Casos de uso reales, conceptos y compromisos

InnoIT · 19 de octubre de 2026

Innoit

Ruta de aprendizaje

01. Fundamentos de machine learning

02. Deep learning y generación de imágenes

03. Sistemas GenAI y flujos de trabajo con agentes

12 temas solicitados. 15 casos, un diagrama de solución para cada uno y un ejemplo integrado de cierre con BBVA Blue.

Guía de los ejemplos

Tareas e implementaciones

Clasificación, clustering y forecasting describen tareas. Varias familias de algoritmos pueden resolver cada una.

RAG y la orquestación de agentes describen sistemas que combinan modelos con otro software.

Cómo leer cada caso

Cada caso recoge el concepto, el flujo de trabajo real, las ventajas, las limitaciones y una conclusión de una frase.

Las fuentes describen el despliegue documentado en el momento de su publicación. Los compromisos son análisis didáctico.

01

Fundamentos de machine learning

Relaciones, etiquetas, grupos y predicciones numéricas

Innoit

Reglas de asociación

Walmart (Estados Unidos)

Sistema de recomendación en producción

Concepto

Encontrar artículos que aparecen juntos con más frecuencia de la que cabría esperar por azar.

Caso de uso real

Walmart extrae de las cestas de la compra pares de productos complementarios y usa esas relaciones

Walmart evitó PageRank y eligió después reglas de coocurrencia por pares, más simples, para poder escalar.

Los productos que se compran juntos pueden orientar qué productos se recomiendan juntos.

Ventaja

Las reglas legibles pueden apoyar la venta cruzada sin necesidad de resultados etiquetados.

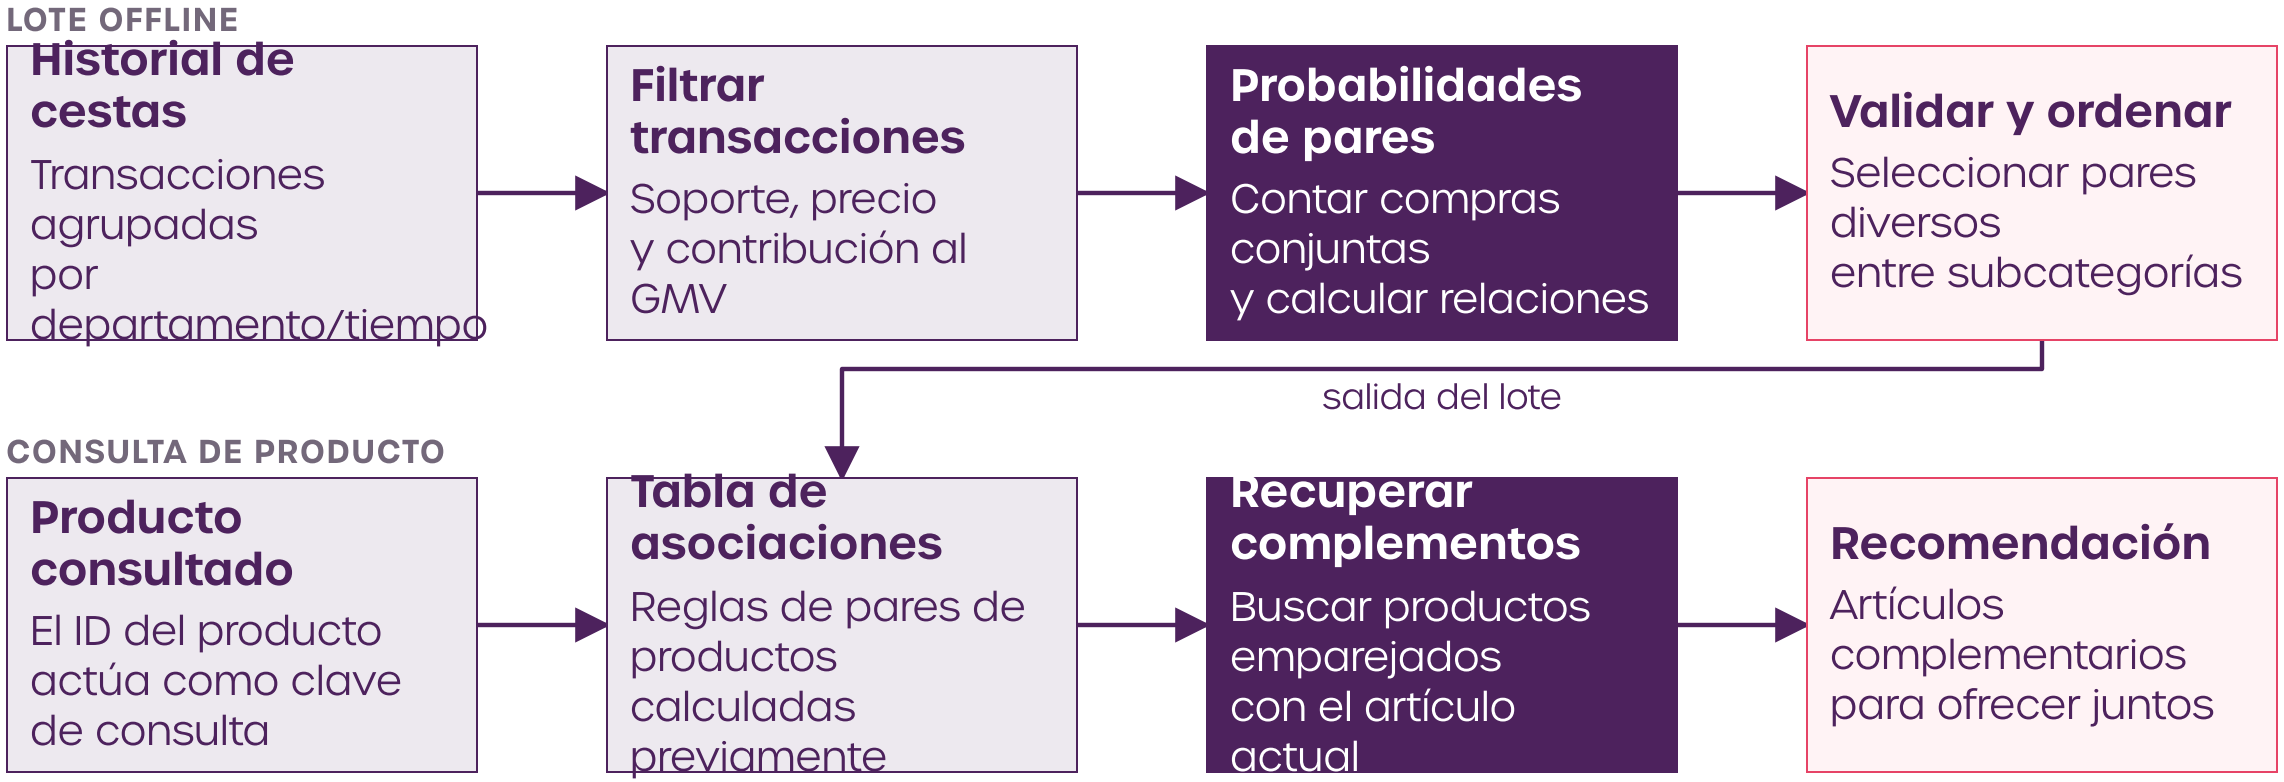
Limitación

La popularidad y las promociones distorsionan la coocurrencia. Una relación no demuestra causalidad.

Fuente: Walmart Global Tech

Walmart: asociaciones en la cesta

El procesamiento por lotes construye la tabla de pares de productos que usan las recomendaciones



El ganador desplegado usa probabilidades por pares. Walmart evaluó FP-Growth como alternativa.

Fuente: Walmart Global Tech

Tres salidas de clasificación

Tarea	Etiquetas por observación	Salida ilustrativa
Binaria	Una de dos	Tráfico legítimo o de bots
Multiclase	Una de varias	Una categoría de gasto
Multietiqueta	Pueden aplicarse varias	Varios intereses de producto

Aquí «multicategoría» se trata como clasificación multietiqueta. Los ejemplos ilustran la estructura de la salida.

Clasificación binaria

Cabify (España)

Servicio operativo mediante Infobip Signals

Concepto

Asignar una de dos etiquetas, a menudo aplicando un umbral a una puntuación de riesgo.

Caso de uso real

Infobip Signals distingue los SMS legítimos del tráfico de bots y bloquea las solicitudes fraudulentas para Cabify.

Ventaja

Automatiza decisiones de gran volumen y reduce la intervención manual.

Limitación

Los falsos positivos pueden bloquear a clientes reales. Los patrones de ataque cambian con el tiempo.

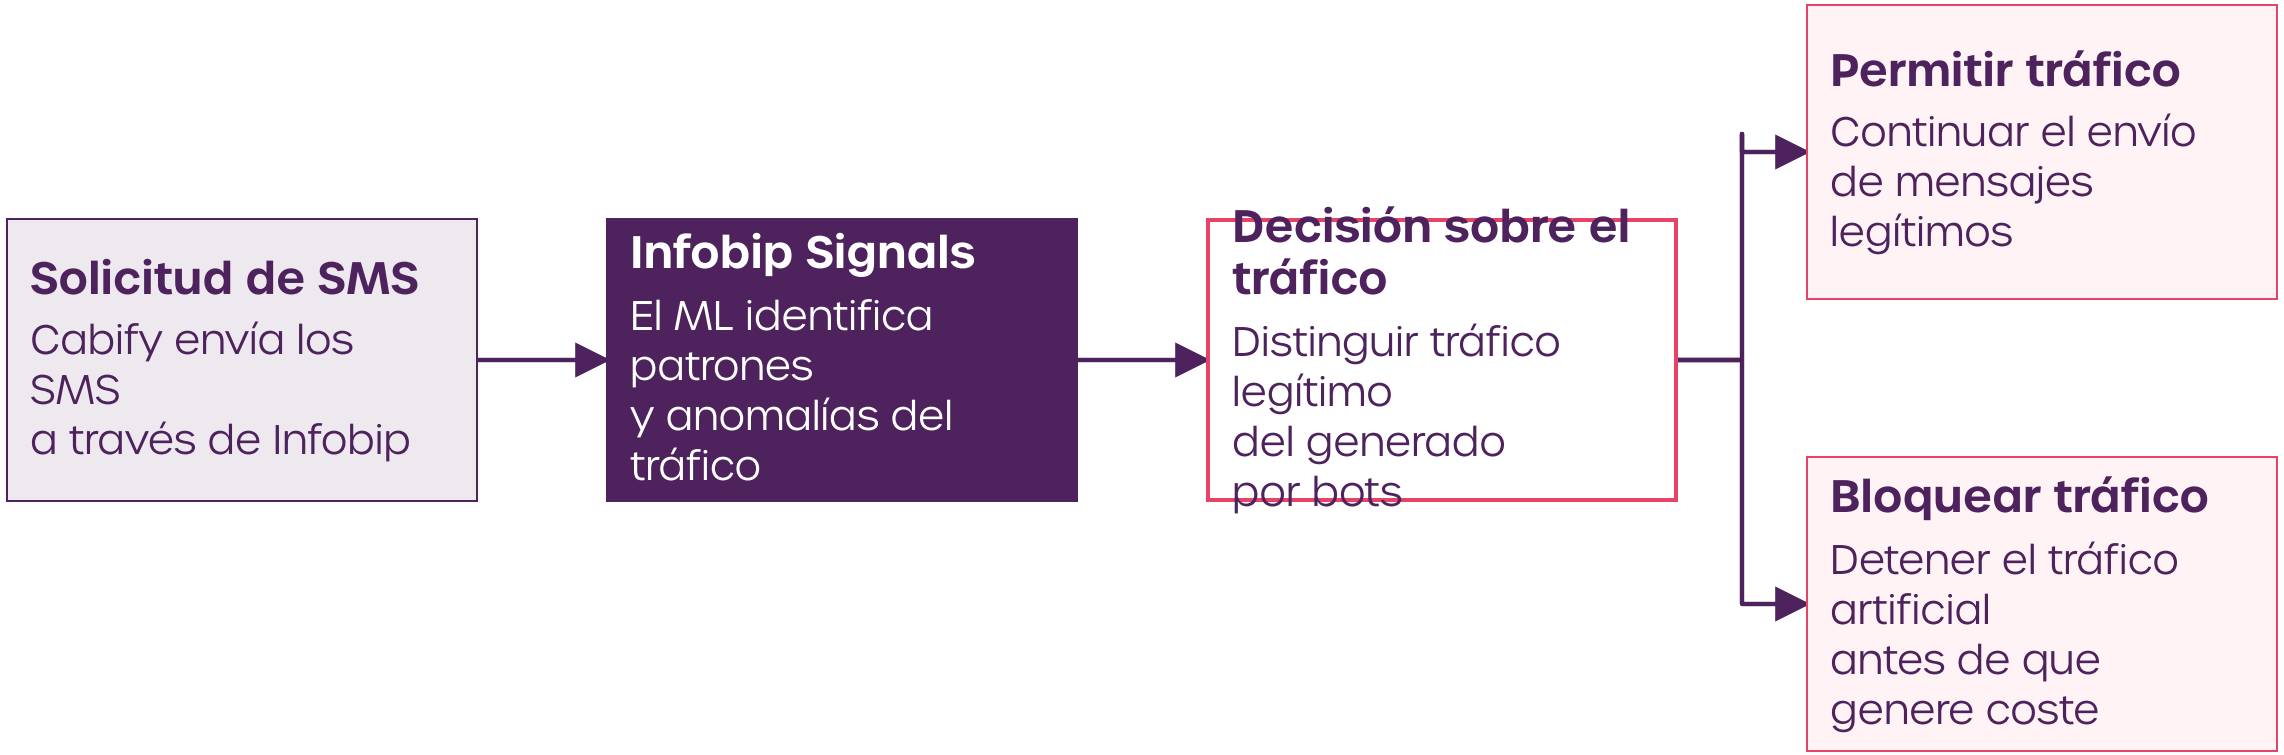
Infobip informa de un 15,7 % menos de pérdidas financieras relacionadas con AIT en un trimestre. La arquitectura del modelo no se ha divulgado.

Una predicción de dos vías resulta útil cuando sus errores tienen costes de negocio claros.

Fuente: Caso de cliente de Infobip con testimonio de Cabify

Cabify: tráfico legítimo o artificial

El servicio de ML toma una decisión concreta de permitir/bloquear sobre el tráfico de SMS



Infobip divulga la decisión y el uso de ML, pero no publica variables, familia de modelo ni umbrales.

Fuente: Caso de cliente de Infobip con testimonio de Cabify

Clasificación multiclase

Uber (Estados Unidos)

Asistente de soporte COTA en producción (relato de 2018)

Concepto

Elegir una categoría entre tres o más alternativas mutuamente excluyentes.

Caso de uso real

Uber COTA predice los tipos de incidencia de soporte a partir del texto del ticket y del contexto del viaje, y ayuda a los agentes a elegir la categoría correcta.

Ventaja

Reduce el esfuerzo de navegar por una taxonomía de soporte extensa.

Limitación

Las incidencias parecidas y las categorías poco frecuentes pueden confundir al clasificador.

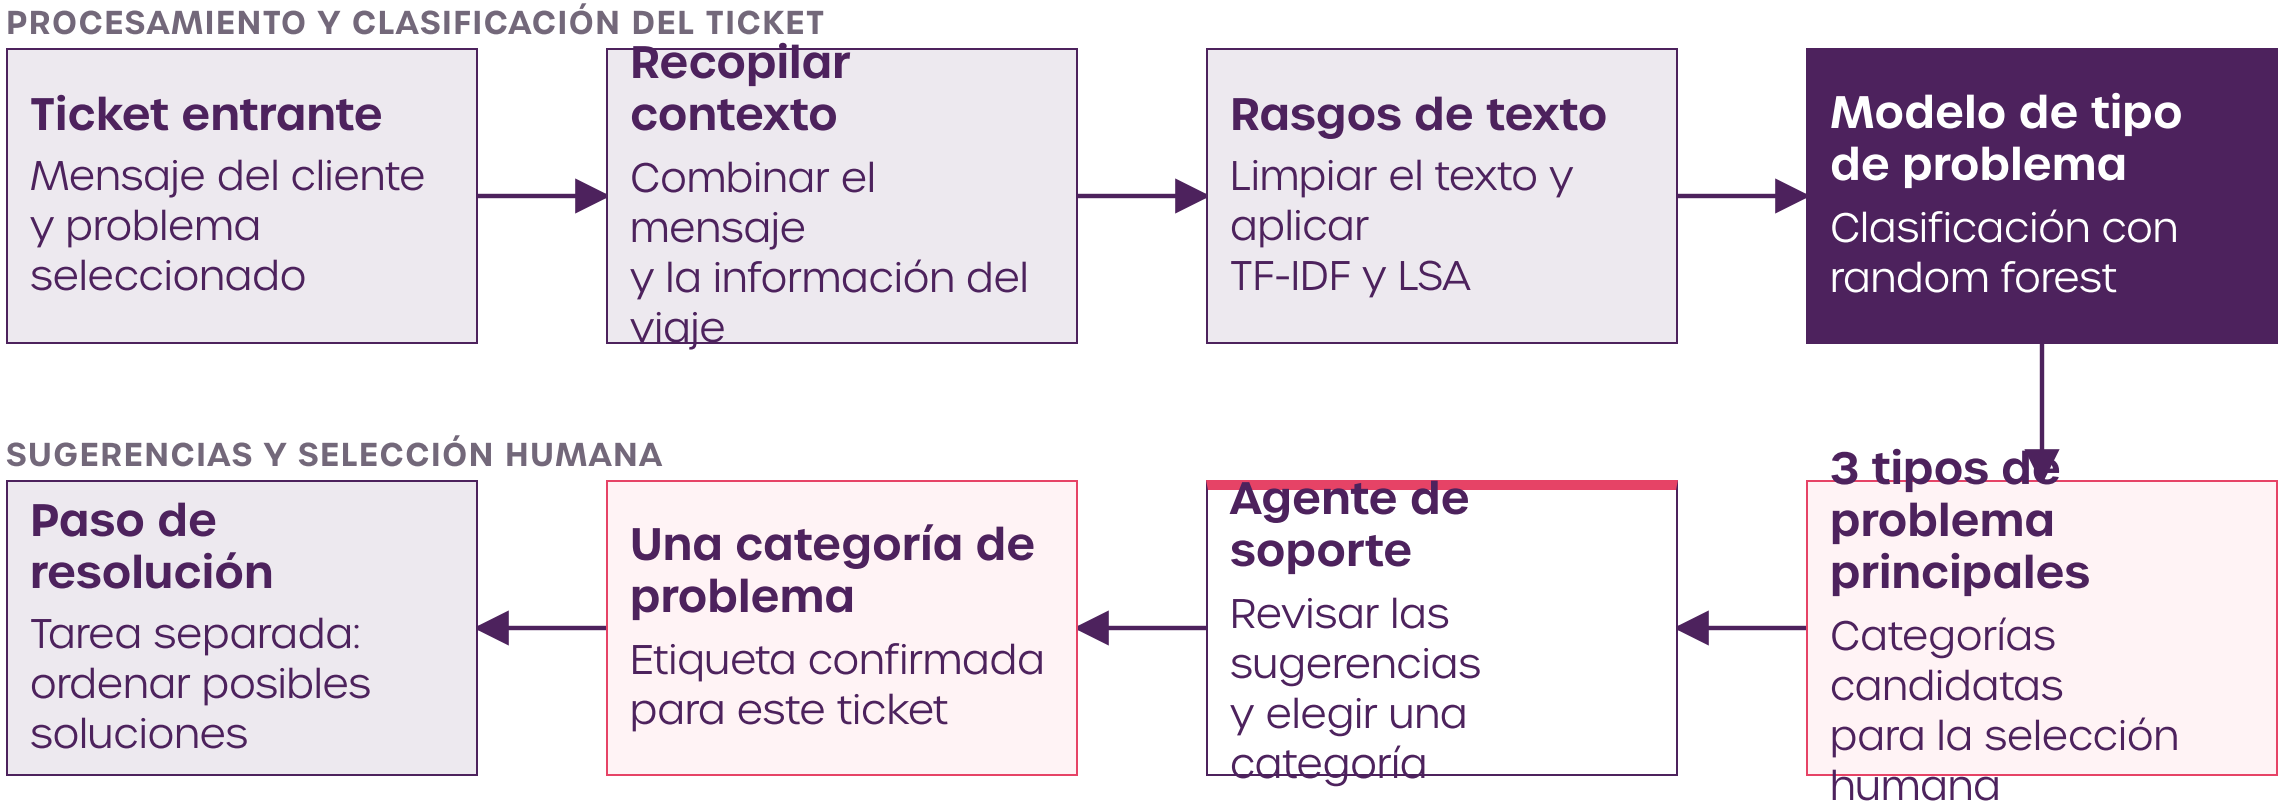
La identificación de la incidencia es independiente de la tarea de ordenación de soluciones de COTA.

Un ticket recibe una categoría de incidencia y una persona confirma las sugerencias del modelo.

Fuente: Uber Engineering

Uber COTA: identificar una incidencia de soporte

El texto del ticket y el contexto del viaje ayudan a un agente a elegir una categoría de problema



La identificación del tipo de problema es la tarea multiclase. COTA ordena las posibles soluciones en un paso aparte.

Fuente: Uber Engineering

Clasificación multietiqueta

Amazon Retail (Estados Unidos)

Inferencia de propensión de clientes en producción

Concepto

Asignar cero, una o varias etiquetas a la misma observación.

Ventaja

Representa intereses solapados sin forzar un único segmento.

Caso de uso real

Amazon predice la propensión de los clientes a actuar en miles de categorías de producto, lo que permite intereses solapados.

Limitación

Las etiquetas poco frecuentes y los distintos umbrales dificultan el entrenamiento y la evaluación.

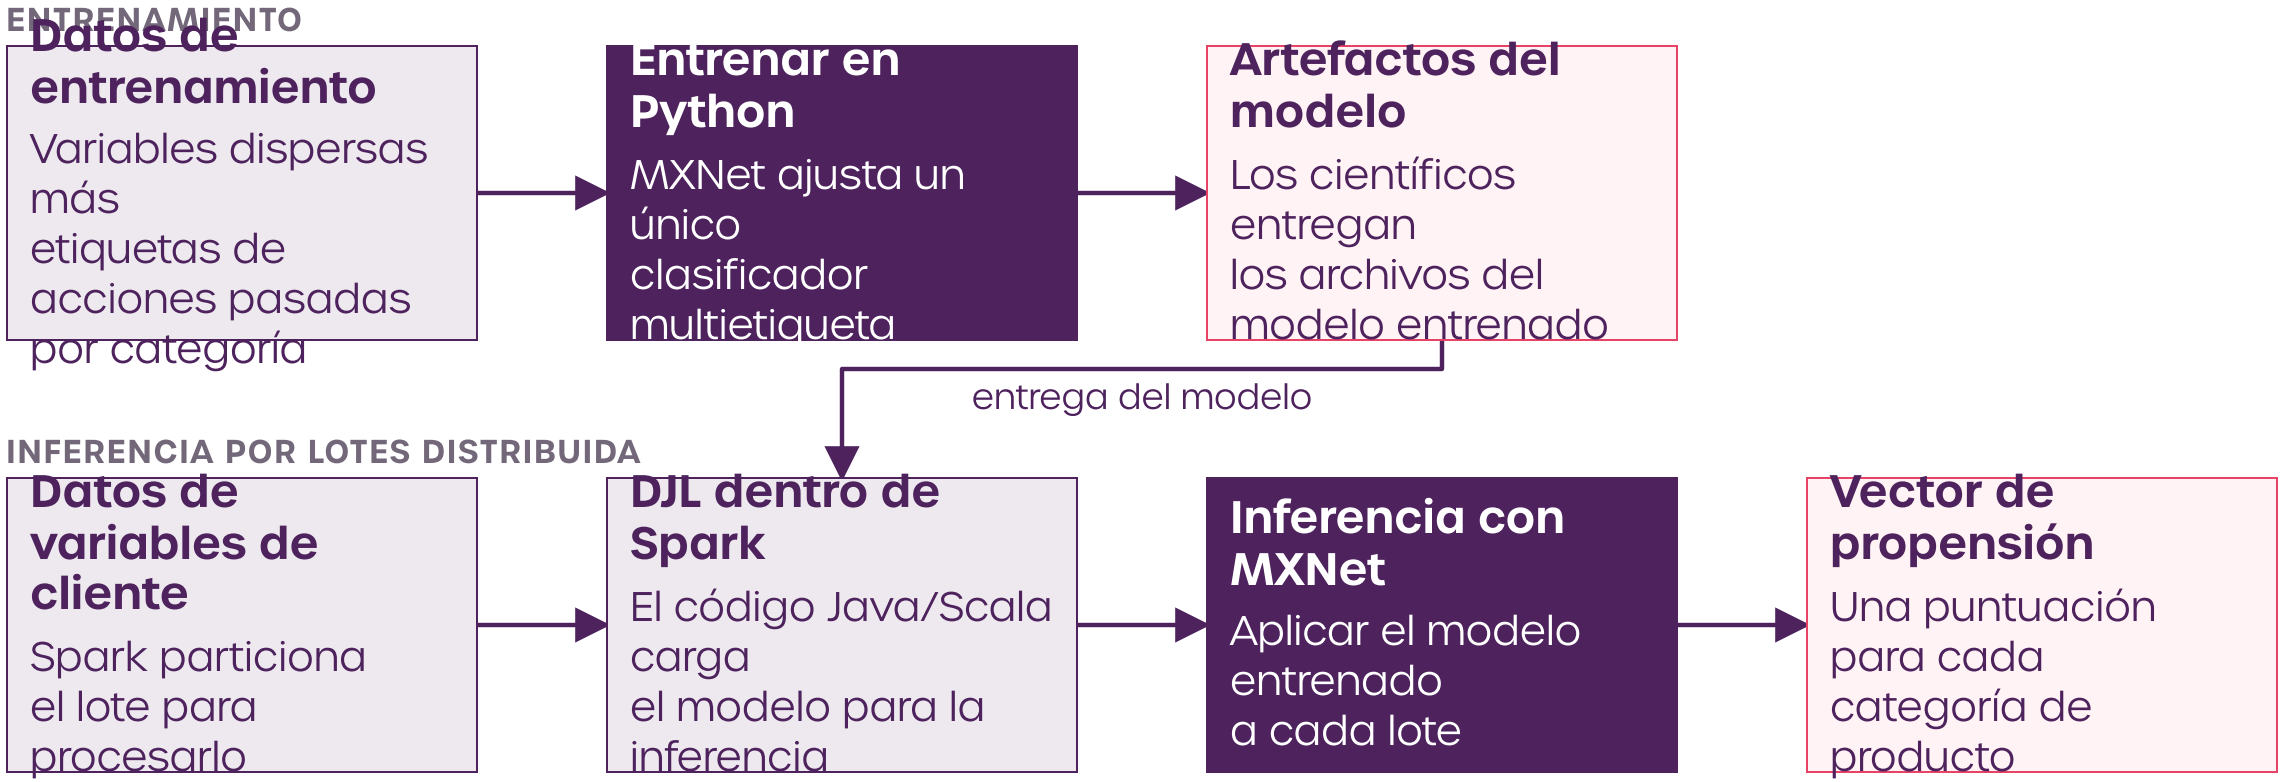
Amazon describe modelos MXNet con inferencia mediante Spark y Deep Java Library.

Un mismo cliente puede pertenecer a varias categorías útiles a la vez.

Fuente: Amazon / AWS Open Source Blog

Amazon: miles de propensiones

Un vector de cliente disperso alimenta un modelo compartido con muchas salidas por categoría



Varias categorías pueden recibir una propensión alta a la vez. El sistema no elige una única etiqueta ganadora.

Fuente: Amazon / AWS Open Source Blog

Clustering

Spotify (Suecia)

Método documentado de investigación de usuarios

Concepto

Descubrir grupos con comportamiento similar sin etiquetas de grupo predefinidas.

Ventaja

Encuentra segmentos inesperados y apoya la investigación dirigida de usuarios.

Caso de uso real

Spotify combina UMAP con HDBSCAN recursivo para descubrir segmentos más finos de usuarios.

Limitación

La elección de variables condiciona los grupos. Los clusters estables siguen necesitando validación humana.

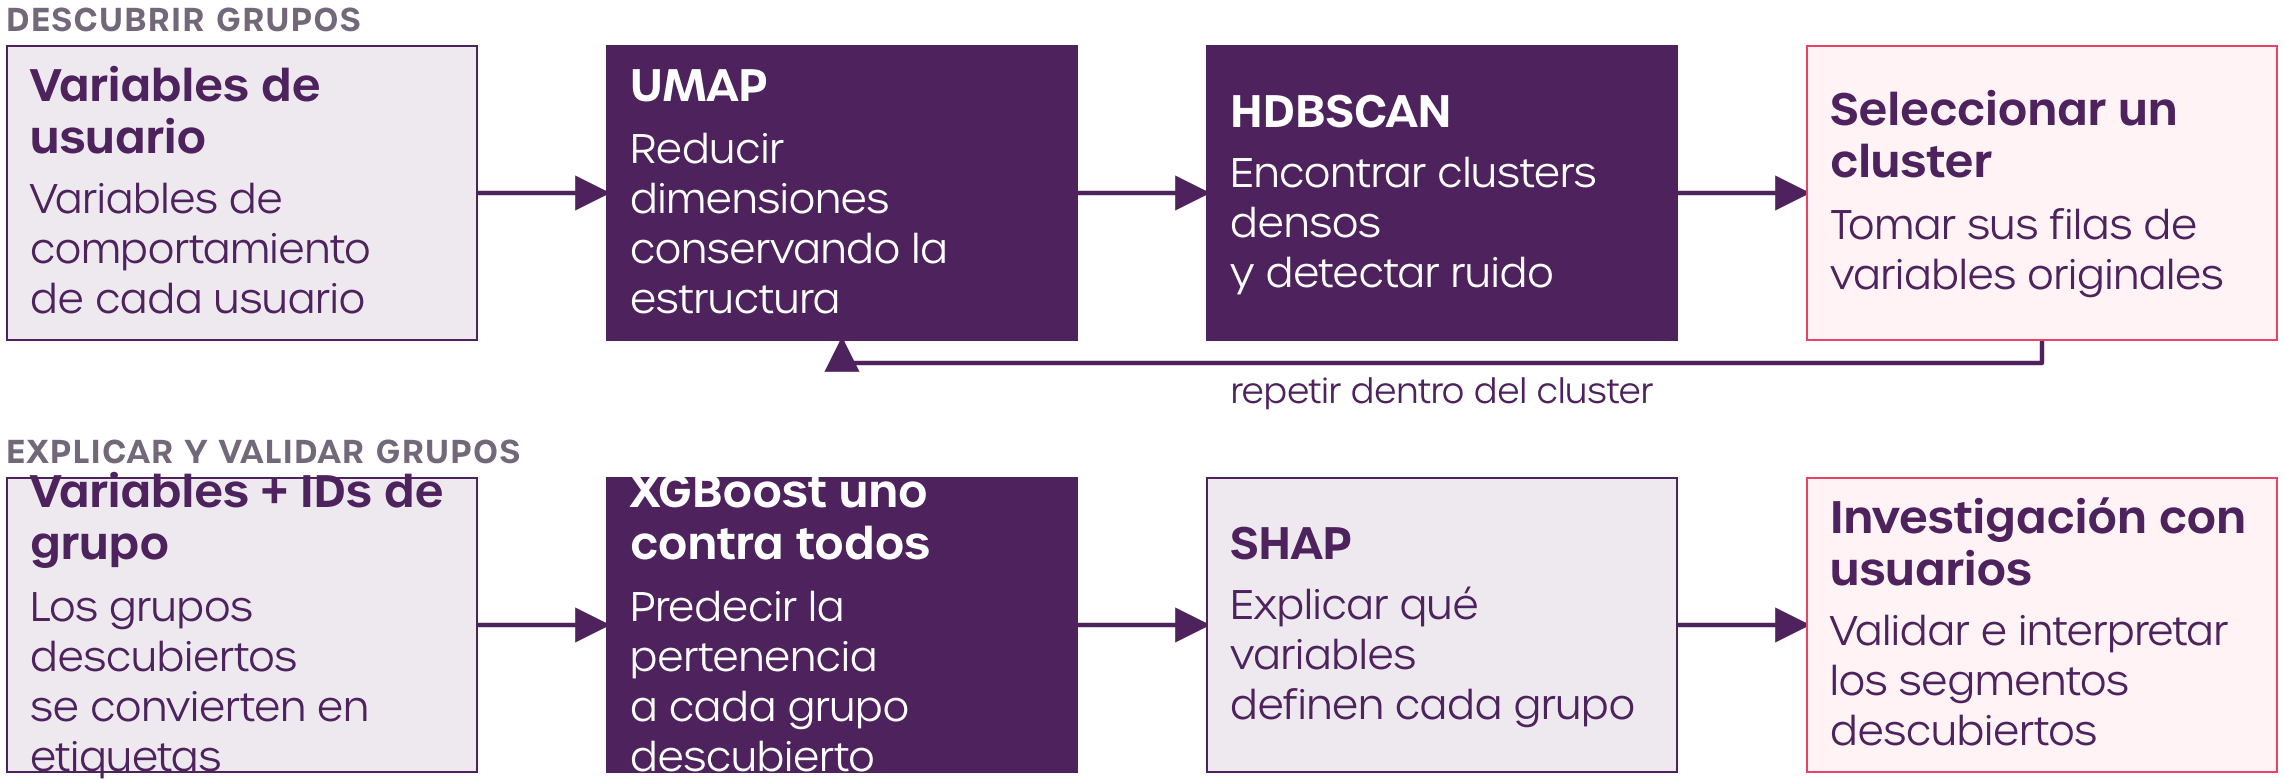
Spotify usa XGBoost y SHAP para explicar los segmentos resultantes.

El clustering descubre grupos que los investigadores pueden analizar después.

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado



Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Las personas detrás del caso de uso

Personas	Ana y Luis escuchan a Izal y a Vetusta Morla. Marta escucha a Charlotte de Witte.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de indie español como la señal principal del grupo.
Uso posible	Sugerir Love of Lesbian a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

1 / 9

Detalles técnicos

Un ejemplo concreto de escucha

Ana y Luis comparten artistas. ¿Podemos descubrir su grupo y explicar qué lo hace diferente?

Sigue a las mismas personas

Cada paso siguiente explica qué supondría el algoritmo para Ana, Luis y Marta.

Historia ilustrativa. Los gráficos calculados usan variables de comportamiento sintéticas, sin recuentos de artistas ni usuarios con nombre.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Variables originales

$X \in \mathbb{R}^{684 \times 6}$

Observaciones sin etiquetar

Oyente	Minutos	Sesiones	Saltos	Descubrimiento	Listas	Noche
L001	222	11.4	10%	17%	52%	72%
L002	124	6.6	46%	64%	41%	29%
L003	32	1.8	28%	27%	75%	8%
L004	127	6.6	42%	66%	32%	36%

Variables numéricas, sin etiquetas de segmento predefinidas

684 filas × 6 variables

StandardScaler $z_{ij} = (x_{ij} - \mu_j) / \sigma_j$ Se ajusta una vez con toda la población de la demo

Demo calculada · oyentes sintéticos

2 / 9

Detalles técnicos

Un vector de variables original para cada oyente

La escucha de Ana se convierte en una fila numérica. Aquí calculamos seis variables de comportamiento. Los recuentos de artistas serían entradas adicionales.

Oyente L001

Minutos	222	Sesiones	11.4
Saltos	10%	Descubrimiento	17%
Listas	52%	Noche	72%

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

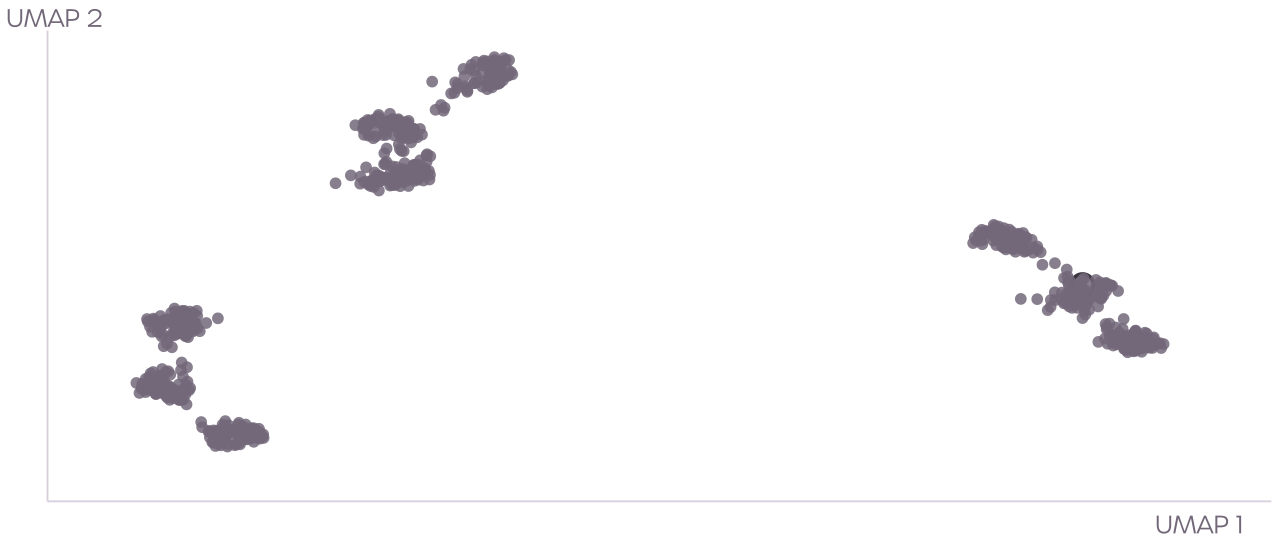
Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Coordenadas UMAP calculadas

3 clusters · 0 ruido · 684 oyentes



Solo es una transición visual. El movimiento de los puntos no reproduce las iteraciones del optimizador.

3 / 9

Detalles técnicos

UMAP hace visibles los vecindarios

Con variables de artistas adecuadas, Ana y Luis podrían aparecer cerca porque comparten artistas. UMAP muestra similitud, no una etiqueta de género.

684 × 6 → 684 × 2

Fiabilidad (trustworthiness) con 10 vecinos: 0.975

Diagnóstico de vecindad local, no validez del segmento.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Coordenadas UMAP calculadas

3 clusters · 0 ruido · 684 oyentes



C1 221 · C2 241 · C3 222 · Ruido 0

Demo calculada · oyentes sintéticos

4 / 9

Detalles técnicos

HDBSCAN descubre grupos basados en densidad

Un grupo denso podría contener a Ana y a Luis, mientras que Marta queda en otro sitio. Los colores muestran los grupos descubiertos. Nuestro gráfico usa datos de comportamiento sintéticos.

Inspeccionar grupo: C1 · 221 oyentes

32.3% de este nodo

Ruido: 0 / 684

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

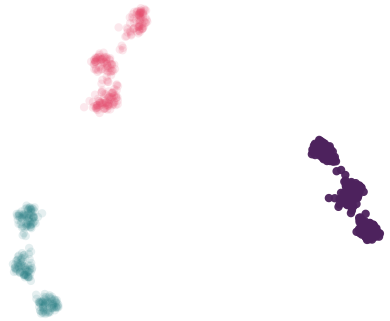
Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

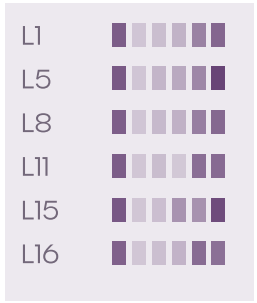
La recursión usa las variables originales dentro de un cluster seleccionado

Un nuevo ajuste, no un gráfico ampliado

1. Seleccionar C1

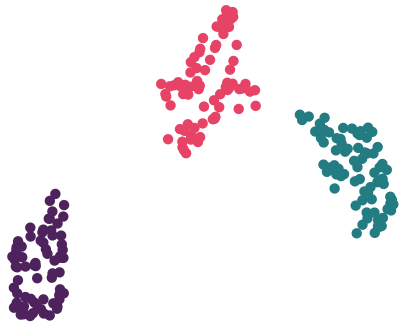


2. Filas X originales



221 × 6 variables

3. Reajustar ambos modelos



3 grupos · 0 ruido

Las nuevas coordenadas proceden de un nuevo ajuste de UMAP sobre las filas originales seleccionadas.

5 / 9

Detalles técnicos

La recursión parte de las filas de variables originales

Analiza de nuevo el grupo de Ana con sus filas originales. Esto podría revelar hábitos más finos dentro de su grupo más amplio.

Cluster padre: C1 · 221 filas

Inspeccionar ajuste hijo de C1

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Jerarquía de clusters calculada



El ruido queda sin asignar. Los recuentos de los hijos pueden sumar menos que el padre.

6 / 9

Detalles técnicos

La jerarquía registra cada paso de descubrimiento

El grupo amplio de Ana podría dividirse en subgrupos. El árbol registra qué usuarios entran en cada nuevo ajuste. Haz clic en una rama para inspeccionar su población calculada.

4 ajustes calculados

Cada hijo tiene sus propias coordenadas UMAP y asignaciones HDBSCAN.

Demo calculada · oyentes sintéticos

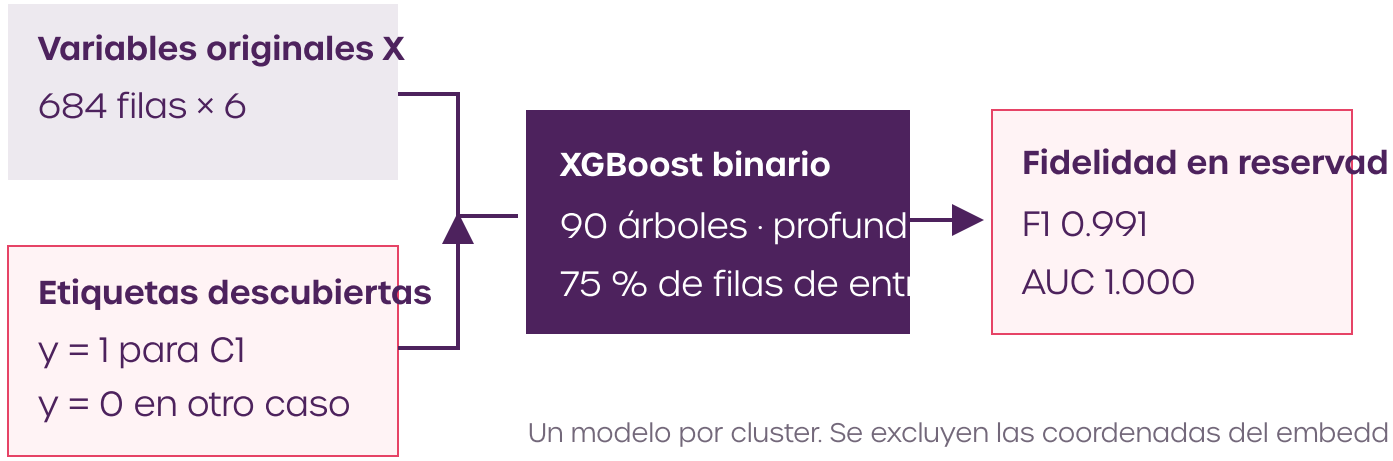
← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Entrenamiento uno contra el resto



Un modelo por cluster. Se excluyen las coordenadas del embedd

7 / 9

Detalles técnicos

Un modelo supervisado aprende la pertenencia descubierta

XGBoost aprende a predecir el grupo de Ana frente al resto, usando las variables originales y las etiquetas descubiertas.

Modelo de pertenencia: C1 contra el resto

513 entrenamiento / 171 reservados

La partición prueba la reproducción de etiquetas, no el descubrimiento de clusters con usuarios nuevos.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Contribuciones TreeSHAP calculadas

Este oyente | Mean |SHAP| — Contribución con signo al log-odds de pertenencia



Base -0.80 + Σ SHAP 6.55 = log-odds 5.75 **P(C1) = 99.7%**

8 / 9

Detalles técnicos

SHAP explica el predictor de pertenencia

SHAP explica la puntuación de grupo de un oyente. La escucha indie podría importar con variables de artistas. Estas barras explican el comportamiento.

Explicar la pertenencia a: C1

Oyente: L001 · reservado

Oyente reservado. Las puntuaciones binarias independientes no tienen por qué sumar 1.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Por qué hace falta interpretar

Personas	Ana y Luis escuchan a Izal y a Vetusta Morla. Marta escucha a Charlotte de Witte.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de indie español como la señal principal del grupo.
Uso posible	Sugerir Love of Lesbian a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

9 / 9

Detalles técnicos

Qué significan los resultados

Grupo C1 Oyente L001

En todos los oyentes

Minutos / día y Escucha nocturna tienen los mayores efectos medios.

Este oyente

Minutos / día = 222 es el empuje más fuerte hacia C1.

Las explicaciones del modelo no prueban causas ni validan segmentos.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Detección de anomalías

Adyen (Países Bajos)

Monitorización del volumen de pagos en producción

Concepto

Señalar observaciones que difieren del patrón esperado para su contexto.

Caso de uso real

Adyen modela los volúmenes de pago de los comercios y avisa a los equipos cuando las observaciones quedan fuera de los límites esperados.

Ventaja

Puede identificar problemas operativos poco frecuentes sin ejemplos etiquetados de incidentes.

Limitación

Los festivos y los cambios en los comercios provocan falsas alertas. Los umbrales sensibles aumentan el ruido.

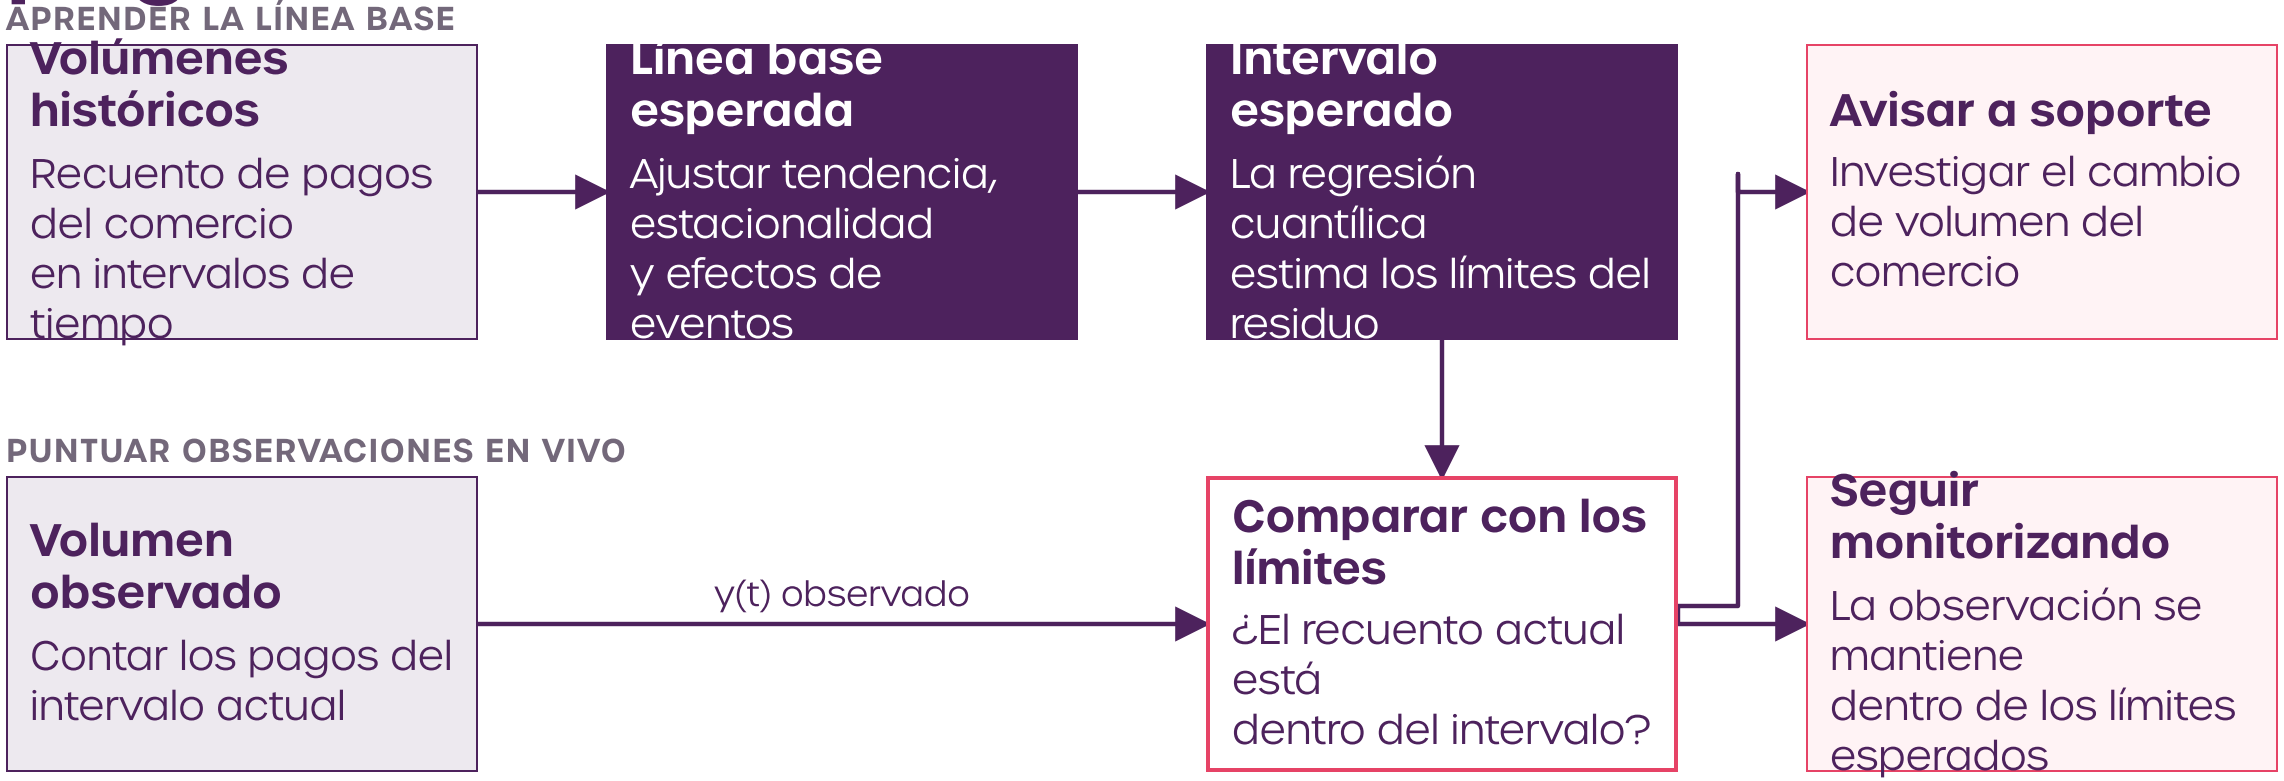
El modelo captura tendencia, estacionalidad y eventos, con regresión cuantílica para los límites de incertidumbre.

Una anomalía es algo inusual respecto a una línea base significativa.

Fuente: Adyen Engineering

Adyen: detectar una caída del volumen de pagos

Una línea base contextual y unos límites de incertidumbre definen qué se considera inusual



Un recuento absoluto bajo puede ser normal. La decisión depende del comercio, del momento y del intervalo esperado.

Fuente: Adyen Engineering

Análisis de regresión

idealista/data (España)

Servicio comercial de valoración automática

Concepto

Estimar un número continuo a partir de variables explicativas.

Caso de uso real

idealista/data combina comparables y ML hedónico para estimar el valor de los inmuebles a partir de su ubicación y sus atributos.

Ventaja

Produce estimaciones coherentes en grandes carteras de inmuebles.

Limitación

La falta de atributos y los cambios del mercado reducen la precisión. Las estimaciones difieren de los precios de venta reales.

La empresa revela el enfoque de valoración, pero no el estimador exacto.

La regresión estima un número a partir de las características de una observación.

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Los atributos del inmueble y los inmuebles comparables alimentan la valoración automatizada

idealista/data



Fuente: idealista/data e idealista labs

Innoit

idealista: estimar el valor de un inmueble

Los atributos del inmueble y los inmuebles comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

El inmueble objeto se convierte en un vector de variables

El piso de Ana

Zona B · mercado ficticio

Superficie	80 m²	Dormitorios	2
Reformado	Sí	Ascensor	Sí

↓

$$x = [80, 2, 1, 0, 1, 1]$$

superficie, dorm., zona B, zona C, reformado, ascensor

La zona A es la referencia. Las zonas B y C usan indicadores 0/1 independientes.

Demo calculada · viviendas y precios sintéticos

1 / 5

Detalles técnicos

La vivienda de Ana que hay que valorar

Ana quiere estimar el precio de su piso. Cambia sus atributos para seguir la misma vivienda en cada paso.

Superficie — 80 m²

Dormitorios — 2

Zona ficticia — Zona B

Reformado — ☑

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Los atributos del inmueble y los inmuebles comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

Evidencia comparable del conjunto de entrenamiento

Solo Zona B · 80 m² · 2 dormitorios · seis coincidencias más cercanas

Inmueble	Superficie	Dorm.	Reformado	Ascensor	Precio de referencia
P425	85 m²	2	Sí	Sí	302.180 €
P276	91 m²	2	Sí	Sí	339.450 €
P201	80 m²	3	Sí	Sí	311.444 €
P393	80 m²	1	Sí	Sí	283.257 €
P275	85 m²	3	Sí	Sí	311.032 €
P216	71 m²	2	No	Sí	278.683 €

Media de estos seis precios **304.341 €**

Todos los inmuebles y precios son sintéticos. Las reglas de coincidencia son didácticas.

Demo calculada · viviendas y precios sintéticos

2 / 5

Detalles técnicos

Seis inmuebles de referencia similares

Busca seis viviendas como la de Ana: la misma zona, tamaño y dormitorios similares. Sus precios de referencia ofrecen una primera comparación.

¿Qué hace que haya coincidencia?

Misma zona, superficie y dormitorios similares, además de reforma y ascensor.

En esta comparación solo entran inmuebles de entrenamiento.

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Los atributos del inmueble y los inmuebles comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | **3 Regresión** | 4 Estimación | 5 Explicabilidad

Primero se aprende, después se predice

ENTRENAMIENTO · se calcula una vez

360 ejemplos conocidos
Variables X + precio y

→

Regresión lineal
Aprende los pesos β

→

Ajuste MCO
min $\Sigma(y - \hat{y})^2$

PREDICCIÓN · se actualiza con tus datos

Variables de esta vivienda
80 m² · Zona B

→

Modelo ajustado fijo
$\hat{y} = \beta_0 + \Sigma\, \beta_j x_j$

→

Precio del modelo
305.790 €

3 / 5

Detalles técnicos

La regresión aprende una relación numérica

Aprende de viviendas conocidas y luego predice el precio de Ana a partir de los atributos de su piso.

¿Qué aprende?

Por ejemplo, +10 m² suman 19.802 € a la predicción de este modelo, manteniendo fijas las demás entradas.

Es una asociación ajustada sobre datos sintéticos.

Demo calculada · viviendas y precios sintéticos

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Los atributos del inmueble y los inmuebles comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

Una combinación transparente para esta demo

Media de viviendas similares

304.341 €

50 % de la estimación de la demo

+

Estimación de la regresión

305.790 €

50 % de la estimación de la demo

↓

Precio estimado ilustrativo

305.000 €

Redondeado a los 1.000 € más cercanos

La combinación 50/50 es una elección didáctica. La ponderación de producción de idealista no es pública.

4 / 5

Detalles técnicos

Una estimación continua del precio

Para la vivienda de Ana, combina la media de viviendas similares con la predicción de la regresión. Esta demo usa un promedio ilustrativo 50/50.

Error absoluto medio en datos reservados

10.577 € en 120 viviendas sintéticas.

Una evaluación de demostración, no la precisión de idealista ni un intervalo de predicción individual.

Demo calculada · viviendas y precios sintéticos

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

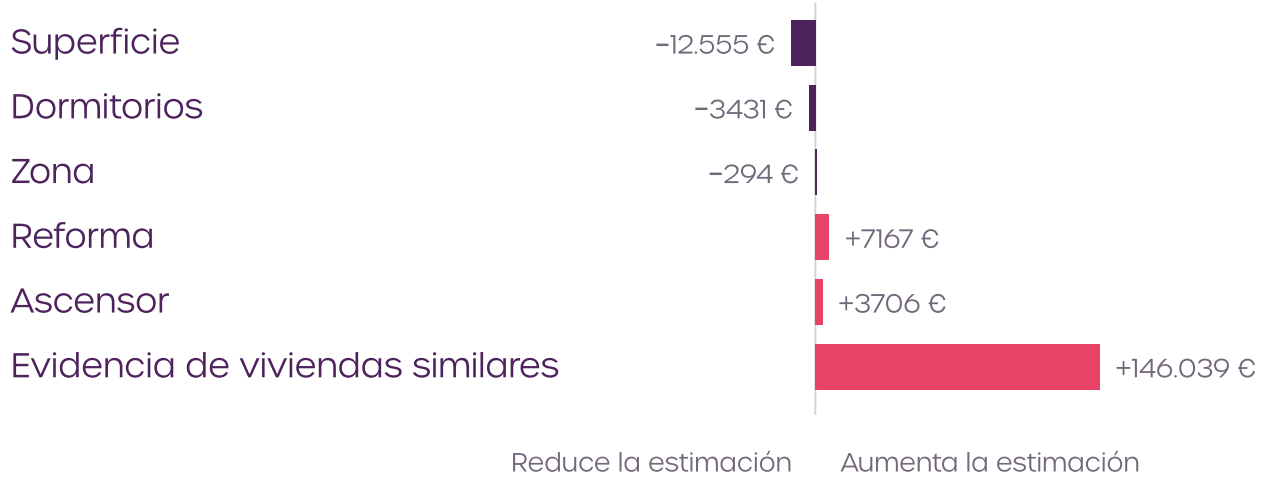
idealista: estimar el valor de un inmueble

Los atributos del inmueble y los inmuebles comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

Un desglose aritmético de esta estimación



Línea base 316.604 € + ajustes **= 305.065 €**

Aritmética exacta de la demo, antes de redondear. La línea base es la predicción media del modelo de entrenamiento

5 / 5

Detalles técnicos

¿Qué problema resuelve esto?

Para Ana, explica cómo afectan el tamaño, la reforma y el ascensor a esta estimación.

Este piso

80 m² frente a una media de entrenamiento de 93 m²: la superficie aporta −12.555 €.

Reforma y ascensor

Reformado: +7167 €. Con ascensor: +3706 €.

Demo calculada · viviendas y precios sintéticos

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

Innoit

Forecasting

Iberdrola (España)

Sistema MeteoFlow operativo

Concepto

Estimar valores futuros a partir de patrones temporales y de los factores disponibles.

Caso de uso real

MeteoFlow combina datos meteorológicos y de generación, y usa ML para afinar las previsiones de producción renovable.

Ventaja

Apoya la planificación cuando la producción eólica y solar varía con el tiempo meteorológico.

Limitación

La incertidumbre de la previsión crece con el horizonte y con los cambios meteorológicos inesperados.

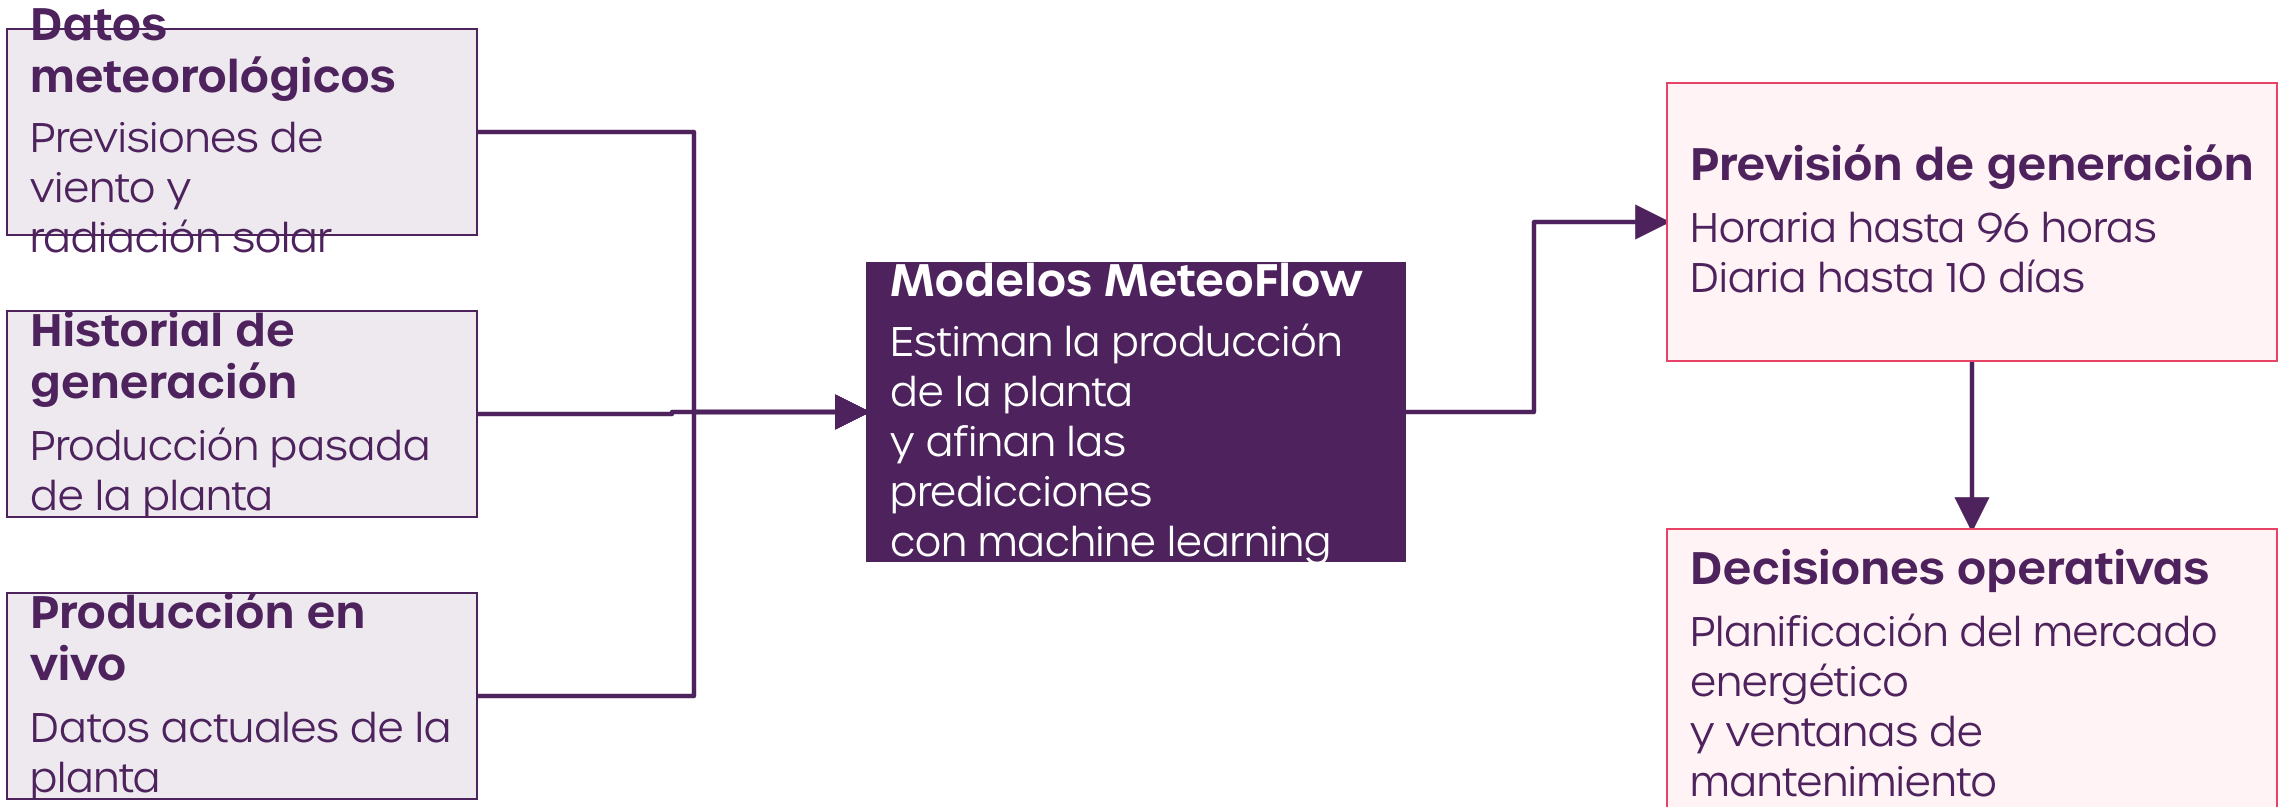
Iberdrola actualmente monitoriza más de 400 plantas eólicas y solares, con previsiones horarias de hasta 96 horas.

El forecasting convierte un futuro incierto en una entrada de planificación cuantificada.

Fuente: Iberdrola

Iberdrola: previsiones de producción renovable

MeteoFlow combina el tiempo externo con información histórica y en vivo de las plantas



Las fuentes de datos y los horizontes de previsión están documentados. Iberdrola no nombra la familia exacta de modelo de ML.

Fuente: Iberdrola

Análisis de sentimiento y PLN

Booking.com (Países Bajos)

Flujo documentado de análisis de reseñas

Concepto

Extraer opiniones del lenguaje y vincular cada opinión con aquello que describe.

Ventaja

Hace visibles los elogios y las quejas concretas entre muchas reseñas.

Caso de uso real

Booking.com vincula las opiniones de las reseñas con más de 50 aspectos, como la limpieza o la ubicación.

Limitación

El sarcasmo, las opiniones mixtas y las diferencias de idioma pueden cambiar la interpretación.

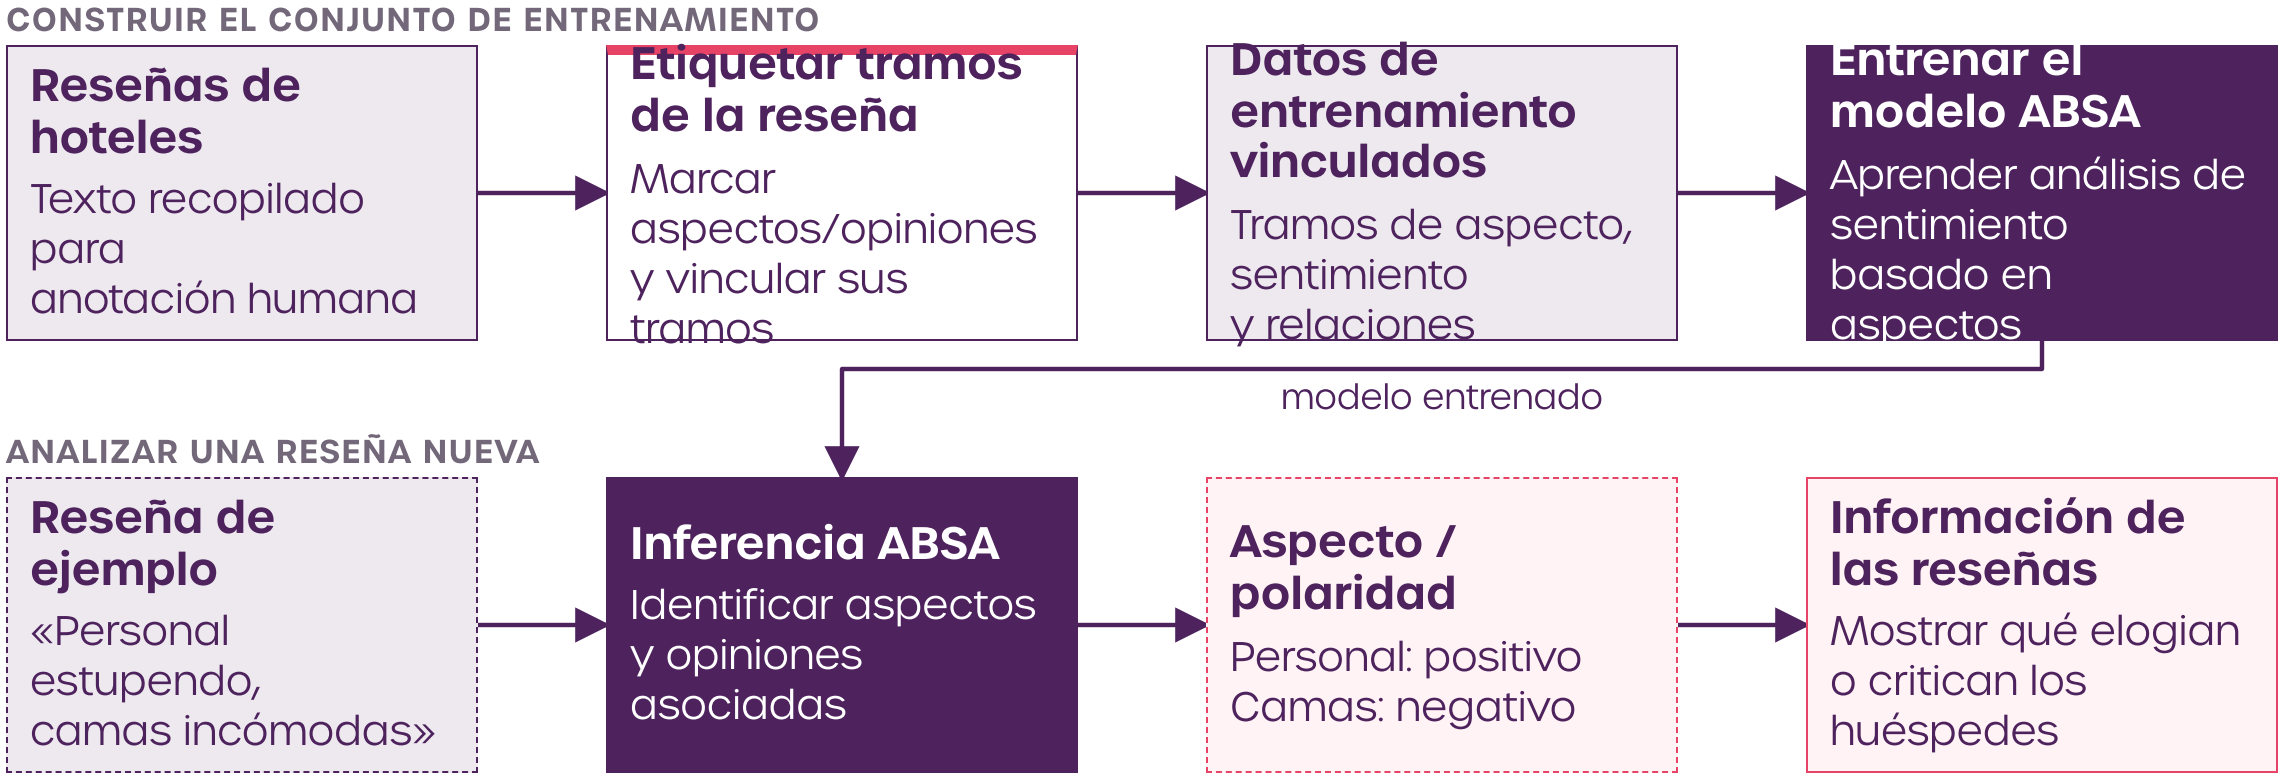
La extracción de aspectos identifica el tema. El análisis de sentimiento estima la opinión sobre él.

Una reseña puede elogiar la ubicación y criticar la habitación.

Fuente: Equipo de Booking.com / AWS Machine Learning Blog

Booking.com: opiniones por aspecto

El entrenamiento vincula tramos de aspecto con sentimiento. La inferencia devuelve juicios separados



Los cuadros discontinuos contienen un ejemplo didáctico. El artículo documenta la anotación y el propósito del modelo, no su arquitectura.

Fuente: Equipo de Booking.com / AWS Machine Learning Blog

Minería de textos

ING (Países Bajos)

Aplicación desplegada de monitorización del riesgo de crédito

Concepto

Extraer hechos estructurados y señales recurrentes de una gran colección de textos.

Caso de uso real

El Early Warning System de ING combina señales de noticias y de datos de mercado para los analistas de riesgo de crédito.

Incluye el procesamiento de hasta 80.000 noticias al día.

Ventaja

Ayuda a los analistas a monitorizar más información externa de la que pueden leer manualmente.

Limitación

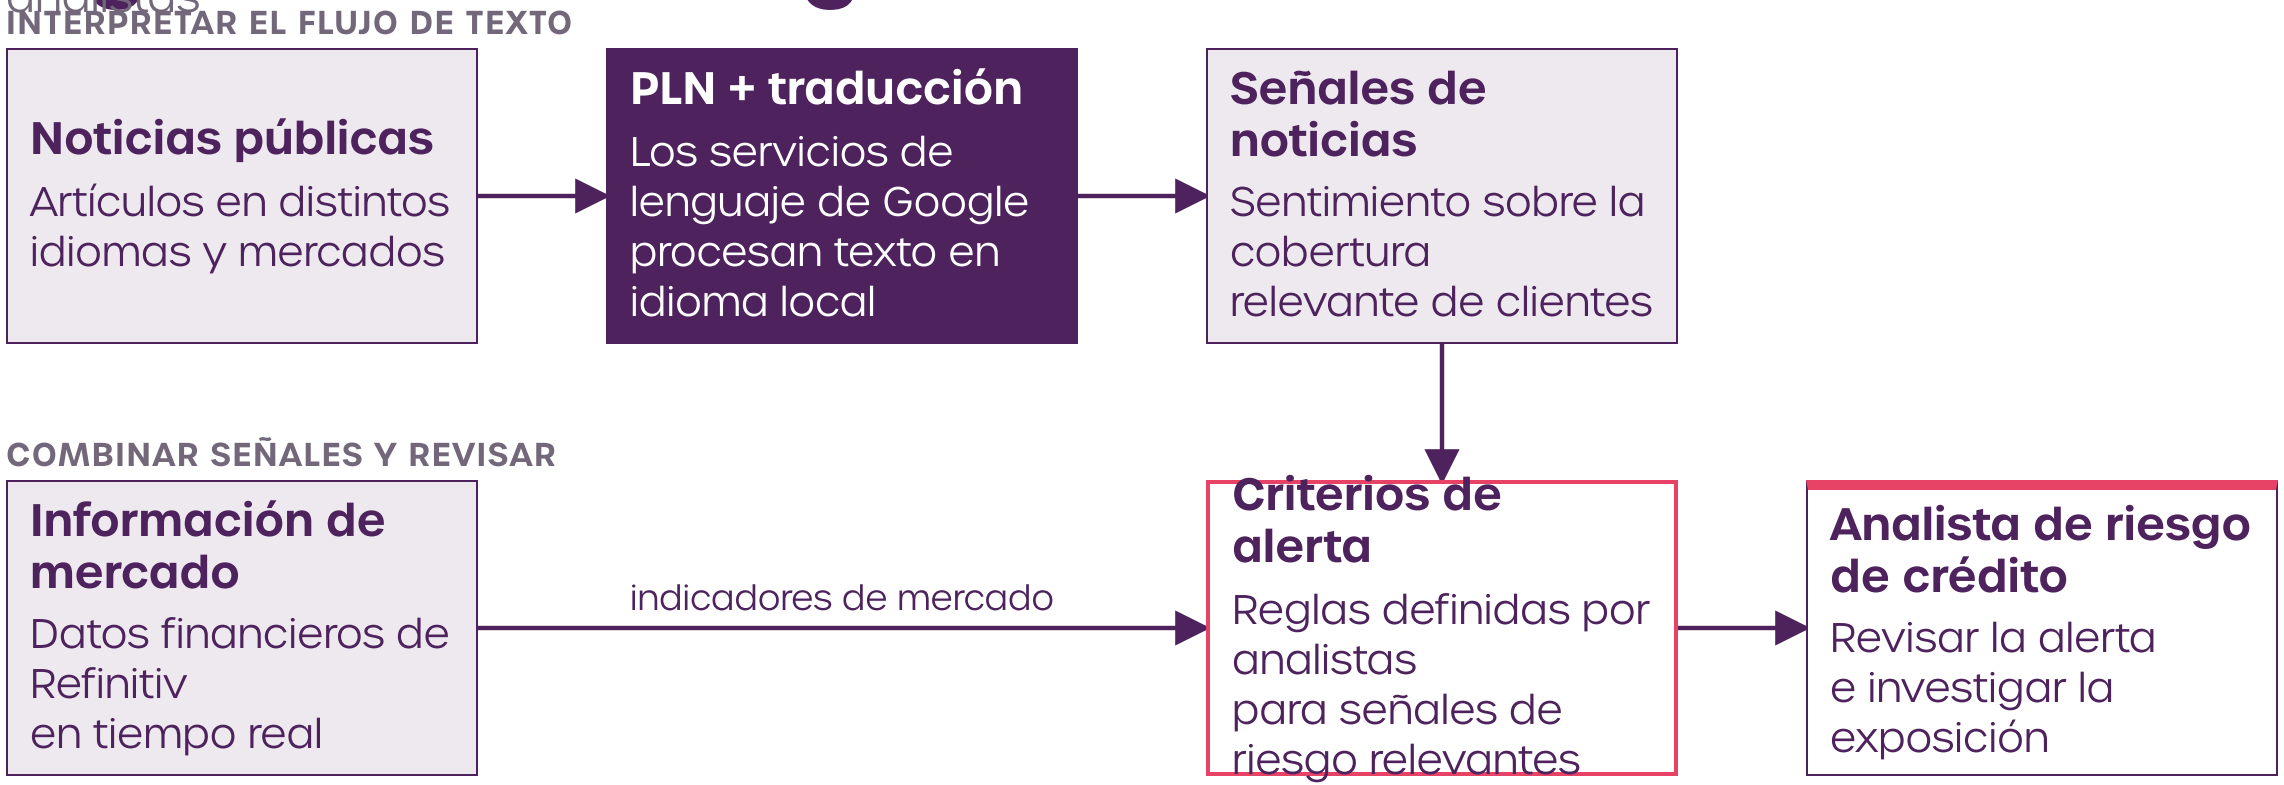
Las noticias irrelevantes o duplicadas generan ruido. Una señal sigue necesitando el criterio de un analista.

La minería de textos convierte un flujo de documentos en evidencia para investigar.

Fuente: ING

ING: las noticias se convierten en una lista de vigilancia de riesgo

El análisis de noticias y las señales de mercado se combinan con criterios de alerta definidos por analistas



La salida es una alerta para el analista. La fuente presenta la predicción de impagos como una ambición futura.

Fuente: ING

02

Deep learning

Las redes neuronales aprenden rasgos visuales y generan imágenes nuevas

Reconocimiento de patrones

BMW Group (Alemania)

Aplicaciones en producción en serie desde 2018

Concepto

Aprender rasgos visuales que identifican un objeto o una configuración recurrente.

Caso de uso real

En Dingolfing, BMW compara la insignia del modelo de un vehículo con la especificación del pedido y señala las inconsistencias antes de la entrega.

Ventaja

Realiza controles visuales repetidos a la velocidad de la producción.

Limitación

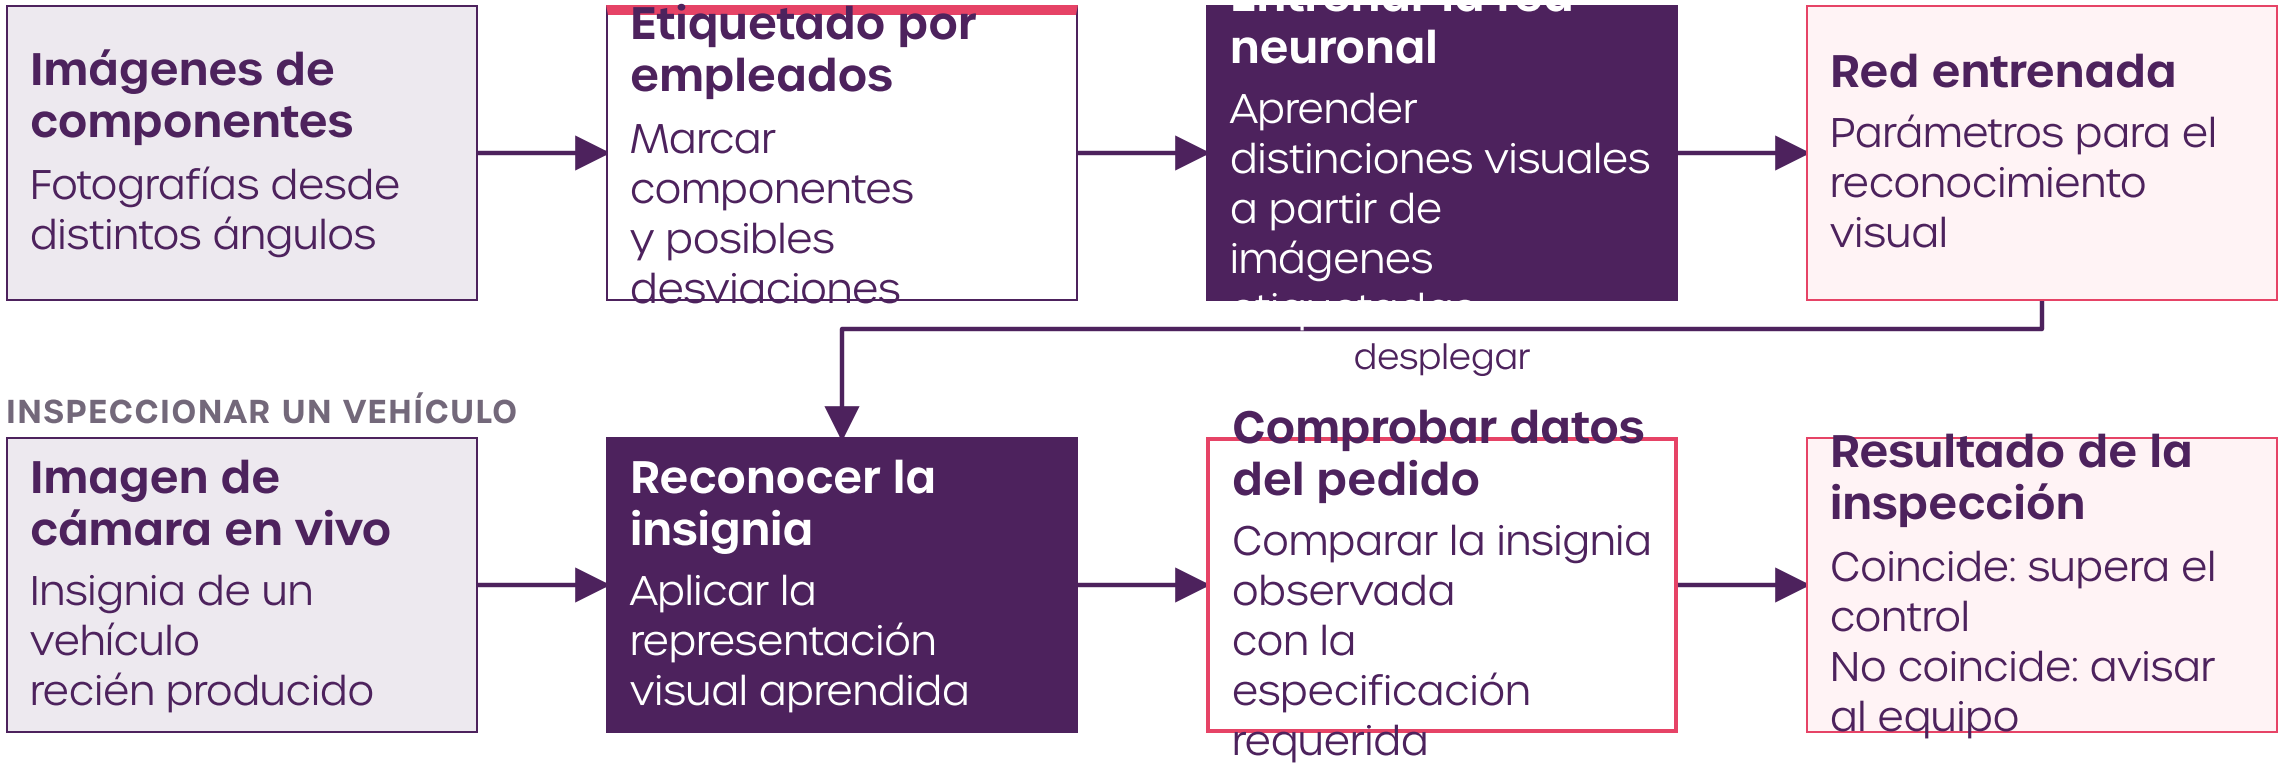
Los componentes nuevos y las condiciones de iluminación requieren imágenes representativas y monitorización.

Un patrón visual aprendido puede convertir la imagen de una cámara en un control de calidad.

Fuente: BMW Group

BMW: el reconocimiento de imágenes comprueba la insignia

Aprender el patrón visual y comprobar el pedido son pasos separados



La red neuronal reconoce la imagen. La lógica de negocio compara el resultado del reconocimiento con los datos del pedido del vehículo.

Fuente: BMW Group

Inspección visual en BMW

La cámara observa un componente del vehículo.

La red neuronal lo reconoce

El software compara el resultado con la especificación del pedido y señala cualquier discrepancia.



Foto de producción de BMW Group. Fuente: BMW Group, 15 de julio de 2019.

Generación de imágenes

Mango (España)

Campaña Mango Teen publicada

Concepto

Generar imágenes nuevas a partir de la estructura visual aprendida.

Ventaja

Amplía las opciones creativas y apoya flujos de producción repetibles.

Caso de uso real

Mango creó Sunset Dream a partir de fotos reales de las prendas, un modelo generativo y una selección y un retoque realizados por personas.

Limitación

La fidelidad al producto y la calidad editorial siguen requiriendo dirección de arte humana.

Mango no nombra ninguna arquitectura de modelo concreta. Difusión y GAN son ejemplos generales, no elecciones confirmadas.

Generar imágenes nuevas conservando las características del producto real.

Fuente: Mango Fashion Group

Mango: de prendas reales a imágenes de campaña

El flujo publicado incluye entrenamiento del modelo y producción editorial humana



Mango no nombra la difusión, las GAN ni un modelo concreto. La selección y el retoque humanos son pasos documentados.

Fuente: Mango Fashion Group

Mango Teen: Sunset Dream

Una campaña publicada, creada con IA generativa en julio de 2024.

Las fotografías reales de las prendas anclan el trabajo

El equipo de arte de Mango selecciona y retoca las imágenes generadas para conservar el detalle del producto y la calidad editorial.



Imagen oficial de la campaña. Crédito: Mango Fashion Group

03

Sistemas GenAI

Recuperación, generación multimodal y uso coordinado de herramientas

Innoit

Qué aporta RAG a un modelo de lenguaje

Recuperación

1. Leer la pregunta del empleado.
2. Buscar en la base de conocimiento autorizada.
3. Seleccionar los pasajes relevantes de los documentos.

Generación fundamentada

4. Dar al modelo la evidencia recuperada.
5. Generar una respuesta con fuentes.
6. Comprobar la respuesta o escalarla.

Búsqueda inteligente con RAG

Allianz (Alemania)

EKA en producción en Allianz Leben desde julio de 2024

Concepto

Recuperar conocimiento relevante antes de que un LLM genere una respuesta.

Caso de uso real

Allianz EKA busca en AWISO, resume el conocimiento relevante y remite al personal del centro de llamadas a las fuentes completas.

Ventaja

Hace que el conocimiento interno sea más fácil de consultar y de revisar.

Limitación

La falta de resultados de recuperación y los documentos desactualizados pueden seguir produciendo respuestas erróneas.

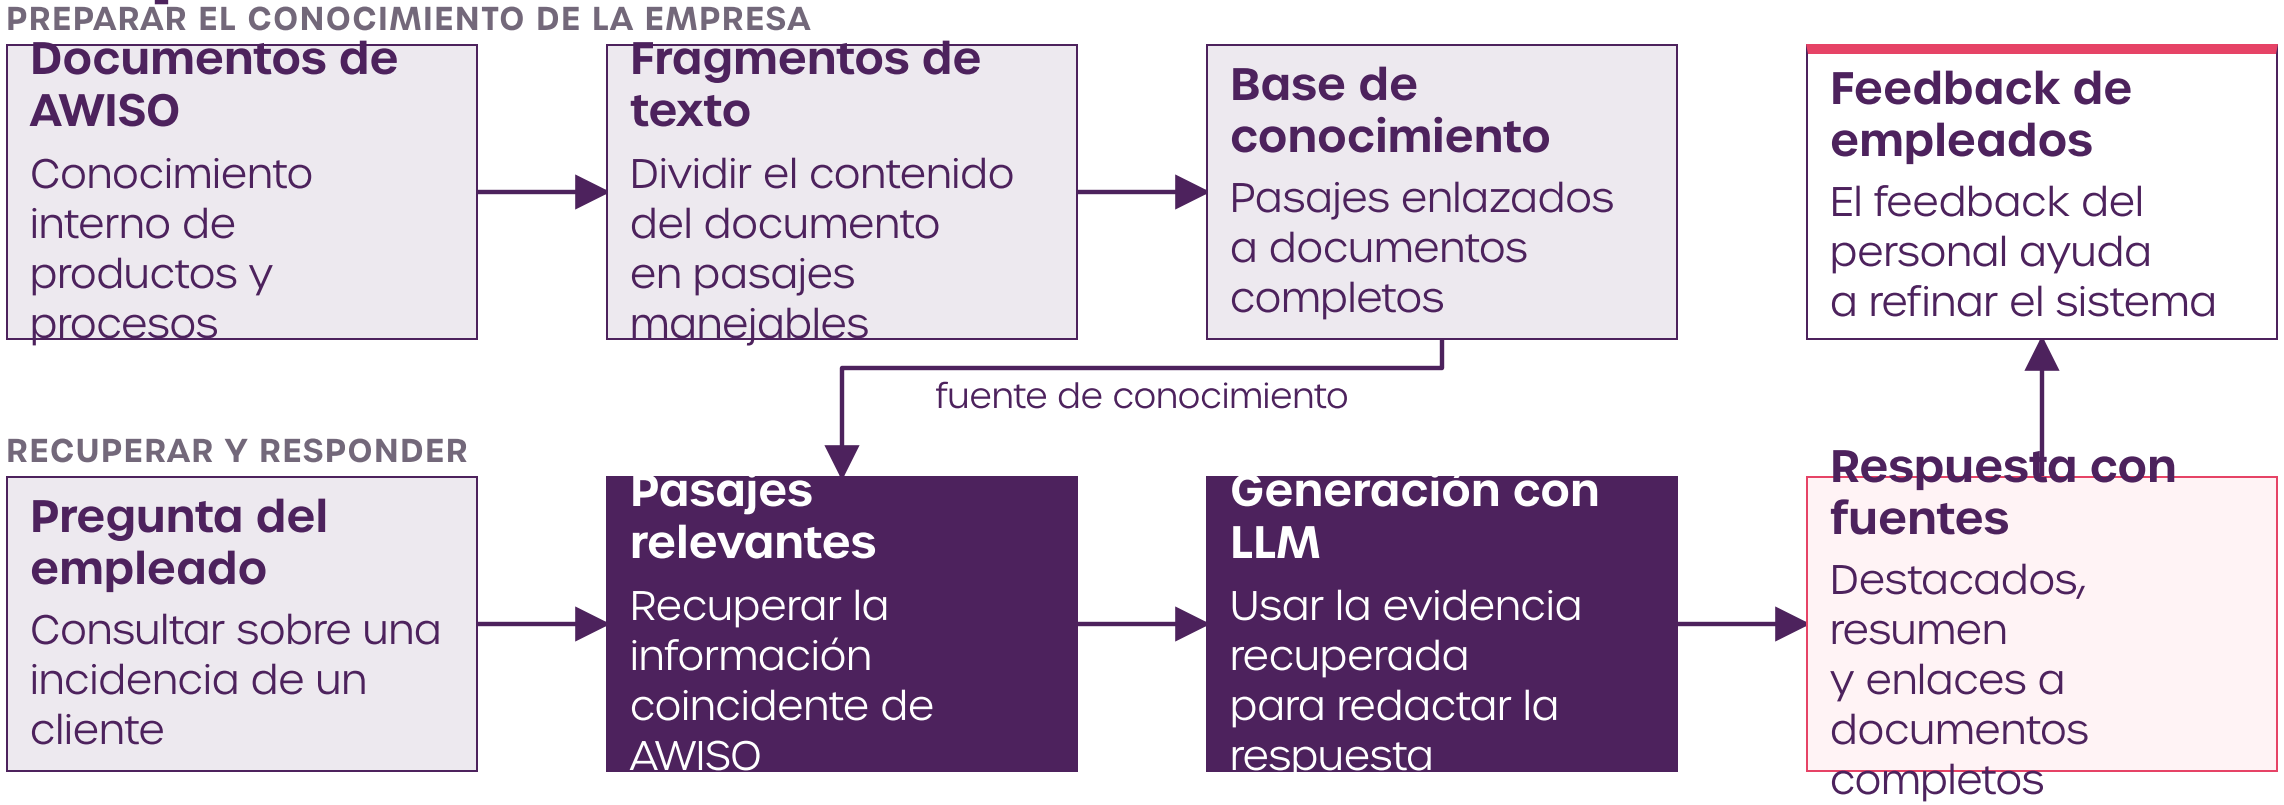
Allianz comunica una exactitud superior al 90 % en las consultas habituales, sin publicar la metodología del benchmark.

Primero se recupera la evidencia y después se genera una respuesta fundamentada.

Fuente: Allianz

Allianz: la recuperación fundamenta la respuesta

EKA busca en el conocimiento de AWISO y devuelve información verificable a los empleados



Esta vista funcional de RAG omite los demás agentes de EKA. La fuente no publica su recuperador ni su modelo de embeddings exactos.

Fuente: Allianz

Generación multimodal

Google (Estados Unidos)

Veo 3 lanzado en Google Vids (junio de 2025)

Concepto

Generar contenido relacionado entre modalidades, como vídeo y sonido.

Ventaja

Crea un borrador audiovisual sin tener que filmar ni grabar una primera versión.

Caso de uso real

Google Vids usa Veo 3 para convertir un prompt de texto en un clip de vídeo con sonido, listo para previsualizar e insertar.

Limitación

La continuidad visual, el habla y los detalles factuales siguen necesitando revisión humana.

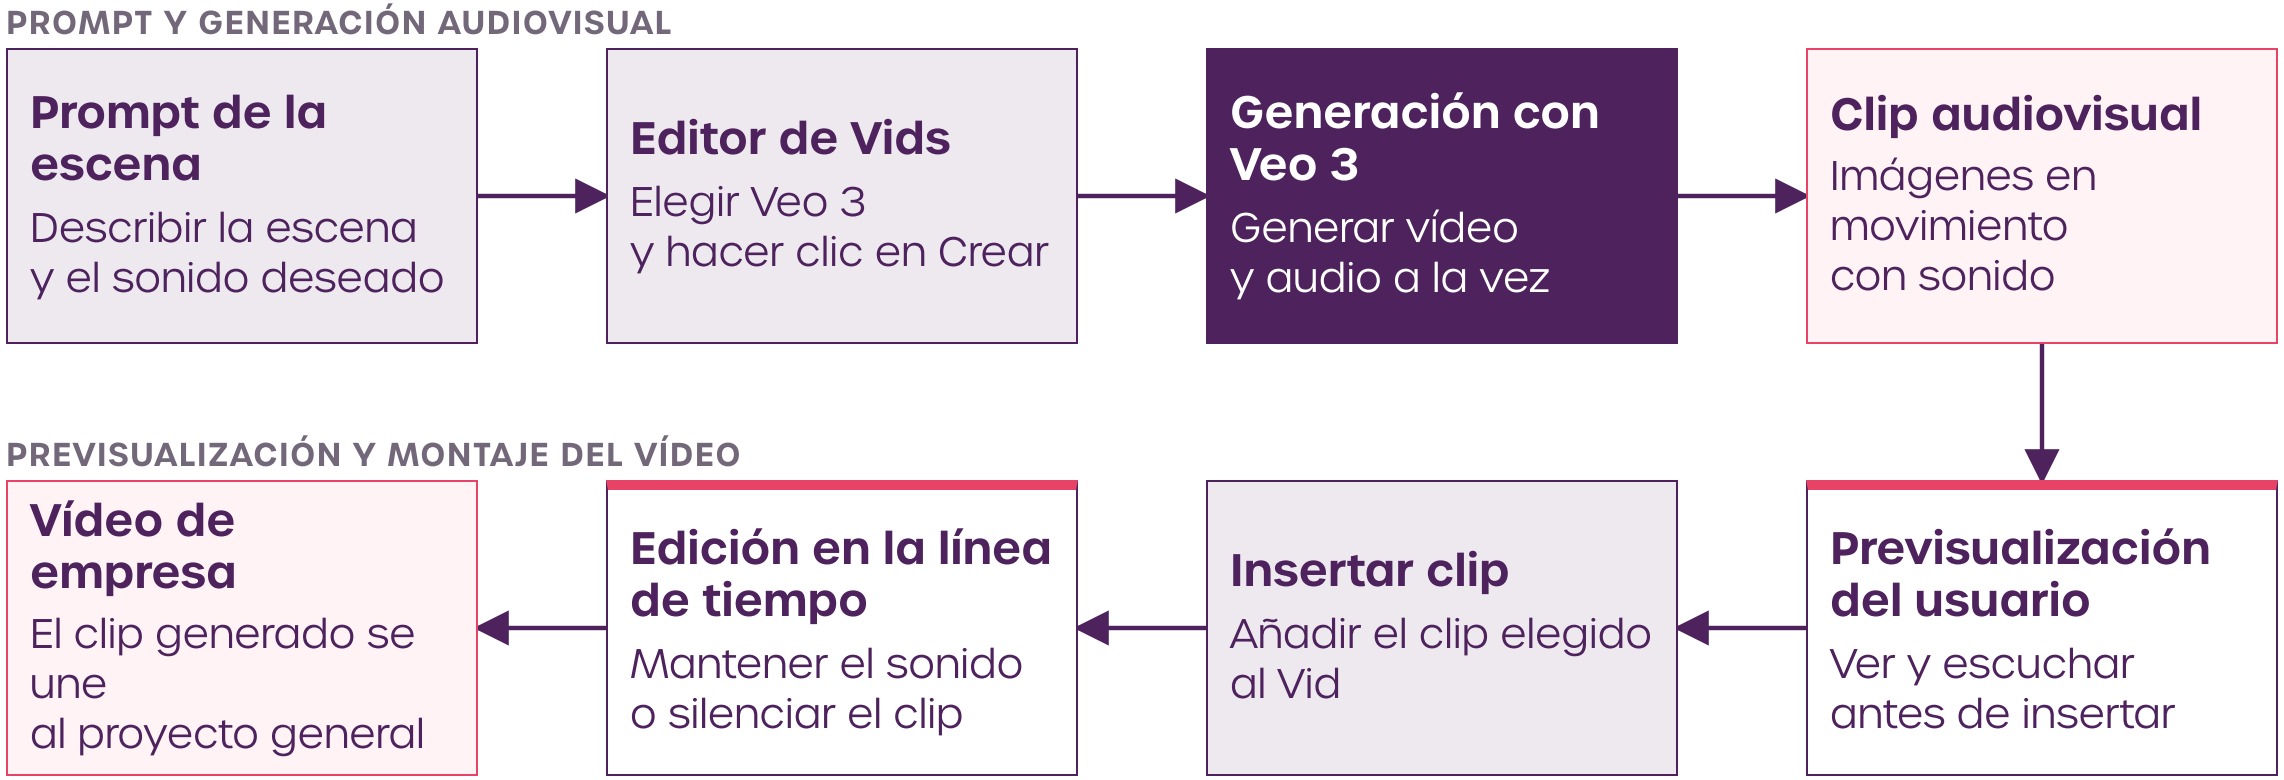
El comunicado de lanzamiento documenta clips de 8 segundos. Es una capacidad de producto ya lanzada.

Un solo prompt puede generar tanto la escena en movimiento como su sonido.

Fuente: Google Workspace Updates

Google Vids: generar vídeo y sonido

Veo 3 genera ambas modalidades. El usuario previsualiza el clip antes de insertarlo



La versión de junio de 2025 documenta clips de 8 segundos con sonido. La previsualización y la inserción siguen bajo control del usuario.

Fuente: Google Workspace Updates

Qué coordina un orquestador

Solicitud y enrutamiento

1. Interpretar el objetivo y el contexto.
2. Seleccionar un especialista o una herramienta relevante.
3. Pedir aclaraciones cuando haga falta.

Acción y retroalimentación

4. Ejecutar la operación autorizada.
5. Inspeccionar el resultado y actualizar el estado.
6. Responder, reintentar o pasar el caso a una persona.

Orquestación de flujos agénticos

BBVA (España)

Asistente Blue desplegado en España en 2025

Concepto

Coordinar agentes y herramientas especializados para completar una tarea acotada.

Ventaja

Conecta las solicitudes conversacionales con operaciones definidas de cuentas y tarjetas.

Caso de uso real

Blue enruta las solicitudes a una herramienta bancaria, a un agente de información o a un paso de aclaración.

Limitación

Los errores de enrutamiento pueden elegir un flujo equivocado. Los permisos y las confirmaciones importan.

BBVA describe el filtrado de más de 150 operaciones hasta unos 5-6 candidatos antes del enrutamiento.

Los agentes resultan operativamente útiles cuando la herramienta adecuada puede ejecutar la tarea.

Fuente: BBVA AI Factory y anuncio del despliegue de BBVA

BBVA Blue: enrutar una solicitud bancaria

El agente de enrutamiento elige un especialista, una herramienta o una respuesta de aclaración



Las operaciones bancarias son herramientas invocables. Una conversación puede ramificarse entre herramienta, acción y aclaración.

Fuente: BBVA AI Factory y anuncio del despliegue de BBVA

Elección de método: salidas estructuradas

Pregunta de negocio	Método	Caso
¿Qué ocurre junto?	Reglas de asociación	Walmart
¿Cuál de dos resultados?	Clasificación binaria	Cabify
¿Qué categoría única?	Clasificación multiclase	Uber
¿Qué etiquetas solapadas?	Clasificación multietiqueta	Amazon
¿Qué grupos emergen?	Clustering	Spotify
¿Qué se desvía de lo normal?	Detección de anomalías	Adyen
¿Qué valor numérico?	Regresión	idealista
¿Qué valor futuro?	Forecasting	Iberdrola

La salida y la decisión de negocio determinan la tarea.

Elección de método: lenguaje y GenAI

Pregunta de negocio	Método	Caso
¿Sobre qué es la opinión?	Sentimiento y PLN	Booking.com
¿Qué señales aparecen en el texto?	Minería de textos	ING
¿Qué patrón visual hay?	Reconocimiento de patrones	BMW
¿Qué imagen podemos crear?	Generación de imágenes	Mango
¿Qué dicen nuestros documentos?	Búsqueda con RAG	Allianz
¿Puede un prompt dar vídeo y sonido?	Generación multimodal	Google
¿Puede el software completar la tarea?	Orquestación de agentes	BBVA

La generación de imágenes usa deep learning y ya es una forma de GenAI.

Valor de negocio y calidad del modelo

Un modelo útil cambia una decisión o facilita un flujo de trabajo.

- **Clasificación:** la precisión y el recall reflejan costes de error distintos.
- **Predicción:** los backtests necesitan límites realistas de tiempo y de datos.
- **Sistemas GenAI:** una recuperación correcta o un texto fluido, por sí solos, no demuestran el éxito de la tarea.
- **Todo método:** el despliegue requiere responsables, monitorización y una alternativa clara.

Fuentes 1 de 3

Walmart Reglas de asociación

Walmart Global Tech · 24 ago 2022

Cabify Clasificación binaria

Caso de cliente de Infobip con testimonio de Cabify · Caso de cliente sin fecha

Uber Clasificación multiclase

Uber Engineering · 3 ene 2018

Amazon Retail Clasificación multietiqueta

Amazon / AWS Open Source Blog · 14 jul 2020

Spotify Clustering

Spotify Engineering · 5 dic 2023

Fuentes primarias de las empresas o de sus socios de implementación. Los enlaces adicionales figuran en las notas del orador. Consultadas del 19 al 20 de octubre de 2026.

Fuentes 2 de 3

Adyen Detección de anomalías

Adyen Engineering · 9 oct 2019

idealista/data Análisis de regresión

idealista/data e idealista labs · Página de producto y artículo de ingeniería del 17 feb 2021

Iberdrola Forecasting

Iberdrola · Página corporativa de proyecto sin fecha

Booking.com Análisis de sentimiento y PLN

Equipo de Booking.com / AWS Machine Learning Blog · 14 ene 2022

ING Minería de textos

ING · 17 dic 2018

Fuentes primarias de las empresas o de sus socios de implementación. Los enlaces adicionales figuran en las notas del orador. Consultadas del 19 al 20 de octubre de 2026.

Fuentes 3 de 3

BMW Group Reconocimiento de patrones

BMW Group · 15 jul 2019

Mango Generación de imágenes

Mango Fashion Group · 10 jul 2024

Allianz Búsqueda inteligente con RAG

Allianz · 7 feb 2025

Google Generación multimodal

Google Workspace Updates · 9 jun 2025

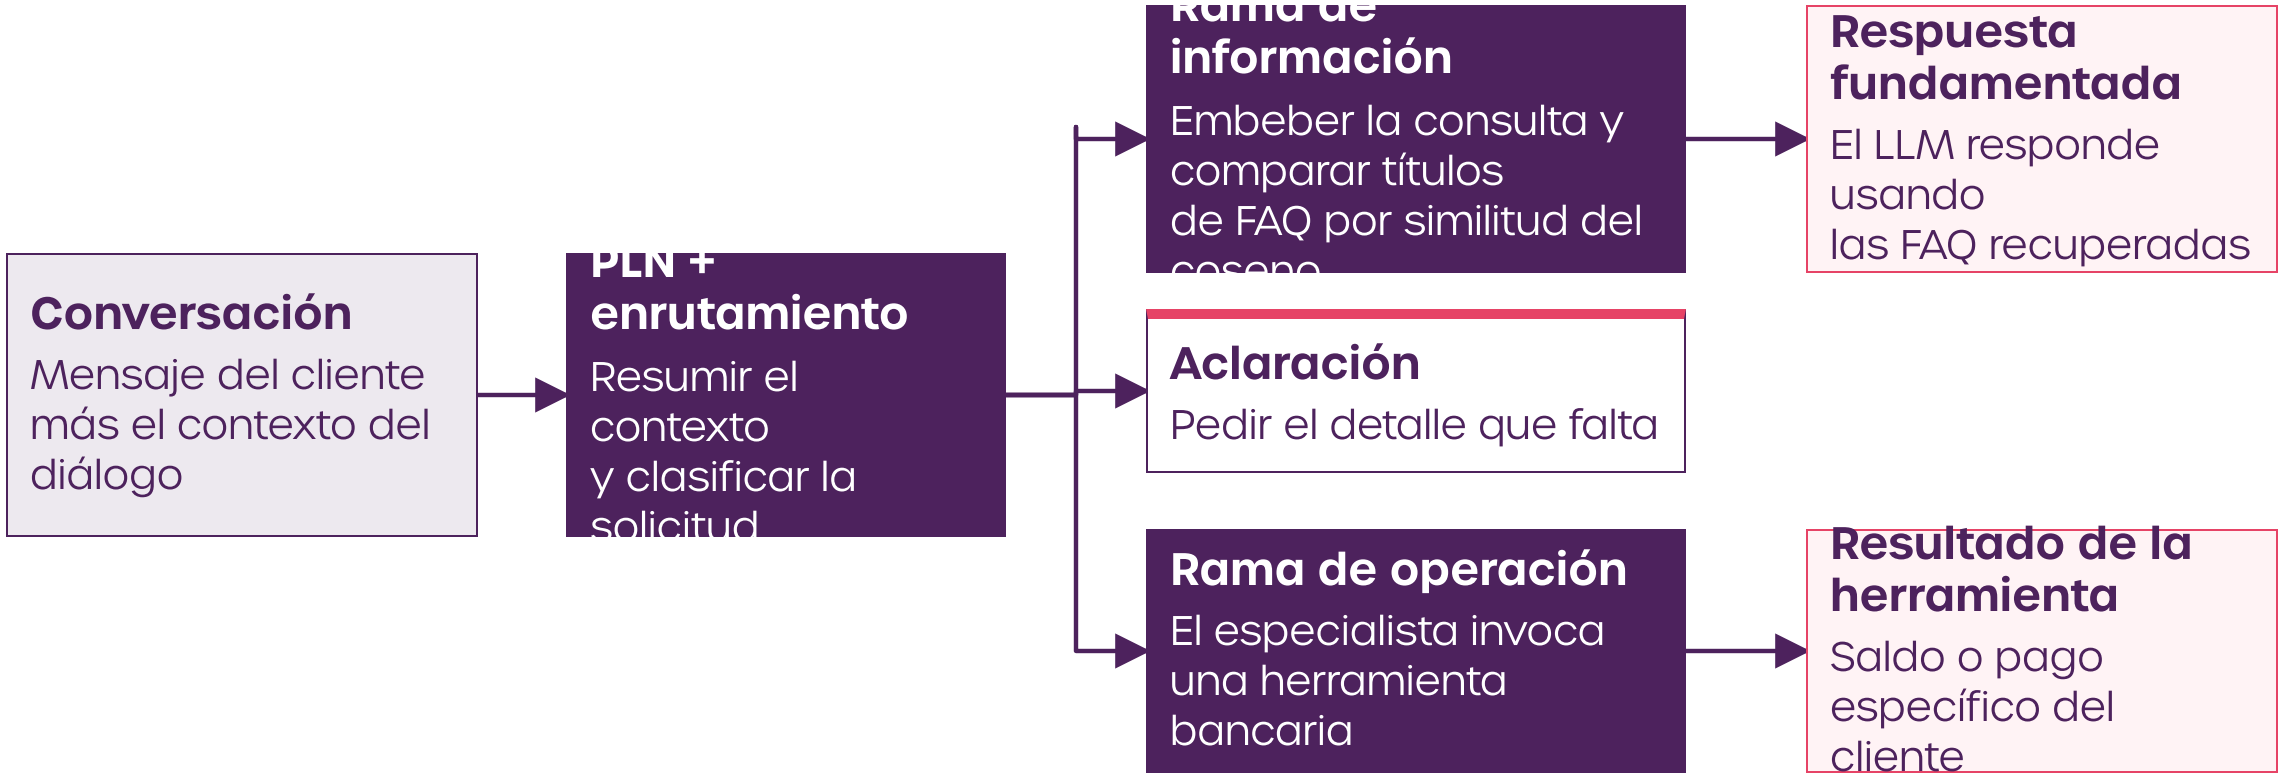
BBVA Orquestación de flujos agénticos

BBVA AI Factory y anuncio del despliegue de BBVA · Relato técnico del 13 nov 2025

Fuentes primarias de las empresas o de sus socios de implementación. Los enlaces adicionales figuran en las notas del orador. Consultadas del 19 al 20 de octubre de 2026.

BBVA Blue: conocimiento y acciones

Un asistente combina PLN, clasificación de intenciones, RAG y orquestación de herramientas



Las FAQ genéricas y las operaciones específicas del cliente siguen ramas distintas. La información que falta provoca una aclaración.

Fuente: BBVA AI Factory: agente de enrutamiento y agente de información RAG

Debate

¿Qué decisión de negocio necesita una mejor entrada?

¿Una regla, una predicción, contenido generado o una tarea completada?

www.inno-it.es