Machine learning
en empresas reales

Predecir, agrupar y combinar: de idealista y Spotify al simulador de Uber

PONENTE

Andrés Herencia · AI Engineer en InnoIT

Diseño y construyo soluciones de IA y machine learning aplicadas a casos reales.

Innoit

Objetivo de la presentación

La IA y el **machine learning** ya están en las aplicaciones que usamos cada día. Hoy veremos **qué hay detrás** y **cómo se implementa** cada caso de uso.

¿Cuánto vale este piso?

Buscas casa y el portal te da un precio estimado al instante.

¿Qué tipo de oyente eres?

La app de música agrupa a millones de usuarios por cómo escuchan.

¿Por qué hoy cuesta más?

Pides un coche con lluvia y la tarifa sube para atraer conductores.

Cada caso, con el mismo método: **Datos** → **Modelo** → **Decisión**

Tres casos de uso

idealista/data

01 **Regresión**

Predecir el valor de una vivienda

- Modelo hedónico y comparables
- Demo: valora un piso

Spotify®

02 **Clustering**

Agrupar oyentes sin etiquetas

- UMAP y HDBSCAN para segmentar
- Demo: explora los grupos

Uber

03 **Sistema completo**

Fijar el precio dinámico

- Demanda, zonas y precio
- Simulador web paso a paso

01

Predicción: idealista

Innoit

Análisis de regresión

idealista/data (España)

Servicio comercial de valoración automática

Concepto

Estimar un número a partir de variables.

Caso de uso real

Comparables y ML hedónico para valorar inmuebles.

Ventaja

Valoraciones coherentes a gran escala.

Limitación

Pierde precisión si faltan datos o cambia el mercado.

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

El inmueble objeto se convierte en un vector de variables

El piso de Ana

Zona B · mercado ficticio

Superficie	80 m²	Dormitorios	2
Reformado	Sí	Ascensor	Sí

↓

$$x = [80, 2, 1, 0, 1, 1]$$

superficie, dorm., zona B, zona C, reformado, ascensor

La zona A es la referencia. Las zonas B y C usan indicadores 0/1 independientes.

1 / 5

Detalles técnicos

La vivienda de Ana que hay que valorar

Ana quiere estimar el precio de su piso. Cambia sus atributos para seguir la misma vivienda en cada paso.

Superficie — 80 m²

Dormitorios — 2

Zona ficticia — Zona B

Reformado — ☑

← Atrás | Siguiente → | Reproducir | Reiniciar

Editar vivienda | 80 m² · 2 dorm. · Zona B | Abrir explorador ↗

Demo calculada · viviendas y precios sintéticos

Fuente: idealista/data e idealista labs

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Innoit

02

Clasificación y agrupamiento: Spotify

Innoit

Clustering

Spotify (Suecia)

Método documentado de investigación de usuarios

Concepto

Agrupar datos parecidos sin etiquetas previas.

Caso de uso real

UMAP y HDBSCAN para segmentar usuarios.

Ventaja

Descubre segmentos inesperados.

Limitación

Los grupos dependen de las variables elegidas.

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

Primero se descubren los grupos; después, un modelo explica qué los define

Spotify

1 Ejemplo | 2 Variables | 3 UMAP | 4 HDBSCAN | 5 XGBoost | 6 SHAP | 7 Explicabilidad

Las personas detrás del caso de uso

Personas	Ana y Luis escuchan a AC/DC y a Metallica. Marta escucha a Taylor Swift.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de rock y metal como la señal principal del grupo.
Uso posible	Sugerir Iron Maiden a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

1 / 7

Detalles técnicos

Un ejemplo concreto de escucha

Ana y Luis comparten artistas. ¿Podemos descubrir su grupo y explicar qué lo hace diferente?

Sigue a las mismas personas

Cada paso siguiente explica qué supondría el algoritmo para Ana, Luis y Marta.

Historia ilustrativa. Los gráficos calculados usan variables de comportamiento sintéticas, sin recuentos de artistas ni usuarios con nombre.

← Atrás | Siguiente → | Reproducir | Reiniciar

Todos los oyentes | Preajuste calculado | Equilibrada · mcs 100 | Abrir explorador ↗

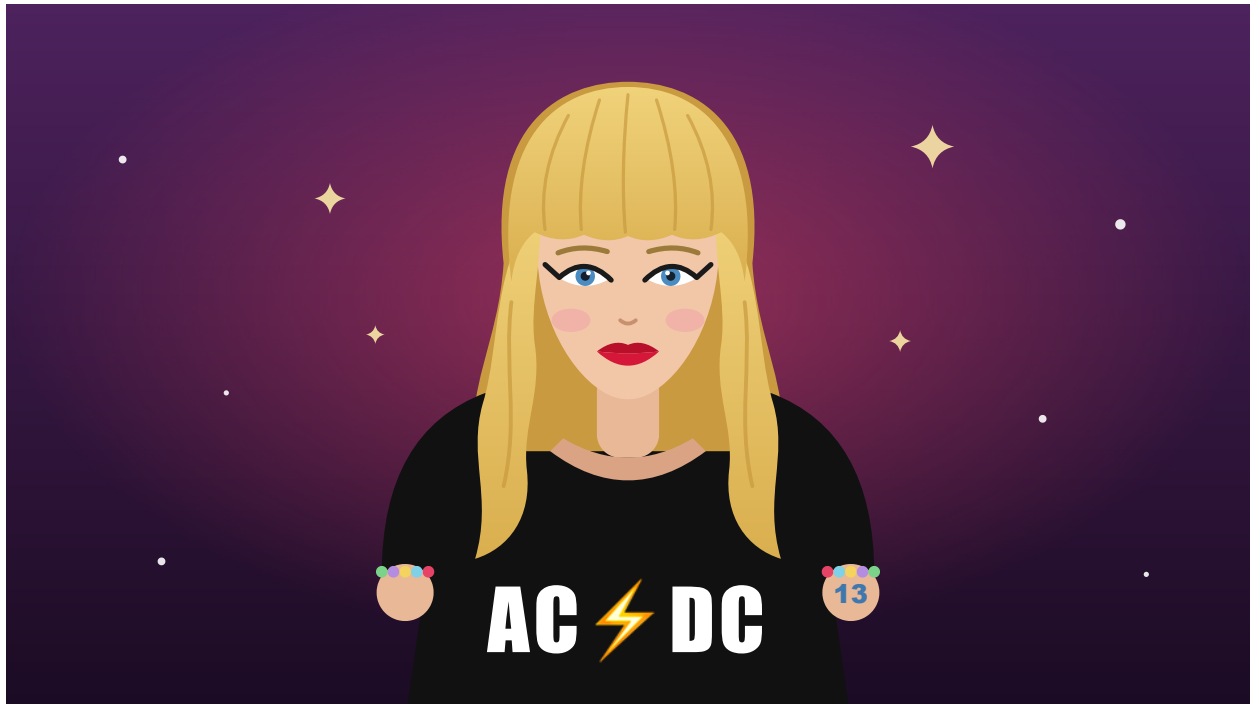
Demo calculada · oyentes sintéticos

Fuente: Spotify Engineering

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Cuando el grupo se equivoca de grupo

Marta escuchaba a Taylor Swift, pero si un día se pone la camiseta de AC/DC...
¿sigue en su grupo?



03

Juntamos todo: simulador de Uber

Innoit

De dos casos a un sistema completo

Lo que ya hemos visto

Regresión (idealista): estimar un valor continuo a partir de atributos.

Clustering (Spotify): agrupar observaciones parecidas sin etiquetas.

Lo que añade Uber

Series temporales: pronosticar la demanda de los próximos minutos.

Un bucle de control: corregir el precio cada pocos minutos hasta equilibrar oferta y demanda.

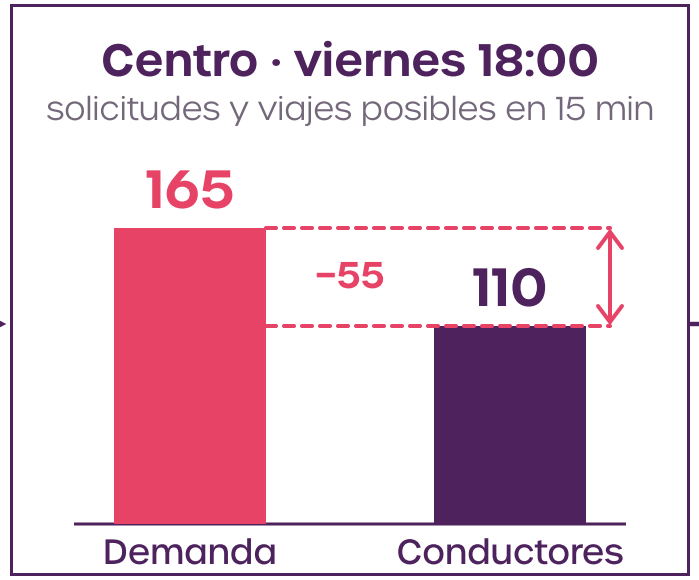
Uber: el problema

En cada zona y cada pocos minutos, la demanda y los conductores casi nunca coinciden

QUÉ MUEVE LA DEMANDA

- Hora y día
- Clima
- Eventos
- Tráfico

LA ZONA AHORA



SI NADIE ACTÚA

Demanda mayor que oferta

Esperas largas, más cancelaciones y usuarios menos satisfechos

LO QUE OCURRE EN CENTRO

Oferta mayor que demanda

Menos viajes por conductor, menos ingresos y desconexión

EN OTRA ZONA O A OTRA HORA

Reto: equilibrar oferta y demanda en minutos, zona a zona

El reto no es solo predecir: es equilibrar oferta y demanda antes de que el desajuste perjudique a todos.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

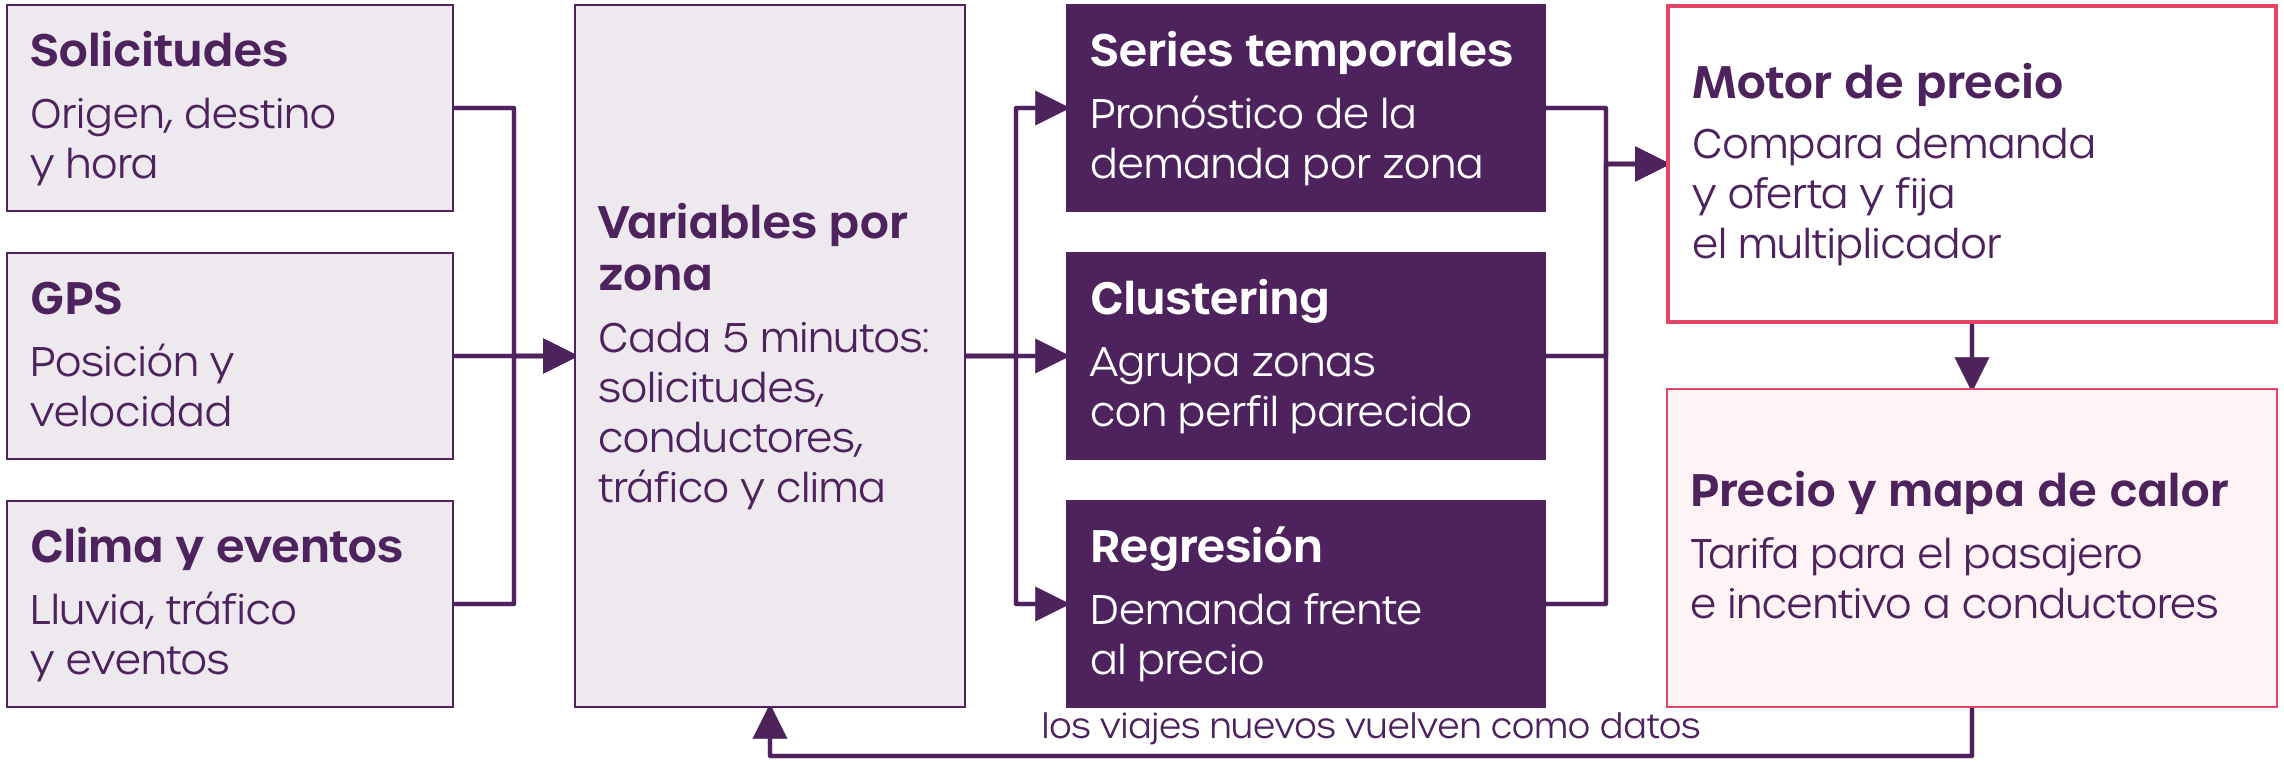
Los datos de partida

Fuente	Qué contiene	Para qué sirve
Solicitudes y viajes	Origen, destino, hora, duración, ruta, cancelaciones y pagos	Medir la demanda real y su histórico
GPS de móviles	Posición y velocidad de cada conductor, cada pocos segundos	Conocer la oferta y el tráfico en tiempo real
Contexto externo	Clima, cortes de carretera y eventos locales	Anticipar picos que el histórico no explica
Uso de la app	Valoraciones, cancelaciones y comentarios	Entender el comportamiento y la satisfacción

Volumen, variedad y velocidad: las tres «V» del Big Data. Fuente: Shuaib Ullattil, Medium (5 feb 2026).

Uber: del dato al precio

Del dato en bruto al precio que ve el pasajero, con un bucle de realimentación



Reconstrucción didáctica a partir de la descripción del artículo: la arquitectura real de Uber no es pública.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Algoritmos

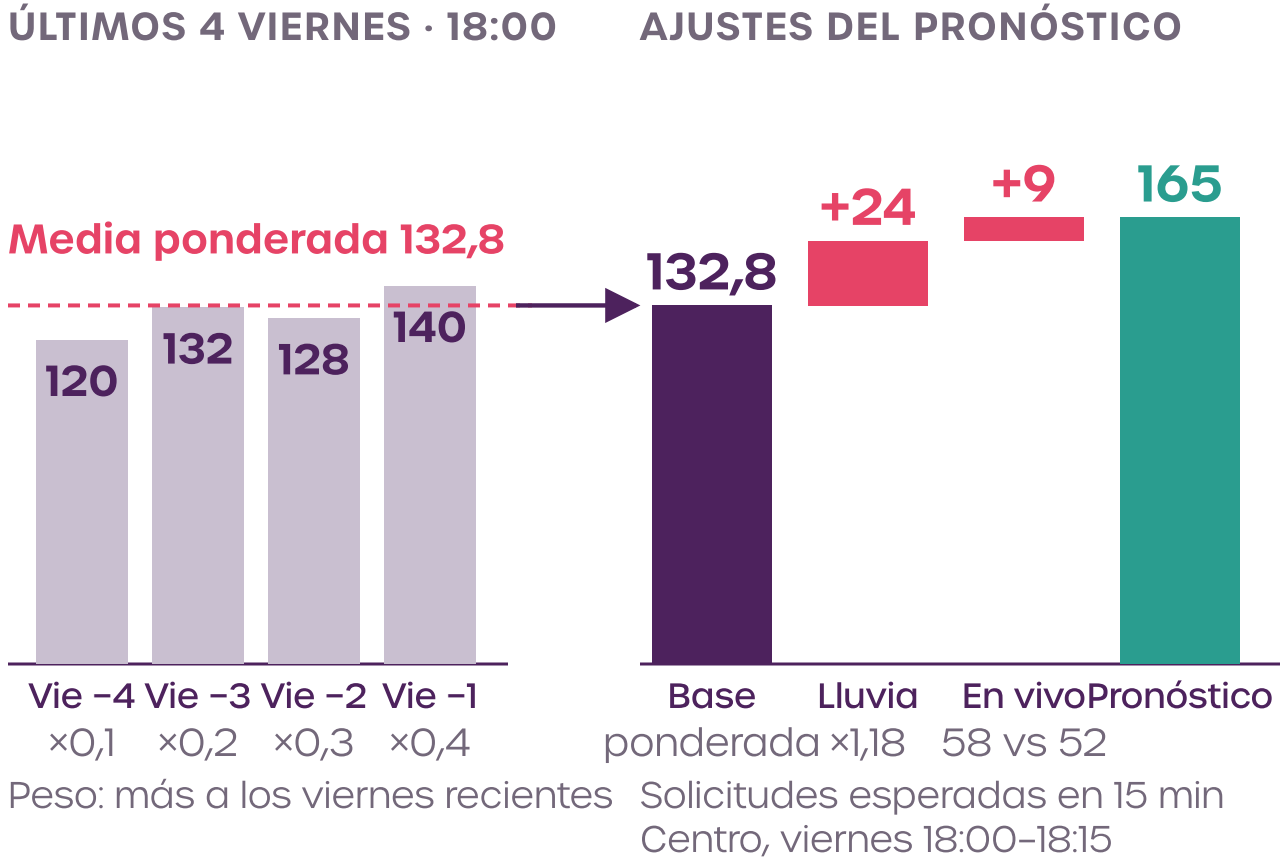
Cuatro piezas, paso a paso

Cada una con un ejemplo numérico sintético: Centro, viernes 18:00, con lluvia.

Series temporales: ¿cuántos viajes habrá?

Algoritmo 1/4 Pronóstico de la demanda de Centro entre las 18:00 y las 18:15

1. **Mirar el pasado.** Solicitudes a esa hora los últimos 4 viernes: 120, 132, 128 y 140.
2. **Ponderar.** Los viernes recientes pesan más: 0,1·120 + 0,2·132 + 0,3·128 + 0,4·140 = **132,8**.
3. **Ajustar por contexto.** Un modelo aprendió que la lluvia añade ≈18 % de demanda: 132,8 × 1,18 = **156,7**.
4. **Corregir en vivo.** En los primeros 5 min hay 58 solicitudes frente a 52 esperadas (+11 %). Se aplica la mitad: 156,7 × 1,055 = **165**.

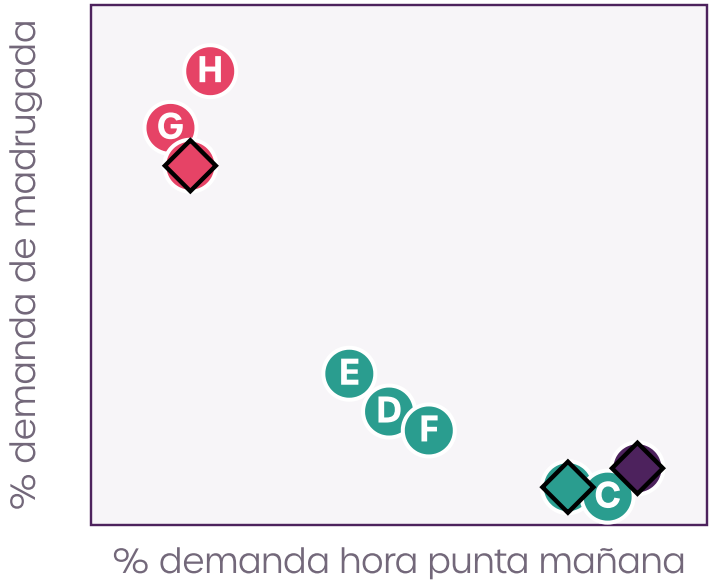


Datos sintéticos. Uber no publica sus modelos: aquí se usa una media ponderada estacional con ajustes, la forma más sencilla de una serie temporal.

Clustering: ¿qué tipo de zona es?

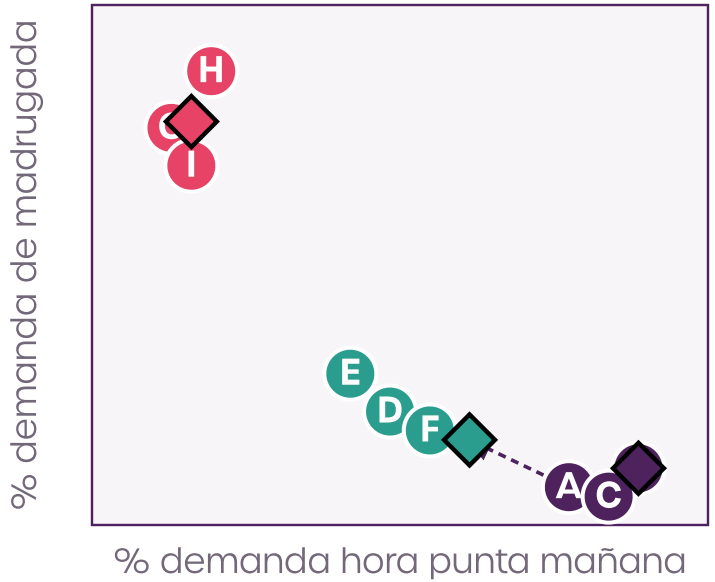
Algoritmo 2/4 k-means agrupa zonas por su perfil de demanda (k = 3)

1 · Centros iniciales



Dos centros caen en la misma zona de negocios. Cada zona pasa al centro más cercano.

2 · Mover y reasignar



Cada centro pasa a la media de sus zonas. A y C cambian de grupo.

3 · Se repite hasta converger



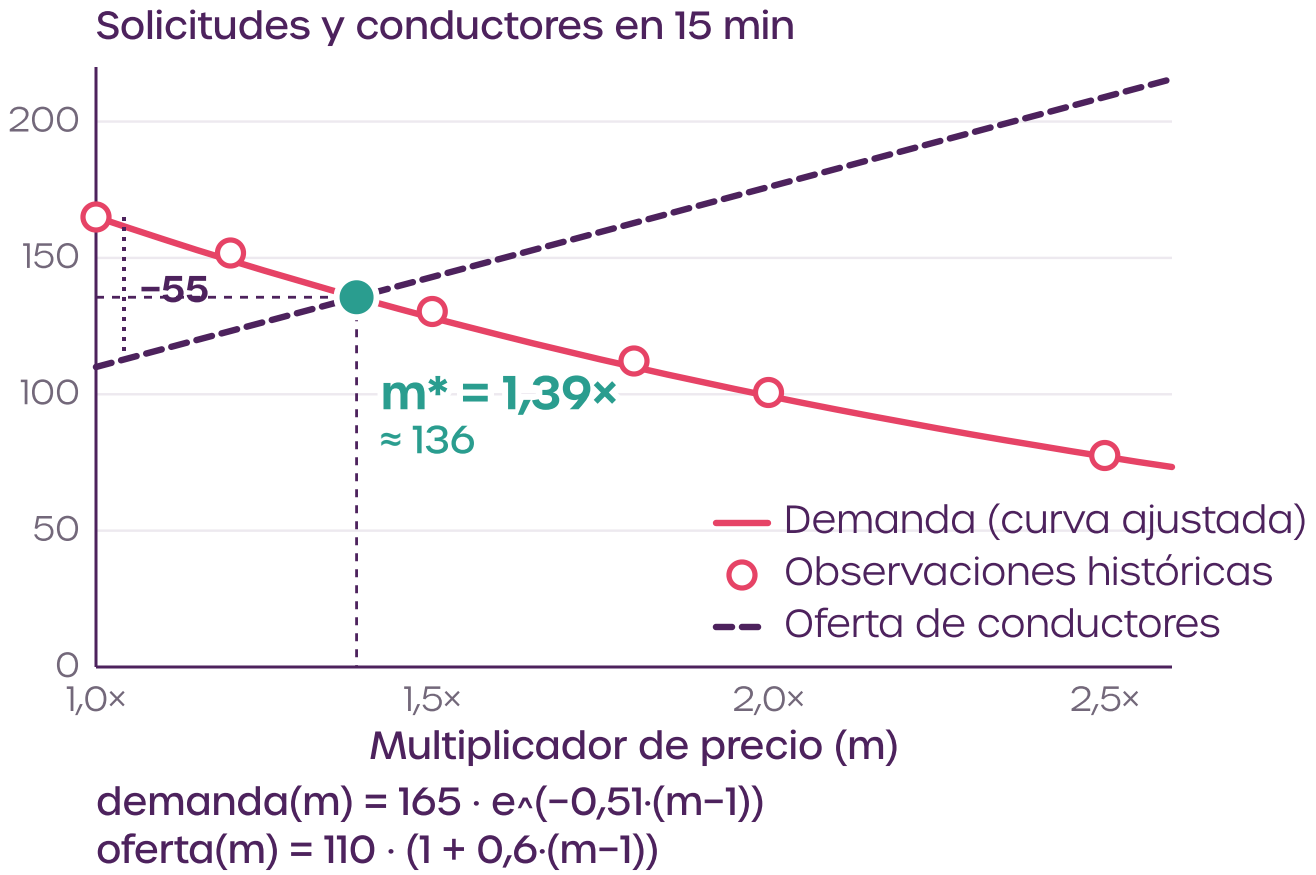
Ninguna zona cambia: quedan 3 grupos. Centro (C) es una zona de negocios.

Datos sintéticos de nueve zonas (A–I). Cada zona se describe con dos números; los grupos nacen de los datos, sin etiquetas previas. Zonas del mismo grupo comparten patrón: se pronostican juntas y se anticipa dónde enviar conductores.

Regresión: demanda frente al precio

Algoritmo 3/4 Sensibilidad de la demanda al precio y precio de equilibrio

1. **Reunir pares (precio, demanda).** Seis niveles históricos: a 1,0× la demanda es el 100 %; a 1,5×, el 79 %; a 2,5×, el 47 %.
2. **Elegir la forma.** La demanda cae de forma exponencial: `demanda(m) = base · e^(−β·(m−1))`.
3. **Ajustar por mínimos cuadrados** sobre ln(demanda): **β = 0,51**, R^2 = 0,999. Cada +1,0× quita ≈40 % de la demanda.
4. **Buscar el equilibrio.** Demanda(m) = oferta(m): 165·e^(−0,51(m−1)) = 110·(1 + 0,6(m−1)) → **m* = 1,39×**, unos 136 viajes.



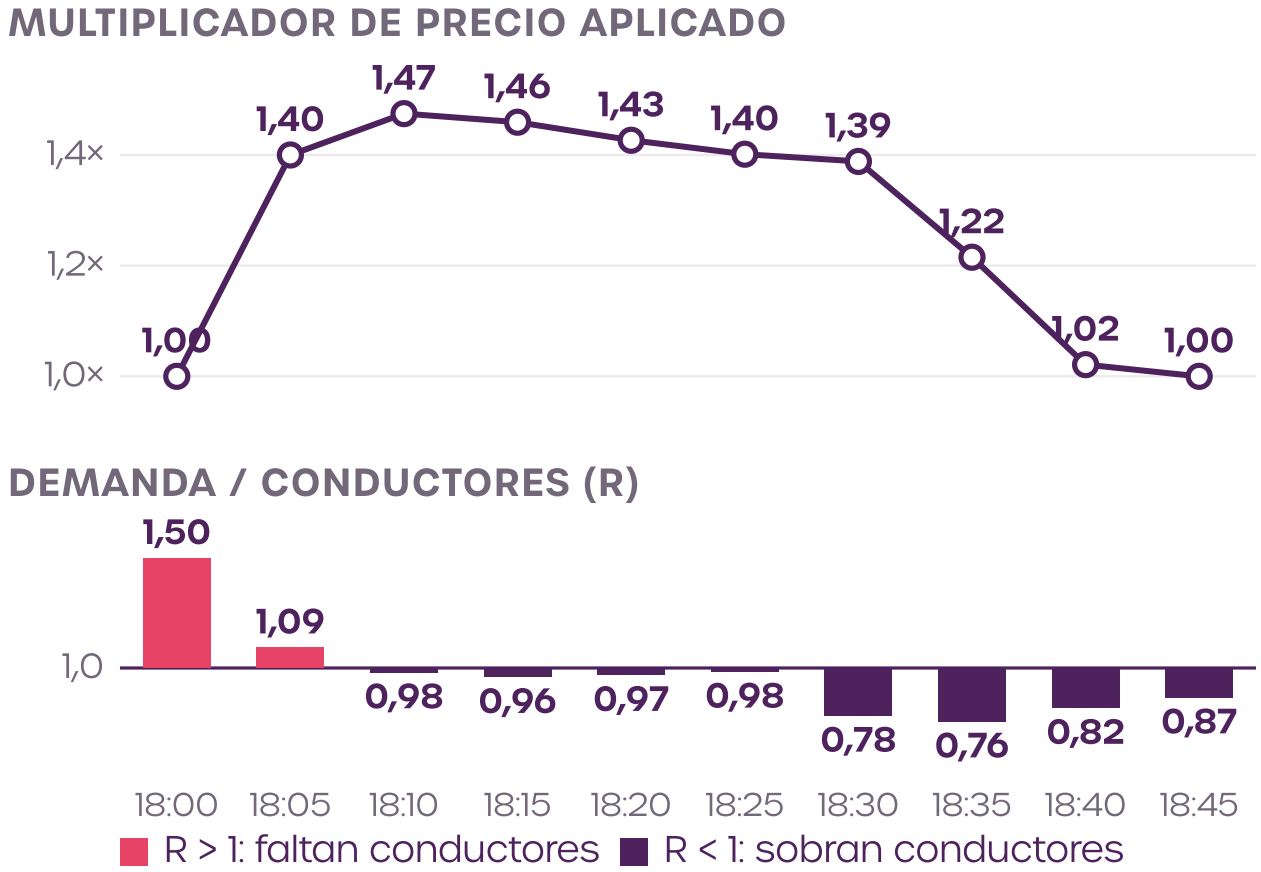
demanda(m) = 165 · e^(−0,51·(m−1))
oferta(m) = 110 · (1 + 0,6·(m−1))

Datos sintéticos. La respuesta de la oferta (+60 % de conductores por cada +1,0×) es una hipótesis didáctica; en la práctica también se estima con datos.

Bucle de precio: ajustar cada 5 minutos

Algoritmo 4/4 Control con realimentación: el precio se corrige cada 5 minutos hasta equilibrar

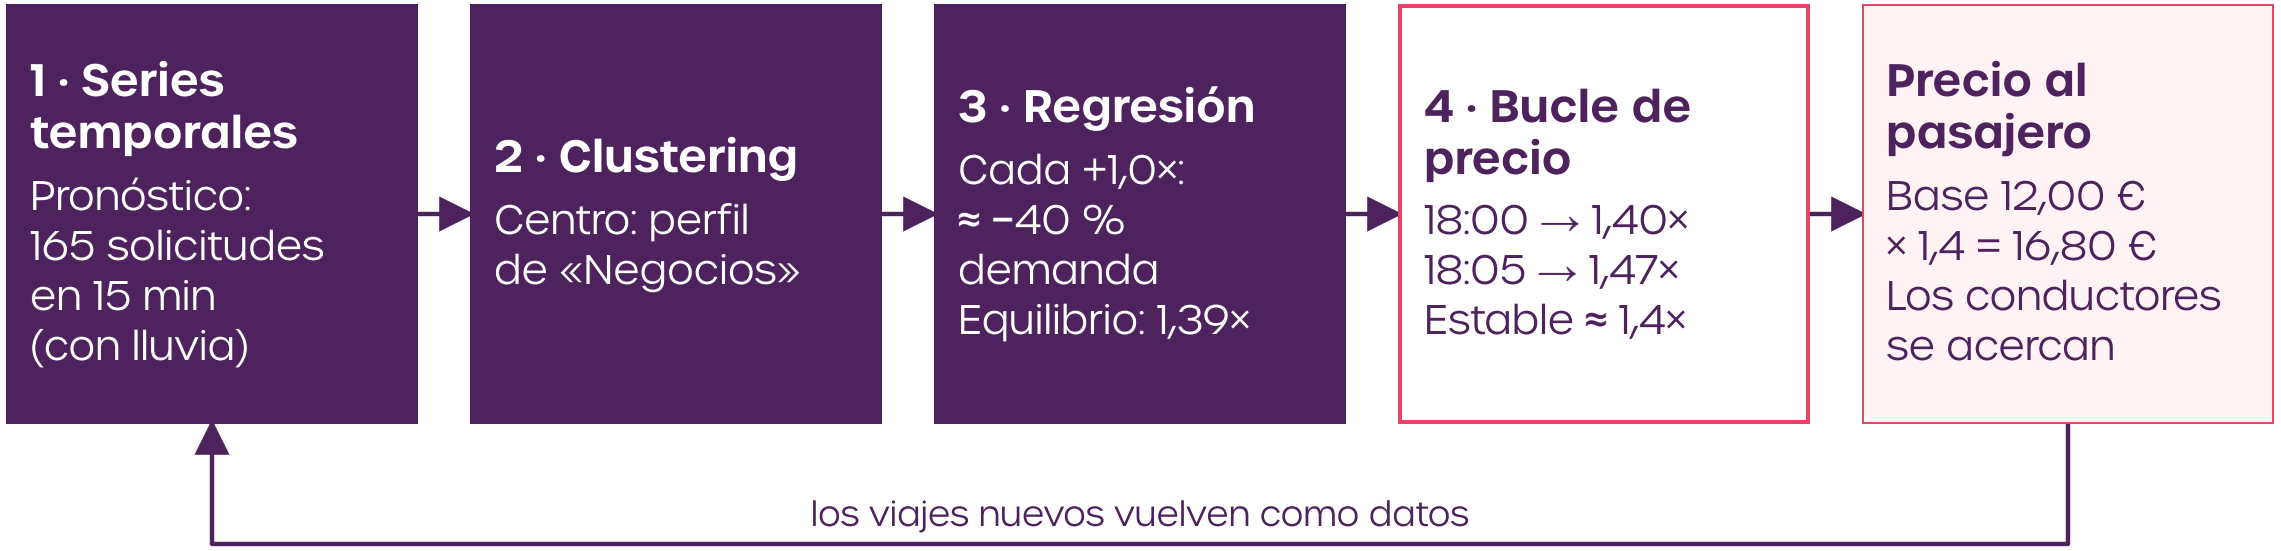
1. **Medir.** Cada 5 min: R = demanda / conductores. A las 18:00, 165 / 110 = **1,50**.
2. **Corregir el precio.** $m \leftarrow m + 0{,}8 \cdot (R - 1)$, entre 1,0× y 3,0×: 1,00 + 0,8·0,50 = **1,40×** desde las 18:05.
3. **Dejar reaccionar.** Algunos pasajeros esperan y los conductores se acercan. A las 18:05, R = 1,09 → **1,47×**.
4. **Repetir y relajar.** Se estabiliza en ≈1,4×. Al caer la demanda (R < 1) el precio baja a 1,00× a las 18:45.



Simulación sintética con la demanda y la oferta del ejemplo. Cuando la demanda baja a las 18:30, el multiplicador vuelve solo a 1,00×.

Un viernes a las 18:00, de principio a fin

Centro, viernes 18:00, con lluvia: los cuatro algoritmos encadenados con las cifras del ejemplo



Cifras sintéticas y coherentes con las diapositivas anteriores: no son datos de Uber.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Retos y ética

Privacidad

Ubicaciones en tiempo real de pasajeros y conductores: exigen consentimiento, seguridad y gobierno del dato.

Percepción de justicia

Subir precios en emergencias o con mal tiempo se vive como abusivo, aunque equilibre el sistema.

Escala técnica

Flujos de millones de usuarios con baja latencia; los modelos se vigilan y se reentrenan.

Ideas para mitigar

Tope al multiplicador, precio visible antes de confirmar y avisos claros al usuario.

Conclusiones y próximos pasos

Conclusiones

Regresión estima un número, pero no garantiza un precio de venta.

Clustering descubre grupos sin etiquetas, y los grupos hay que validarlos.

Los sistemas reales combinan técnicas: Uber encadena series temporales, clustering, regresión y un bucle de control.

Próximos pasos

Notebooks de Jupyter para simular cada caso paso a paso.

Una aplicación web que simule el comportamiento del precio dinámico de Uber.

Probar las ideas con datos propios y medir el impacto en una decisión concreta.

Fuentes

idealista/data Análisis de regresión

idealista/data · 17 feb 2021

Spotify Clustering

Spotify Engineering · 5 dic 2023

Uber Precio dinámico y demanda

Shuaib Ullattil, Medium · 5 feb 2026

Fuentes divulgativas o de las propias empresas. Los datos de las demostraciones y del ejemplo de Uber son sintéticos. Consultadas del 19 de octubre al 10 de noviembre de 2026.

Gracias

www.inno-it.es

Andrés Herencia
linkedin.com/in/andres-herencia

Prueba los simuladores
Uber · idealista, desde el móvil

Innoit