Machine learning
en empresas reales

Predecir, agrupar y combinar: de idealista y Spotify al simulador de Uber

InnoIT

Innoit

Índice

01. Objetivos

02. Predicción: idealista

03. Clasificación y agrupamiento: Spotify

04. Juntamos todo: simulador de Uber

05. Conclusiones y próximos pasos

Tres casos reales de menos a más integrado. Las cifras de las demostraciones son sintéticas.

Objetivos

Qué vamos a aprender

Diferenciar **predecir un valor** (regresión) de **descubrir grupos** (clustering) y entender para qué sirve cada tarea.

Ver cómo lo hacen empresas reales: idealista valora inmuebles y Spotify segmenta usuarios.

Ver cómo **se combinan varias técnicas** en un solo sistema: el precio dinámico de Uber.

Qué te llevas

Una forma de leer cualquier caso de uso: **datos** → **modelo** → **decisión**.

Un ejemplo numérico de cada técnica, para entender cómo funciona por dentro.

Los límites de cada enfoque: qué datos necesita, cómo se valida y qué puede salir mal.

01

Predicción: idealista

Primera tarea: estimar un número a partir de las características de una observación

Análisis de regresión

idealista/data (España)

Servicio comercial de valoración automática

Concepto

Estimar un número continuo a partir de variables explicativas.

Caso de uso real

idealista/data combina comparables y ML hedónico para estimar el valor de los inmuebles a partir de su ubicación y sus atributos.

Ventaja

Produce estimaciones coherentes en grandes carteras de inmuebles.

Limitación

La falta de atributos y los cambios del mercado reducen la precisión. Las estimaciones difieren de los precios de venta reales.

La empresa revela el enfoque de valoración, pero no el estimador exacto.

La regresión estima un número a partir de las características de una observación.

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data



Fuente: idealista/data e idealista labs

Innoit

idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

El inmueble objeto se convierte en un vector de variables

El piso de Ana

Zona B · mercado ficticio

Superficie	80 m²	Dormitorios	2
Reformado	Sí	Ascensor	Sí

↓

$$x = [80, 2, 1, 0, 1, 1]$$

superficie, dorm., zona B, zona C, reformado, ascensor

La zona A es la referencia. Las zonas B y C usan indicadores 0/1 independientes.

Demo calculada · viviendas y precios sintéticos

1 / 5

Detalles técnicos

La vivienda de Ana que hay que valorar

Ana quiere estimar el precio de su piso. Cambia sus atributos para seguir la misma vivienda en cada paso.

Superficie — 80 m²

Dormitorios — 2

Zona ficticia — Zona B

Reformado — ☑

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 **Viviendas similares** | 3 Regresión | 4 Estimación | 5 Explicabilidad

Evidencia comparable del conjunto de entrenamiento

Solo Zona B · 80 m² · 2 dormitorios · seis coincidencias más cercanas

Inmueble	Superficie	Dorm.	Reformado	Ascensor	Precio de referencia
P425	85 m²	2	Sí	Sí	302.180 €
P276	91 m²	2	Sí	Sí	339.450 €
P201	80 m²	3	Sí	Sí	311.444 €
P393	80 m²	1	Sí	Sí	283.257 €
P275	85 m²	3	Sí	Sí	311.032 €
P216	71 m²	2	No	Sí	278.683 €

Media de estos seis precios **304.341 €**

Todos los inmuebles y precios son sintéticos. Las reglas de coincidencia son didácticas.

Demo calculada · viviendas y precios sintéticos

2 / 5

Detalles técnicos

Seis inmuebles de referencia similares

Busca seis viviendas como la de Ana: la misma zona, tamaño y dormitorios similares. Sus precios de referencia ofrecen una primera comparación.

¿Qué hace que haya coincidencia?

Misma zona, superficie y dormitorios similares, además de reforma y ascensor.

En esta comparación solo entran inmuebles de entrenamiento.

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | **3 Regresión** | 4 Estimación | 5 Explicabilidad

Primero se aprende, después se predice

ENTRENAMIENTO · se calcula una vez

360 ejemplos conocidos
Variables X + precio y

→

Regresión lineal
Aprende los pesos β

→

Ajuste MCO
$\min \Sigma(y - \hat{y})^2$

PREDICCIÓN · se actualiza con tus datos

Variables de esta vivienda
80 m² · Zona B

→

Modelo ajustado fijo
$\hat{y} = \beta_0 + \Sigma \beta_j x_j$

→

Precio del modelo
305.790 €

3 / 5

Detalles técnicos

La regresión aprende una relación numérica

Aprende de viviendas conocidas y luego predice el precio de Ana a partir de los atributos de su piso.

¿Qué aprende?

Por ejemplo, +10 m² suman 19.802 € a la predicción de este modelo, manteniendo fijas las demás entradas.

Es una asociación ajustada sobre datos sintéticos.

Demo calculada · viviendas y precios sintéticos

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

Una combinación transparente para esta demo

Media de viviendas similares

304.341 €

50 % de la estimación de la demo

+

Estimación de la regresión

305.790 €

50 % de la estimación de la demo

Precio estimado ilustrativo

305.000 €

Redondeado a los 1.000 € más cercanos

La combinación 50/50 es una elección didáctica. La ponderación de producción de idealista no es pública.

4 / 5

Detalles técnicos

Una estimación continua del precio

Para la vivienda de Ana, combina la media de viviendas similares con la predicción de la regresión. Esta demo usa un promedio ilustrativo 50/50.

Error absoluto medio en datos reservados

10.577 € en 120 viviendas sintéticas.

Una evaluación de demostración, no la precisión de idealista ni un intervalo de predicción individual.

Demo calculada · viviendas y precios sintéticos

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

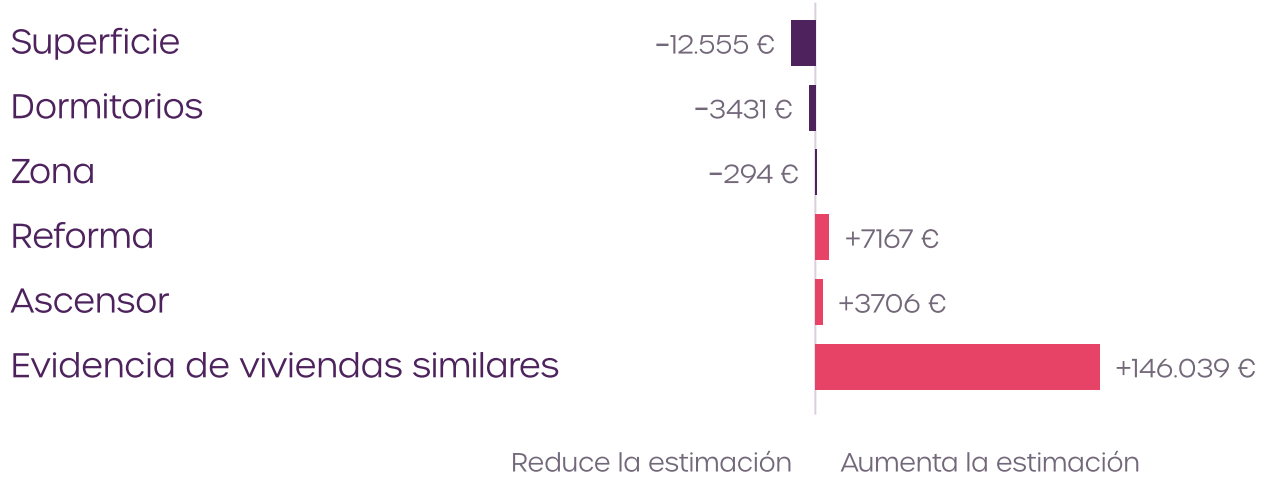
idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 **Explicabilidad**

Un desglose aritmético de esta estimación



Línea base 316.604 € + ajustes **= 305.065 €**

Aritmética exacta de la demo, antes de redondear. La línea base es la predicción media del modelo de entrenamiento

5 / 5

Detalles técnicos

¿Qué problema resuelve esto?

Para Ana, explica cómo afectan el tamaño, la reforma y el ascensor a esta estimación.

Este piso

80 m² frente a una media de entrenamiento de 93 m²: la superficie aporta −12.555 €.

Reforma y ascensor

Reformado: +7167 €. Con ascensor: +3706 €.

Demo calculada · viviendas y precios sintéticos

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Fuente: idealista/data e idealista labs

Innoit

02

Clasificación y agrupamiento: Spotify

Segunda tarea: descubrir grupos cuando no hay etiquetas previas

Innoit

Clustering

Spotify (Suecia)

Método documentado de investigación de usuarios

Concepto

Descubrir grupos con comportamiento similar sin etiquetas de grupo predefinidas.

Ventaja

Encuentra segmentos inesperados y apoya la investigación dirigida de usuarios.

Caso de uso real

Spotify combina UMAP con HDBSCAN recursivo para descubrir segmentos más finos de usuarios.

Limitación

La elección de variables condiciona los grupos. Los clusters estables siguen necesitando validación humana.

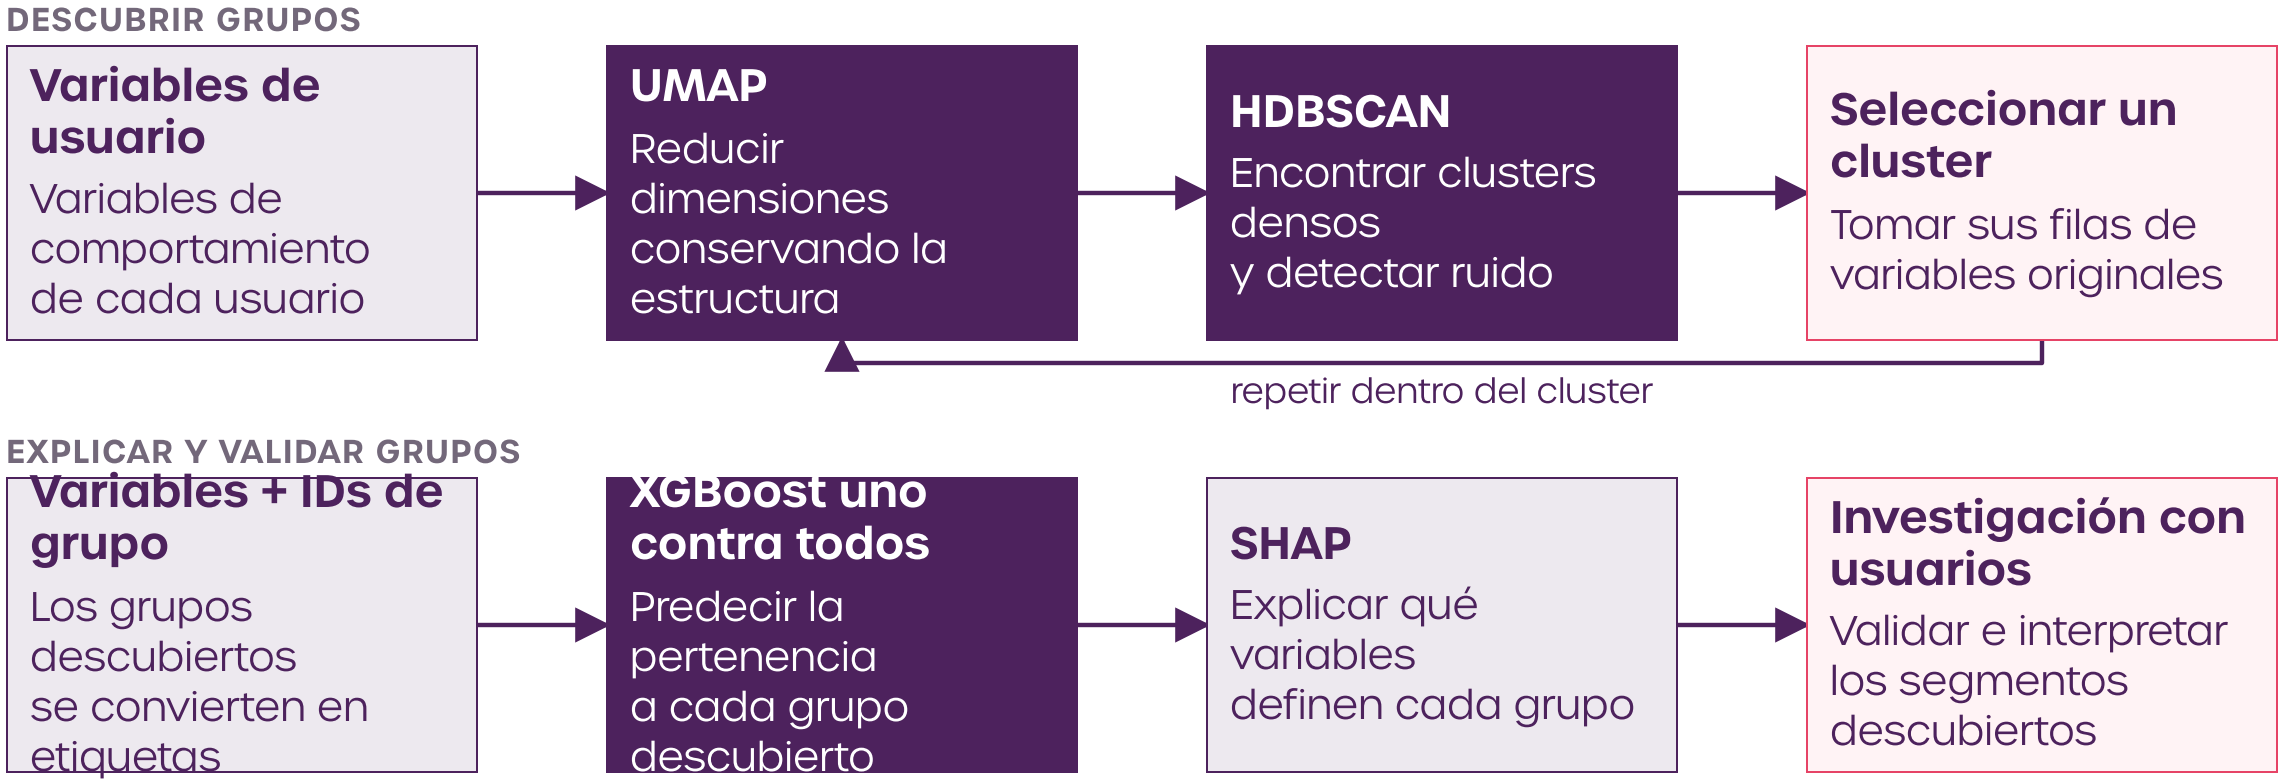
Spotify usa XGBoost y SHAP para explicar los segmentos resultantes.

El clustering descubre grupos que los investigadores pueden analizar después.

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado



Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Las personas detrás del caso de uso

Personas	Ana y Luis escuchan a AC/DC y a Metallica. Marta escucha a Taylor Swift.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de rock y metal como la señal principal del grupo.
Uso posible	Sugerir Iron Maiden a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

1 / 9

Detalles técnicos

Un ejemplo concreto de escucha

Ana y Luis comparten artistas. ¿Podemos descubrir su grupo y explicar qué lo hace diferente?

Sigue a las mismas personas

Cada paso siguiente explica qué supondría el algoritmo para Ana, Luis y Marta.

Historia ilustrativa. Los gráficos calculados usan variables de comportamiento sintéticas, sin recuentos de artistas ni usuarios con nombre.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Variables originales

$X \in \mathbb{R}^{684 \times 6}$

Observaciones sin etiquetar

Oyente	Minutos	Sesiones	Saltos	Descubrimiento	Listas	Noche
L001	222	11.4	10%	17%	52%	72%
L002	124	6.6	46%	64%	41%	29%
L003	32	1.8	28%	27%	75%	8%
L004	127	6.6	42%	66%	32%	36%

Variables numéricas, sin etiquetas de segmento predefinidas

684 filas × 6 variables

StandardScaler $z_{ij} = (x_{ij} - \mu_j) / \sigma_j$ Se ajusta una vez con toda la población de la demo

Demo calculada · oyentes sintéticos

2 / 9

Detalles técnicos

Un vector de variables original para cada oyente

La escucha de Ana se convierte en una fila numérica. Aquí calculamos seis variables de comportamiento. Los recuentos de artistas serían entradas adicionales.

Oyente L001

Minutos	222	Sesiones	11.4
Saltos	10%	Descubrimiento	17%
Listas	52%	Noche	72%

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

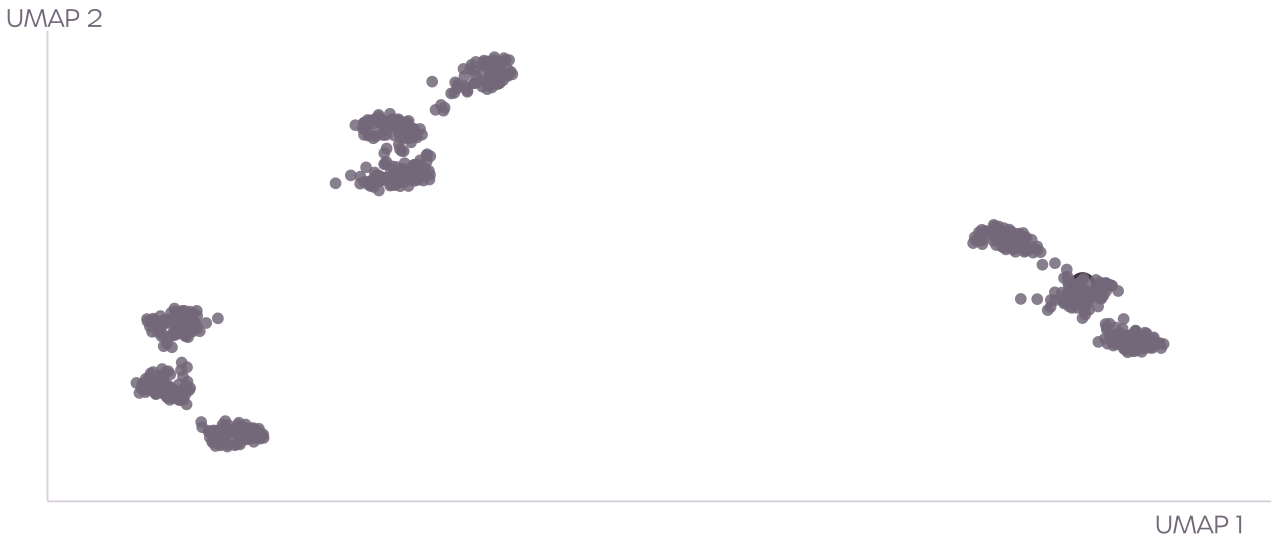
Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Coordenadas UMAP calculadas

3 clusters · 0 ruido · 684 oyentes



Solo es una transición visual. El movimiento de los puntos no reproduce las iteraciones del optimizador.

3 / 9

Detalles técnicos

UMAP hace visibles los vecindarios

Con variables de artistas adecuadas, Ana y Luis podrían aparecer cerca porque comparten artistas. UMAP muestra similitud, no una etiqueta de género.

684 × 6 → 684 × 2

Fiabilidad (trustworthiness) con 10 vecinos: 0.975

Diagnóstico de vecindad local, no validez del segmento.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Coordenadas UMAP calculadas

3 clusters · 0 ruido · 684 oyentes



C1 221 · C2 241 · C3 222 · Ruido 0

Demo calculada · oyentes sintéticos

4 / 9

Detalles técnicos

HDBSCAN descubre grupos basados en densidad

Un grupo denso podría contener a Ana y a Luis, mientras que Marta queda en otro sitio. Los colores muestran los grupos descubiertos. Nuestro gráfico usa datos de comportamiento sintéticos.

Inspeccionar grupo: C1 · 221 oyentes

32.3% de este nodo

Ruido: 0 / 684

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

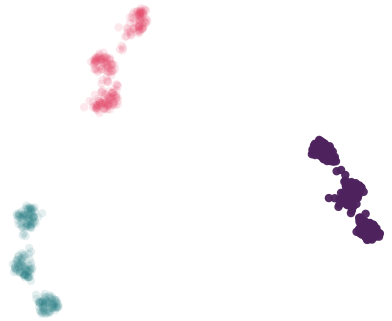
Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

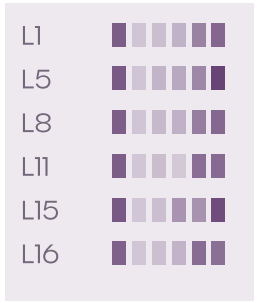
La recursión usa las variables originales dentro de un cluster seleccionado

Un nuevo ajuste, no un gráfico ampliado

1. Seleccionar C1

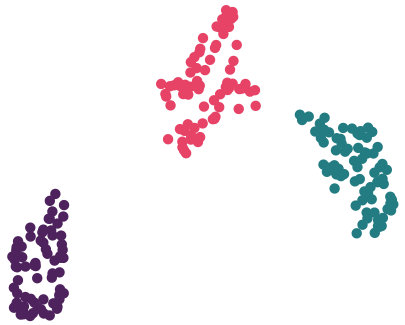


2. Filas X originales



221 × 6 variables

3. Reajustar ambos modelos



3 grupos · 0 ruido

Las nuevas coordenadas proceden de un nuevo ajuste de UMAP sobre las filas originales seleccionadas.

5 / 9

Detalles técnicos

La recursión parte de las filas de variables originales

Analiza de nuevo el grupo de Ana con sus filas originales. Esto podría revelar hábitos más finos dentro de su grupo más amplio.

Cluster padre: C1 · 221 filas

Inspeccionar ajuste hijo de C1

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Jerarquía de clusters calculada



El ruido queda sin asignar. Los recuentos de los hijos pueden sumar menos que el padre.

6 / 9

Detalles técnicos

La jerarquía registra cada paso de descubrimiento

El grupo amplio de Ana podría dividirse en subgrupos. El árbol registra qué usuarios entran en cada nuevo ajuste. Haz clic en una rama para inspeccionar su población calculada.

4 ajustes calculados

Cada hijo tiene sus propias coordenadas UMAP y asignaciones HDBSCAN.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Spotify

1 Ejemplo | 2 Variables | 3 UMAP | 4 HDBSCAN | 5 Re-embedding | 6 Jerarquía | 7 XGBoost | 8 SHAP | 9 Explicabilidad

Entrenamiento uno contra el resto

Variables originales X
684 filas × 6

Etiquetas descubiertas
y = 1 para C1
y = 0 en otro caso

XGBoost binario
90 árboles · profund
75 % de filas de ent

Fidelidad en reservad
F1 0.991
AUC 1.000

Un modelo por cluster. Se excluyen las coordenadas del embedd

7 / 9

Detalles técnicos

Un modelo supervisado aprende la pertenencia descubierta

XGBoost aprende a predecir el grupo de Ana frente al resto, usando las variables originales y las etiquetas descubiertas.

Modelo de pertenencia: C1 contra el resto

513 entrenamiento / 171 reservados

La partición prueba la reproducción de etiquetas, no el descubrimiento de clusters con usuarios nuevos.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Contribuciones TreeSHAP calculadas

Este oyente | Mean |SHAP| — Contribución con signo al log-odds de pertenencia



Base -0.80 + Σ SHAP 6.55 = log-odds 5.75

P(C1) = 99.7%

Demo calculada · oyentes sintéticos

8 / 9

Detalles técnicos

SHAP explica el predictor de pertenencia

SHAP explica la puntuación de grupo de un oyente. La escucha indie podría importar con variables de artistas. Estas barras explican el comportamiento.

Explicar la pertenencia a: C1

Oyente: L001 · reservado

Oyente reservado. Las puntuaciones binarias independientes no tienen por qué sumar 1.

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Por qué hace falta interpretar

Personas	Ana y Luis escuchan a AC/DC y a Metallica. Marta escucha a Taylor Swift.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de rock y metal como la señal principal del grupo.
Uso posible	Sugerir Iron Maiden a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

9 / 9

Detalles técnicos

Qué significan los resultados

Grupo C1 Oyente L001

En todos los oyentes

Minutos / día y Escucha nocturna tienen los mayores efectos medios.

Este oyente

Minutos / día = 222 es el empuje más fuerte hacia C1.

Las explicaciones del modelo no prueban causas ni validan segmentos.

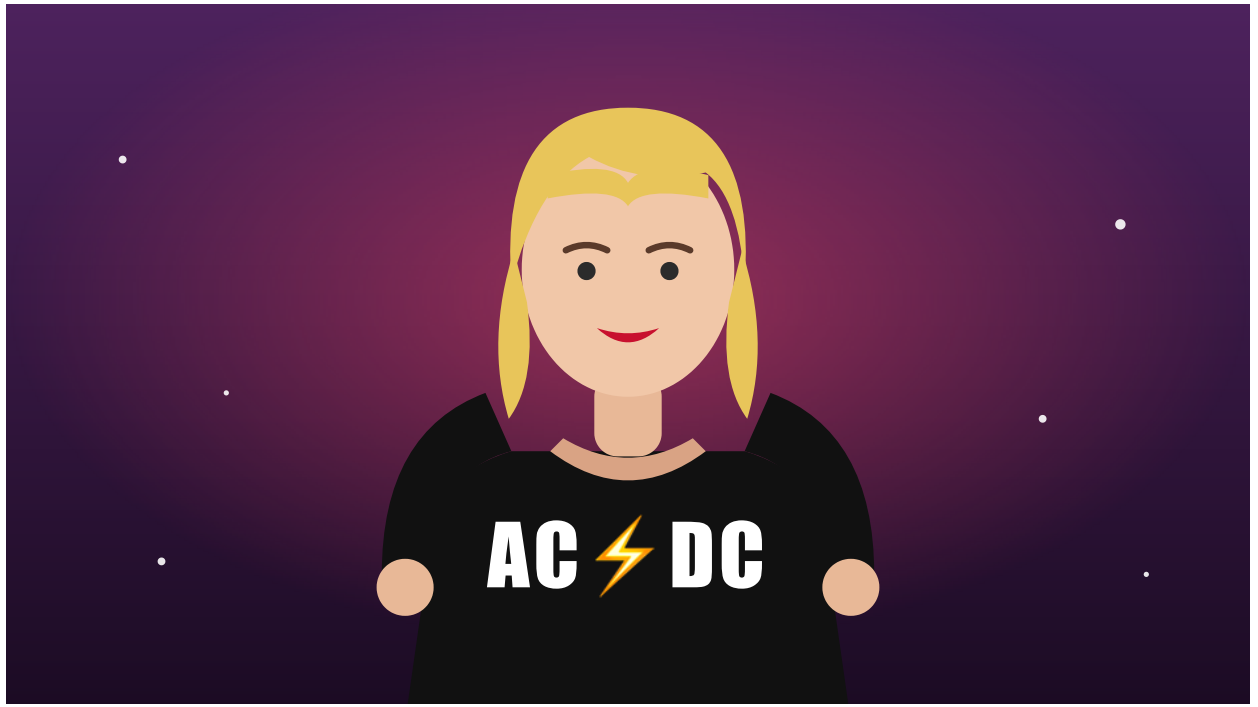
Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Cuando el grupo se equivoca de grupo

Marta escuchaba a Taylor Swift, pero si un día se pone la camiseta de AC/DC...
¿sigue en su grupo?



03

Juntamos todo: simulador de Uber

Un sistema real no usa una técnica, sino varias encadenadas

Innoit

De dos casos a un sistema completo

Lo que ya hemos visto

Regresión (idealista): estimar un valor continuo a partir de atributos.

Clustering (Spotify): agrupar observaciones parecidas sin etiquetas.

Lo que añade Uber

Series temporales: pronosticar la demanda de los próximos minutos.

Un bucle de control: corregir el precio cada pocos minutos hasta equilibrar oferta y demanda.

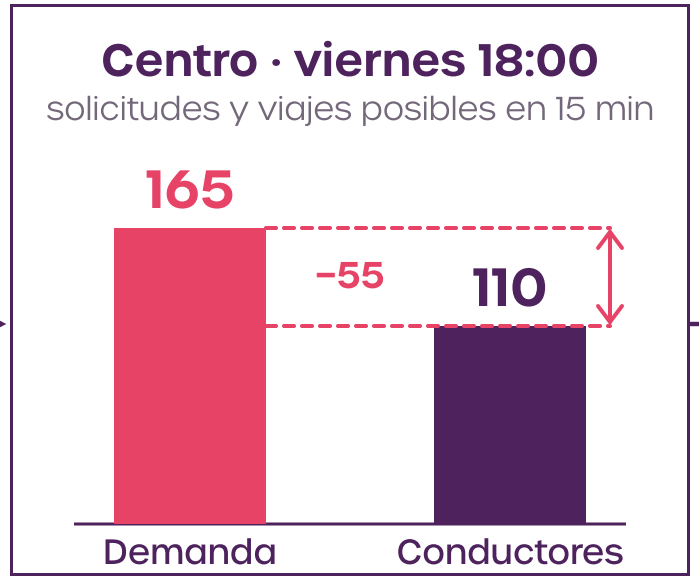
Uber: el problema

En cada zona y cada pocos minutos, la demanda y los conductores casi nunca coinciden

QUÉ MUEVE LA DEMANDA

- Hora y día
- Clima
- Eventos
- Tráfico

LA ZONA AHORA



SI NADIE ACTÚA

Demanda mayor que oferta

Esperas largas, más cancelaciones y usuarios menos satisfechos

LO QUE OCURRE EN CENTRO

Oferta mayor que demanda

Menos viajes por conductor, menos ingresos y desconexión

EN OTRA ZONA O A OTRA HORA

Reto: equilibrar oferta y demanda en minutos, zona a zona

El reto no es solo predecir: es equilibrar oferta y demanda antes de que el desajuste perjudique a todos.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Precio dinámico y demanda

Uber (presencia global)

Caso de estudio divulgativo; los modelos reales de Uber son propietarios

Concepto

Predecir la demanda por zona y ajustar el precio en tiempo real.

Ventaja

Menos esperas y una oferta de conductores más estable.

Caso de uso real

Series temporales, clustering y regresión para fijar el precio dinámico.

Limitación

Las subidas bruscas se perciben como injustas y exigen datos sensibles.

El artículo no publica cifras ni arquitectura real: los números de esta presentación son sintéticos.

El precio es una señal que equilibra el sistema, no solo cobra más.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

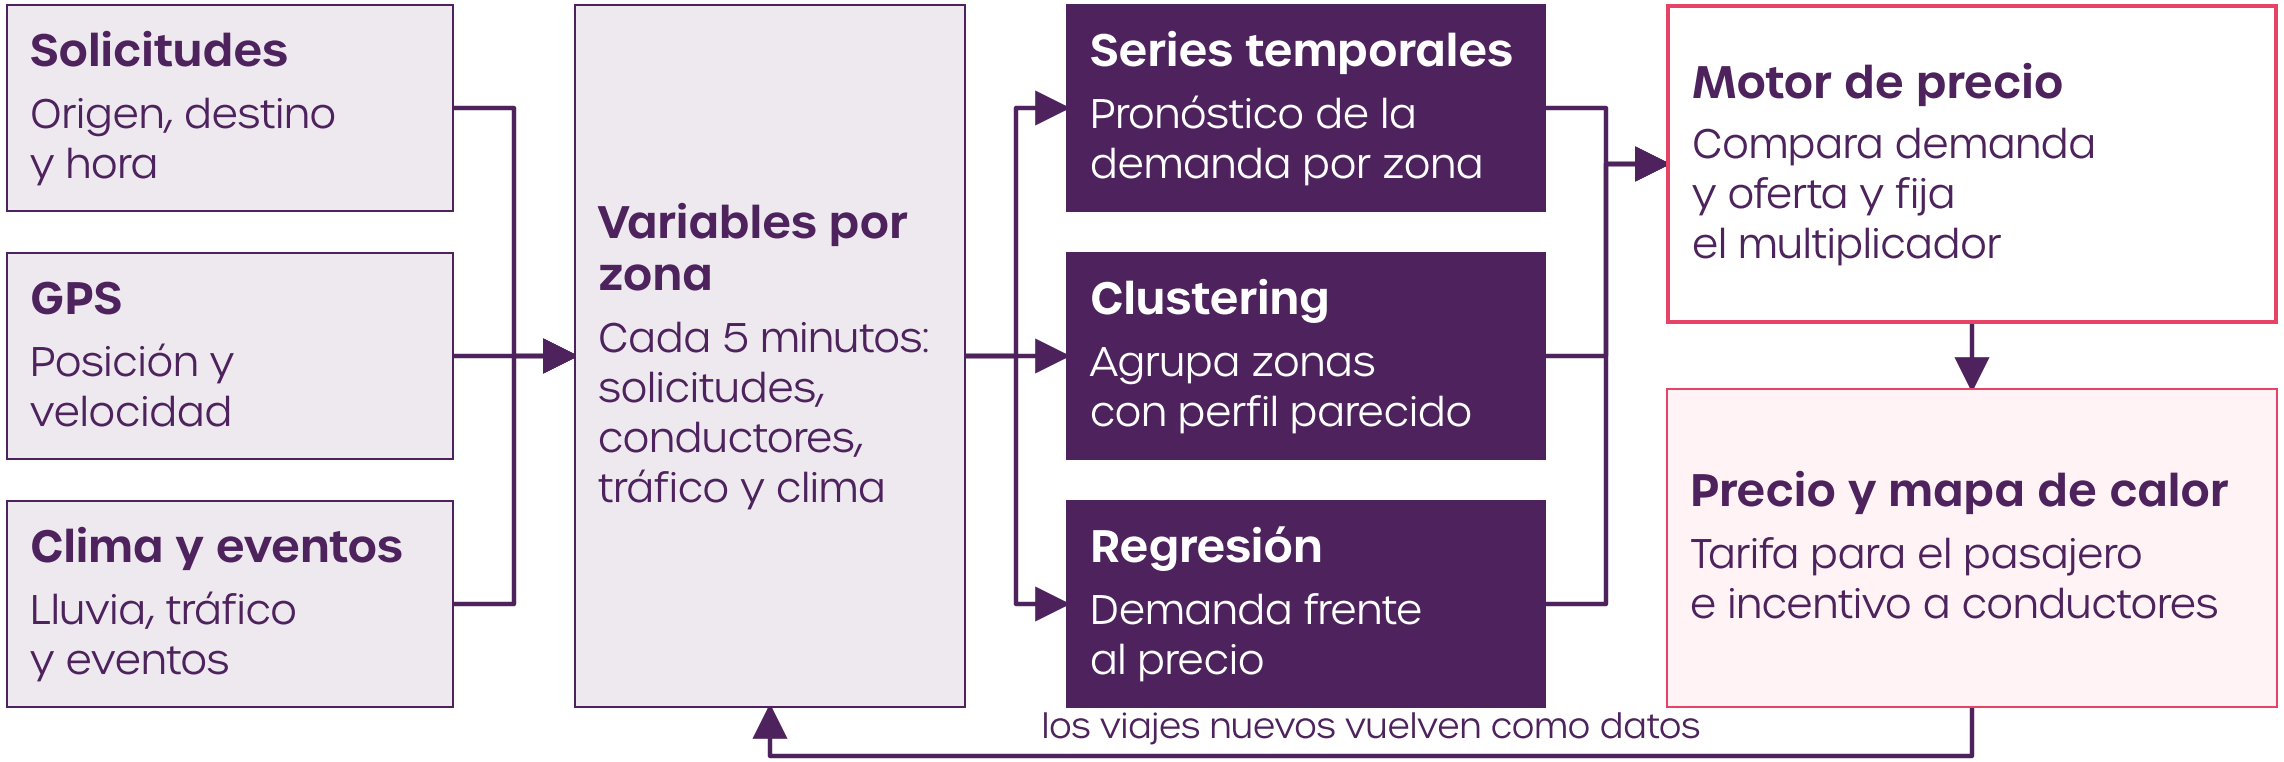
Los datos de partida

Fuente	Qué contiene	Para qué sirve
Solicitudes y viajes	Origen, destino, hora, duración, ruta, cancelaciones y pagos	Medir la demanda real y su histórico
GPS de móviles	Posición y velocidad de cada conductor, cada pocos segundos	Conocer la oferta y el tráfico en tiempo real
Contexto externo	Clima, cortes de carretera y eventos locales	Anticipar picos que el histórico no explica
Uso de la app	Valoraciones, cancelaciones y comentarios	Entender el comportamiento y la satisfacción

Volumen, variedad y velocidad: las tres «V» del Big Data. Fuente: Shuaib Ullattil, Medium (5 feb 2026).

Uber: del dato al precio

Del dato en bruto al precio que ve el pasajero, con un bucle de realimentación



Reconstrucción didáctica a partir de la descripción del artículo: la arquitectura real de Uber no es pública.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Algoritmos

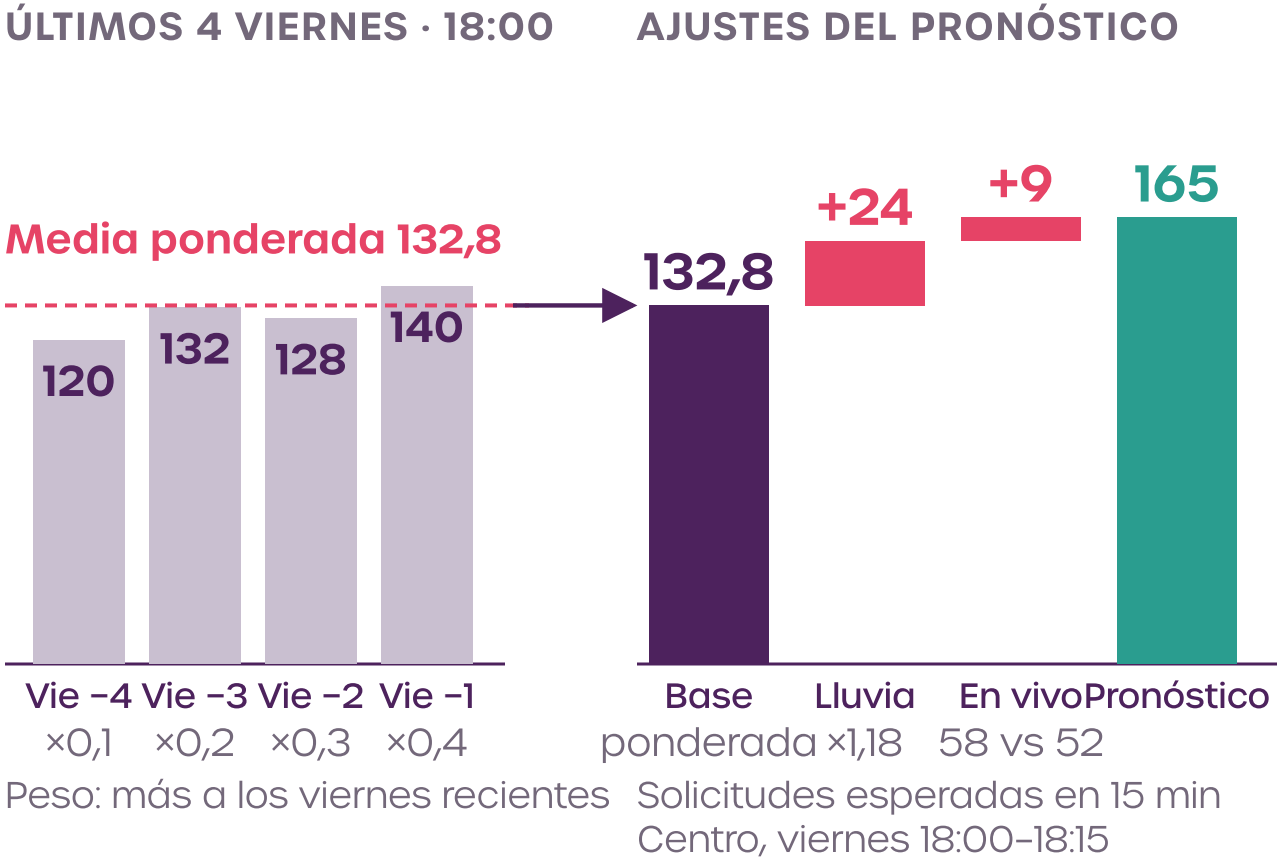
Cuatro piezas, paso a paso

Cada una con un ejemplo numérico sintético: Centro, viernes 18:00, con lluvia.

Series temporales: ¿cuántos viajes habrá?

Algoritmo 1/4 Pronóstico de la demanda de Centro entre las 18:00 y las 18:15

1. **Mirar el pasado.** Solicitudes a esa hora los últimos 4 viernes: 120, 132, 128 y 140.
2. **Ponderar.** Los viernes recientes pesan más: 0,1·120 + 0,2·132 + 0,3·128 + 0,4·140 = **132,8**.
3. **Ajustar por contexto.** Un modelo aprendió que la lluvia añade ≈18 % de demanda: 132,8 × 1,18 = **156,7**.
4. **Corregir en vivo.** En los primeros 5 min hay 58 solicitudes frente a 52 esperadas (+11 %). Se aplica la mitad: 156,7 × 1,055 = **165**.

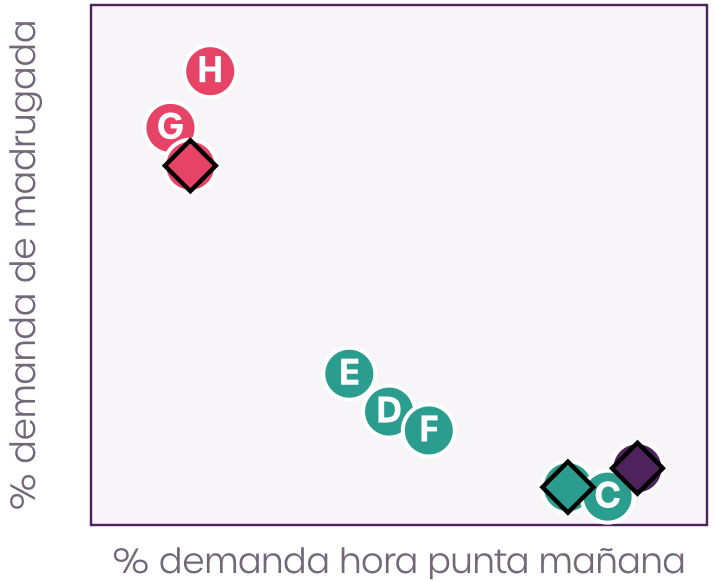


Datos sintéticos. Uber no publica sus modelos: aquí se usa una media ponderada estacional con ajustes, la forma más sencilla de una serie temporal.

Clustering: ¿qué tipo de zona es?

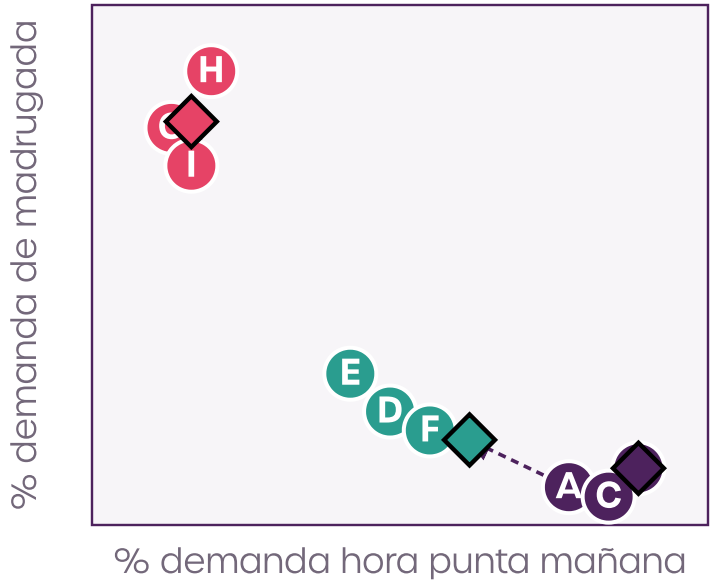
Algoritmo 2/4 k-means agrupa zonas por su perfil de demanda (k = 3)

1 · Centros iniciales



Dos centros caen en la misma zona de negocios. Cada zona pasa al centro más cercano.

2 · Mover y reasignar



Cada centro pasa a la media de sus zonas. A y C cambian de grupo.

3 · Se repite hasta converger



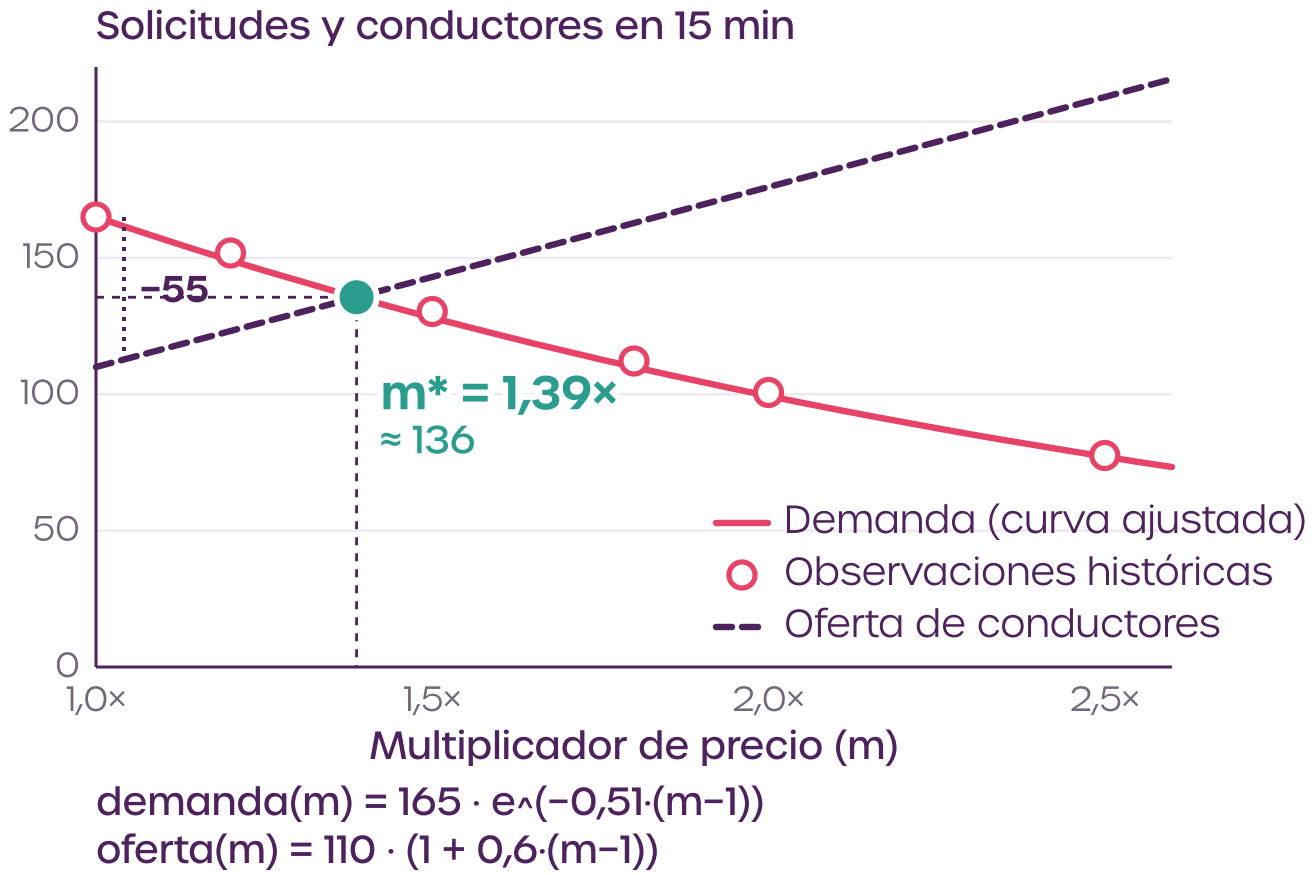
Ninguna zona cambia: quedan 3 grupos. Centro (C) es una zona de negocios.

Datos sintéticos de nueve zonas (A–I). Cada zona se describe con dos números; los grupos nacen de los datos, sin etiquetas previas. Zonas del mismo grupo comparten patrón: se pronostican juntas y se anticipa dónde enviar conductores.

Regresión: demanda frente al precio

Algoritmo 3/4 Sensibilidad de la demanda al precio y precio de equilibrio

1. **Reunir pares (precio, demanda).** Seis niveles históricos: a 1,0× la demanda es el 100 %; a 1,5×, el 79 %; a 2,5×, el 47 %.
2. **Elegir la forma.** La demanda cae de forma exponencial: `demanda(m) = base · e^(−β·(m−1))`.
3. **Ajustar por mínimos cuadrados** sobre ln(demanda): **β = 0,51**, R^2 = 0,999. Cada +1,0× quita ≈40 % de la demanda.
4. **Buscar el equilibrio.** Demanda(m) = oferta(m): 165·e^(−0,51(m−1)) = 110·(1 + 0,6(m−1)) → **m* = 1,39×**, unos 136 viajes.



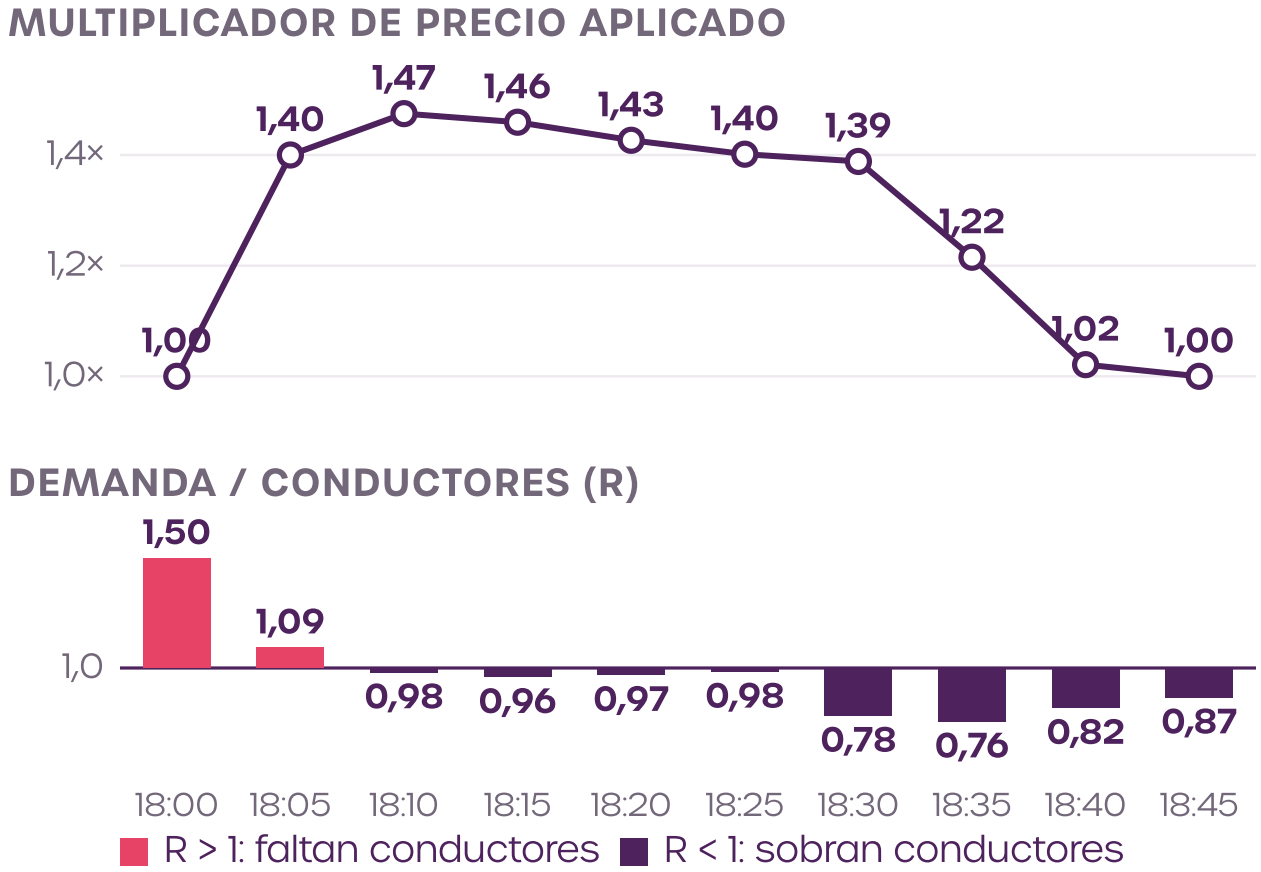
demanda(m) = 165 · e^(−0,51·(m−1))
oferta(m) = 110 · (1 + 0,6·(m−1))

Datos sintéticos. La respuesta de la oferta (+60 % de conductores por cada +1,0×) es una hipótesis didáctica; en la práctica también se estima con datos.

Bucle de precio: ajustar cada 5 minutos

Algoritmo 4/4 Control con realimentación: el precio se corrige cada 5 minutos hasta equilibrar

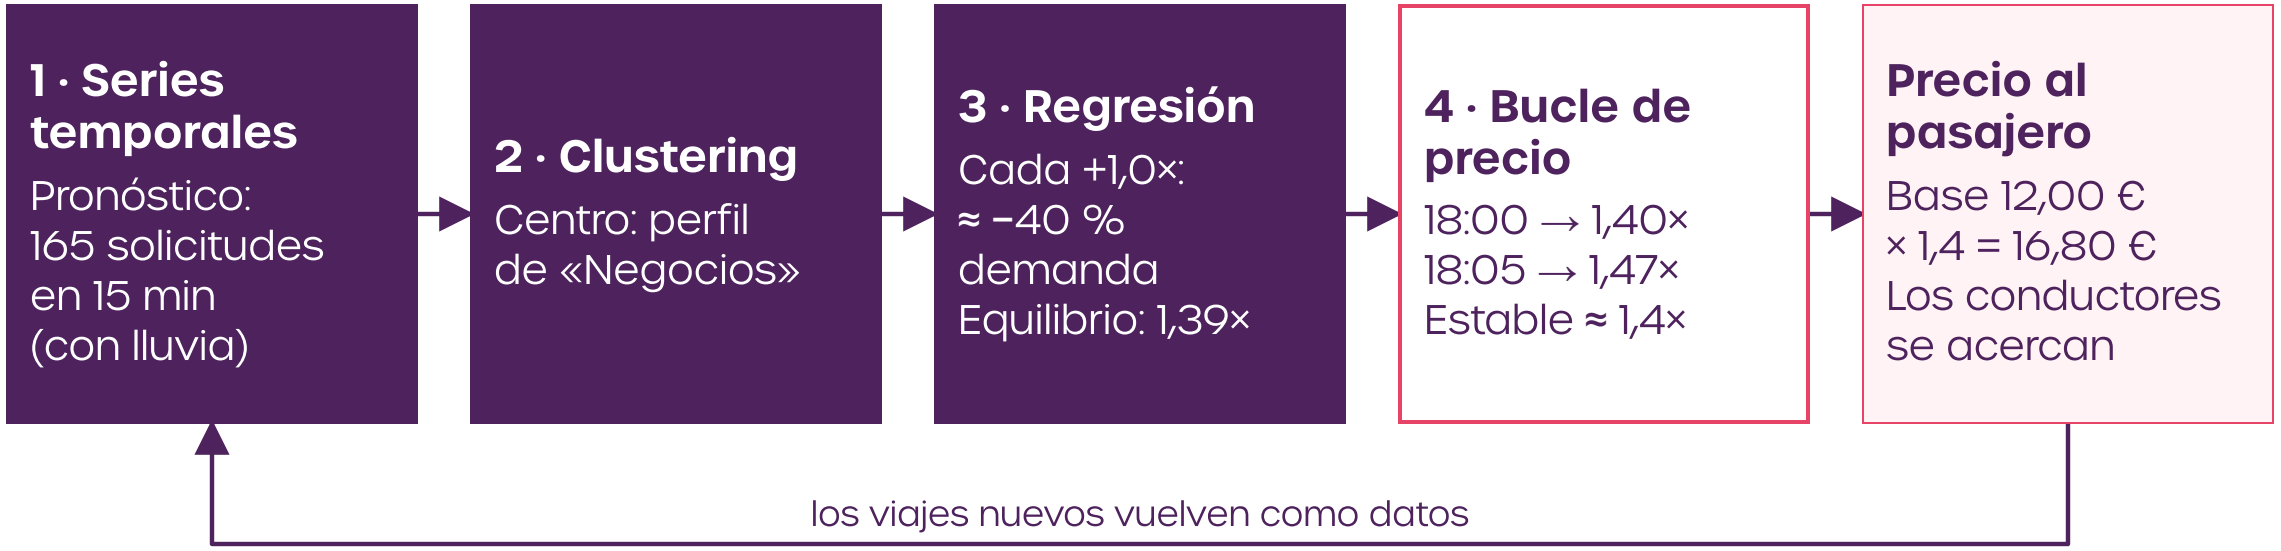
1. **Medir.** Cada 5 min: R = demanda / conductores. A las 18:00, 165 / 110 = **1,50**.
2. **Corregir el precio.** $m \leftarrow m + 0{,}8 \cdot (R - 1)$, entre 1,0× y 3,0×: 1,00 + 0,8·0,50 = **1,40×** desde las 18:05.
3. **Dejar reaccionar.** Algunos pasajeros esperan y los conductores se acercan. A las 18:05, R = 1,09 → **1,47×**.
4. **Repetir y relajar.** Se estabiliza en ≈1,4×. Al caer la demanda (R < 1) el precio baja a 1,00× a las 18:45.



Simulación sintética con la demanda y la oferta del ejemplo. Cuando la demanda baja a las 18:30, el multiplicador vuelve solo a 1,00×.

Un viernes a las 18:00, de principio a fin

Centro, viernes 18:00, con lluvia: los cuatro algoritmos encadenados con las cifras del ejemplo



Cifras sintéticas y coherentes con las diapositivas anteriores: no son datos de Uber.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Retos y ética

Privacidad

Ubicaciones en tiempo real de pasajeros y conductores: exigen consentimiento, seguridad y gobierno del dato.

Percepción de justicia

Subir precios en emergencias o con mal tiempo se vive como abusivo, aunque equilibre el sistema.

Escala técnica

Flujos de millones de usuarios con baja latencia; los modelos se vigilan y se reentrenan.

Ideas para mitigar

Tope al multiplicador, precio visible antes de confirmar y avisos claros al usuario.

Conclusiones y próximos pasos

Conclusiones

Regresión estima un número, pero no garantiza un precio de venta.

Clustering descubre grupos sin etiquetas, y los grupos hay que validarlos.

Los sistemas reales combinan técnicas: Uber encadena series temporales, clustering, regresión y un bucle de control.

Próximos pasos

Notebooks de Jupyter para simular cada caso paso a paso.

Una aplicación web que simule el comportamiento del precio dinámico de Uber.

Probar las ideas con datos propios y medir el impacto en una decisión concreta.

Fuentes

idealista/data Análisis de regresión

idealista/data · 17 feb 2021

Spotify Clustering

Spotify Engineering · 5 dic 2023

Uber Precio dinámico y demanda

Shuaib Ullattil, Medium · 5 feb 2026

Fuentes divulgativas o de las propias empresas. Los datos de las demostraciones y del ejemplo de Uber son sintéticos. Consultadas del 19 de octubre al 10 de noviembre de 2026.

Gracias

¿Qué decisión de tu empresa podría apoyarse en uno de estos tres enfoques?

www.inno-it.es

Andrés Herencia · AI Engineer en InnoIT
Diseño y construyo soluciones de IA y machine learning aplicadas a casos reales.
linkedin.com/in/andres-herencia

Innoit