Machine learning
en empresas reales

Predecir, agrupar y combinar: de idealista y Spotify al simulador de Uber

PONENTE

Andrés Herencia · AI Engineer en InnoIT

Diseño y construyo soluciones de IA y machine learning aplicadas a casos reales.

Innoit

Índice

01. Objetivos

02. Predicción: idealista

03. Clasificación y agrupamiento: Spotify

04. Juntamos todo: simulador de Uber

05. Conclusiones y próximos pasos

Tres casos reales de menos a más integrado. Las cifras de las demostraciones son sintéticas.

Objetivo de la presentación

La IA y el **machine learning** ya están en las aplicaciones que usamos cada día. Hoy veremos **qué hay detrás** y **cómo se implementa** cada caso de uso.

¿Cuánto vale este piso?

Buscas casa y el portal te da un precio estimado al instante.

¿Qué tipo de oyente eres?

La app de música agrupa a millones de usuarios por cómo escuchan.

¿Por qué hoy cuesta más?

Pides un coche con lluvia y la tarifa sube para atraer conductores.

Cada caso, con el mismo método: **Datos** → **Modelo** → **Decisión**

Tres casos de uso

idealista/data

01 **Regresión**

Predecir el valor de una vivienda

- Modelo hedónico y comparables
- Demo: valora un piso

Spotify®

02 **Clustering**

Agrupar oyentes sin etiquetas

- K-means y segmentos de usuarios
- Demo: explora los grupos

Uber

03 **Sistema completo**

Fijar el precio dinámico

- Demanda, zonas y precio
- Simulador web paso a paso

01

Predicción: idealista

Primera tarea: estimar un número a partir de las características de una observación

Innoit

Análisis de regresión

idealista/data (España)

Servicio comercial de valoración automática

Concepto

Estimar un número a partir de variables.

Caso de uso real

Comparables y ML hedónico para valorar inmuebles.

Ventaja

Valoraciones coherentes a gran escala.

Limitación

Pierde precisión si faltan datos o cambia el mercado.

La regresión estima un número a partir de las características de una observación.

Fuente: idealista/data e idealista labs

idealista: estimar el valor de un inmueble

Atributos y comparables alimentan la valoración automatizada

idealista/data

1 Ejemplo | 2 Viviendas similares | 3 Regresión | 4 Estimación | 5 Explicabilidad

El inmueble objeto se convierte en un vector de variables

El piso de Ana

Zona B · mercado ficticio

Superficie	80 m²	Dormitorios	2
Reformado	Sí	Ascensor	Sí

↓

$$x = [80, 2, 1, 0, 1, 1]$$

superficie, dorm., zona B, zona C, reformado, ascensor

La zona A es la referencia. Las zonas B y C usan indicadores 0/1 independientes.

1 / 5

Detalles técnicos

La vivienda de Ana que hay que valorar

Ana quiere estimar el precio de su piso. Cambia sus atributos para seguir la misma vivienda en cada paso.

Superficie — 80 m²

Dormitorios — 2

Zona ficticia — Zona B

Reformado — ☑

← Atrás | Siguiente → | Reproducir | Reiniciar

Editar vivienda | 80 m² · 2 dorm. · Zona B | Abrir explorador ↗

Demo calculada · viviendas y precios sintéticos

Fuente: idealista/data e idealista labs

← / → pasos · línea base didáctica · sin datos ni modelo propietario de idealista

Innoit

02

Clasificación y agrupamiento: Spotify

Segunda tarea: descubrir grupos cuando no hay etiquetas previas

Innoit

Clustering

Spotify (Suecia)

Método documentado de investigación de usuarios

Concepto

Agrupar datos parecidos sin etiquetas previas.

Caso de uso real

UMAP y HDBSCAN para segmentar usuarios.

Ventaja

Descubre segmentos inesperados.

Limitación

Los grupos dependen de las variables elegidas.

El clustering descubre grupos que los investigadores pueden analizar después.

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Spotify

1 Ejemplo | 2 Variables | 3 UMAP | 4 HDBSCAN | 5 Re-embedding | 6 Jerarquía | 7 XGBoost | 8 SHAP | 9 Explicabilidad

Las personas detrás del caso de uso

Personas	Ana y Luis escuchan a AC/DC y a Metallica. Marta escucha a Taylor Swift.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de rock y metal como la señal principal del grupo.
Uso posible	Sugerir Iron Maiden a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

1 / 9

Detalles técnicos

Un ejemplo concreto de escucha

Ana y Luis comparten artistas. ¿Podemos descubrir su grupo y explicar qué lo hace diferente?

Sigue a las mismas personas

Cada paso siguiente explica qué supondría el algoritmo para Ana, Luis y Marta.

Historia ilustrativa. Los gráficos calculados usan variables de comportamiento sintéticas, sin recuentos de artistas ni usuarios con nombre.

← Atrás | Siguiente → | Reproducir | Reiniciar | Todos los oyentes | Preajuste calculado | Equilibrada · mcs 100 | Abrir explorador ↗

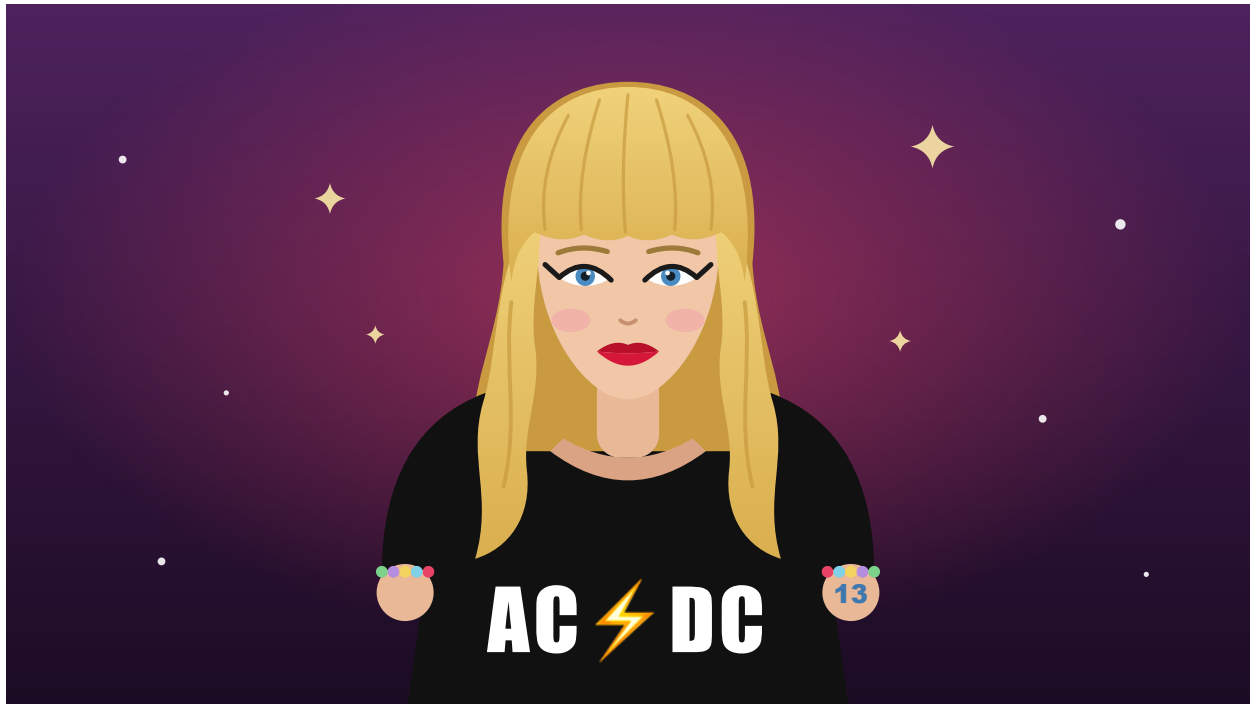
Demo calculada · oyentes sintéticos

Fuente: Spotify Engineering

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Cuando el grupo se equivoca de grupo

Marta escuchaba a Taylor Swift, pero si un día se pone la camiseta de AC/DC... ¿sigue en su grupo?



03

Juntamos todo: simulador de Uber

Un sistema real no usa una técnica, sino varias encadenadas

Innoit

De dos casos a un sistema completo

Lo que ya hemos visto

Regresión (idealista): estimar un valor continuo a partir de atributos.

Clustering (Spotify): agrupar observaciones parecidas sin etiquetas.

Lo que añade Uber

Series temporales: pronosticar la demanda de los próximos minutos.

Un bucle de control: corregir el precio cada pocos minutos hasta equilibrar oferta y demanda.

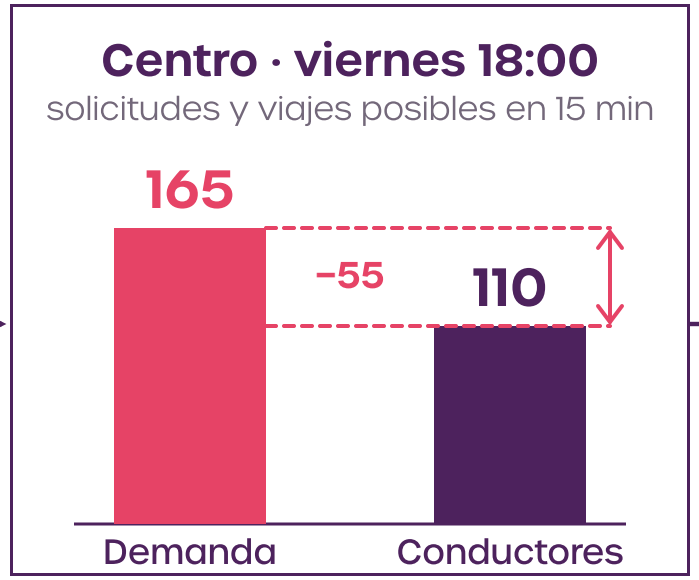
Uber: el problema

En cada zona y cada pocos minutos, la demanda y los conductores casi nunca coinciden

QUÉ MUEVE LA DEMANDA

- Hora y día
- Clima
- Eventos
- Tráfico

LA ZONA AHORA



SI NADIE ACTÚA

Demanda mayor que oferta

Esperas largas, más cancelaciones y usuarios menos satisfechos

LO QUE OCURRE EN CENTRO

Oferta mayor que demanda

Menos viajes por conductor, menos ingresos y desconexión

EN OTRA ZONA O A OTRA HORA

Reto: equilibrar oferta y demanda en minutos, zona a zona

El reto no es solo predecir: es equilibrar oferta y demanda antes de que el desajuste perjudique a todos.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Precio dinámico y demanda

Uber (presencia global)

Caso de estudio divulgativo; los modelos reales de Uber son propietarios

Concepto

Predecir la demanda y ajustar el precio.

Caso de uso real

Series temporales, clustering y regresión.

Ventaja

Menos esperas, oferta más estable.

Limitación

Las subidas bruscas parecen injustas.

El precio es una señal que equilibra el sistema, no solo cobra más.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

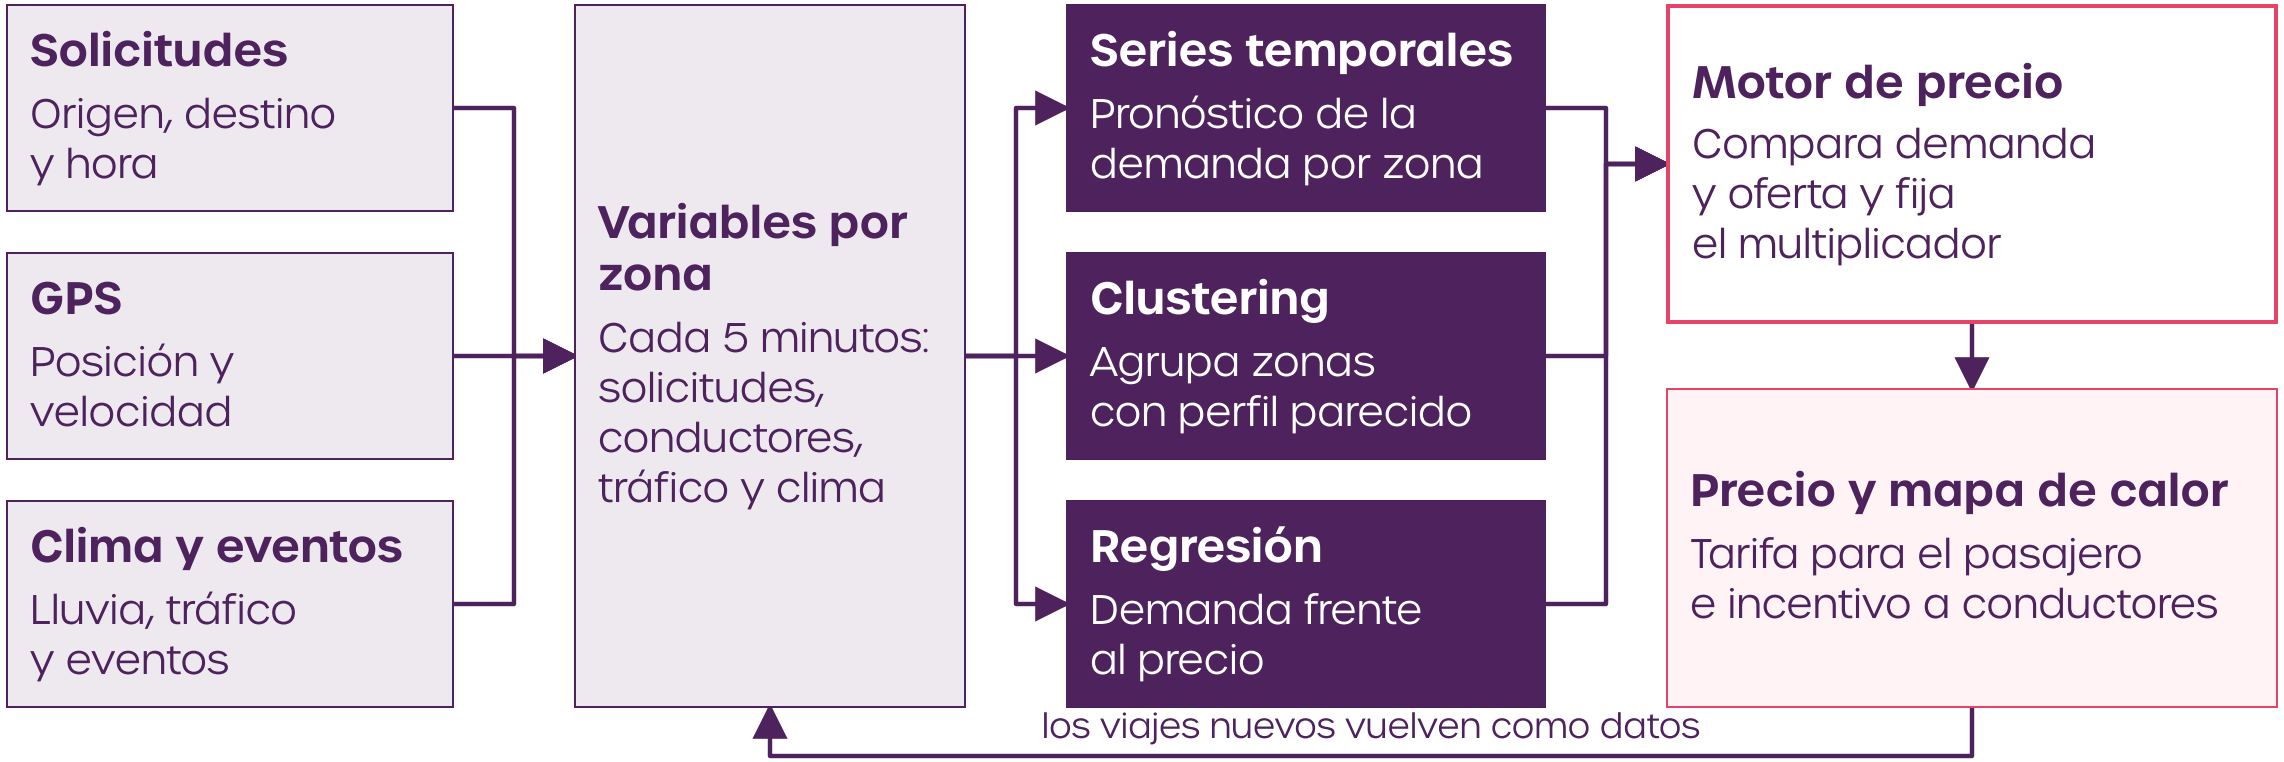
Los datos de partida

Fuente	Qué contiene	Para qué sirve
Solicitudes y viajes	Origen, destino, hora, duración, ruta, cancelaciones y pagos	Medir la demanda real y su histórico
GPS de móviles	Posición y velocidad de cada conductor, cada pocos segundos	Conocer la oferta y el tráfico en tiempo real
Contexto externo	Clima, cortes de carretera y eventos locales	Anticipar picos que el histórico no explica
Uso de la app	Valoraciones, cancelaciones y comentarios	Entender el comportamiento y la satisfacción

Volumen, variedad y velocidad: las tres «V» del Big Data. Fuente: Shuaib Ullattil, Medium (5 feb 2026).

Uber: del dato al precio

Del dato en bruto al precio que ve el pasajero, con un bucle de realimentación



Reconstrucción didáctica a partir de la descripción del artículo: la arquitectura real de Uber no es pública.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Algoritmos

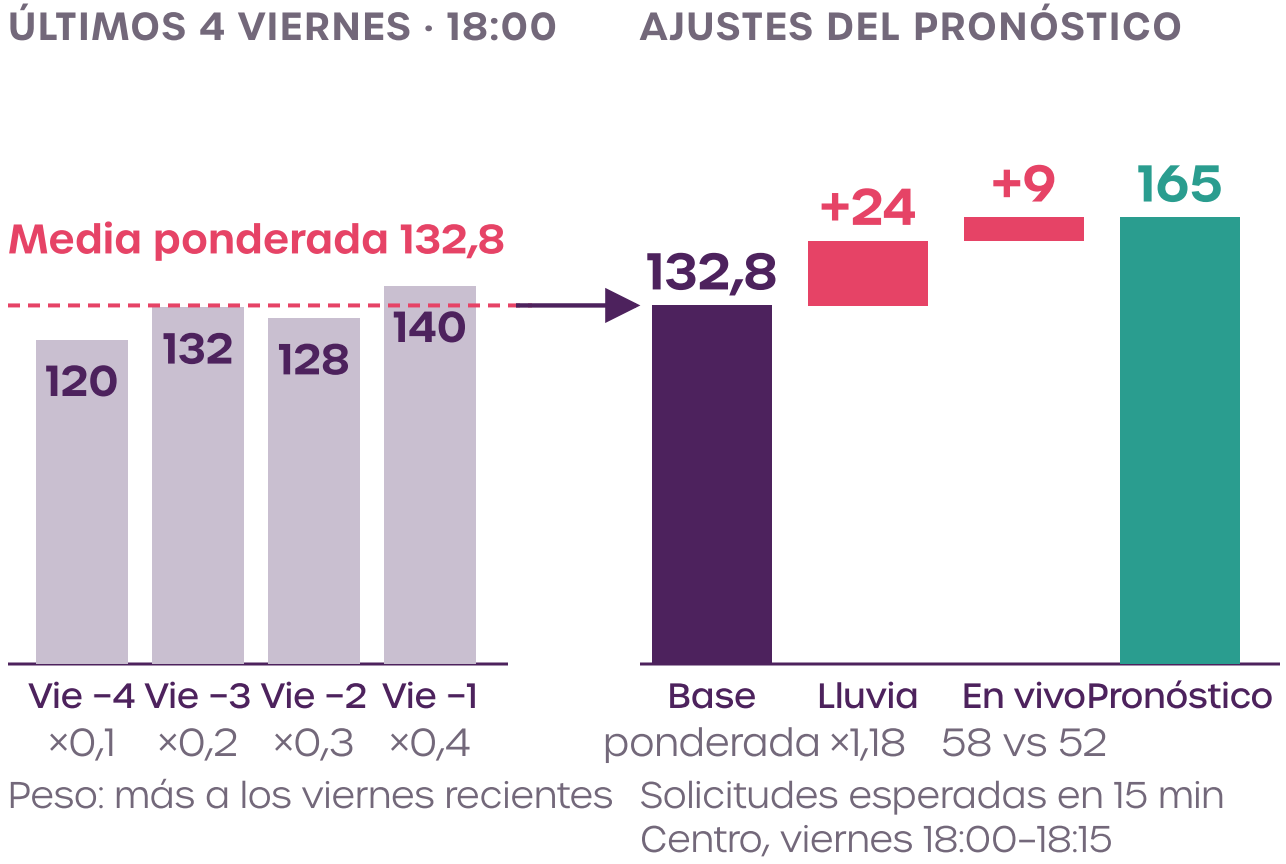
Cuatro piezas, paso a paso

Cada una con un ejemplo numérico sintético: Centro, viernes 18:00, con lluvia.

Series temporales: ¿cuántos viajes habrá?

Algoritmo 1/4 Pronóstico de la demanda de Centro entre las 18:00 y las 18:15

1. **Mirar el pasado.** Solicitudes a esa hora los últimos 4 viernes: 120, 132, 128 y 140.
2. **Ponderar.** Los viernes recientes pesan más: 0,1·120 + 0,2·132 + 0,3·128 + 0,4·140 = **132,8**.
3. **Ajustar por contexto.** Un modelo aprendió que la lluvia añade ≈18 % de demanda: 132,8 × 1,18 = **156,7**.
4. **Corregir en vivo.** En los primeros 5 min hay 58 solicitudes frente a 52 esperadas (+11 %). Se aplica la mitad: 156,7 × 1,055 = **165**.

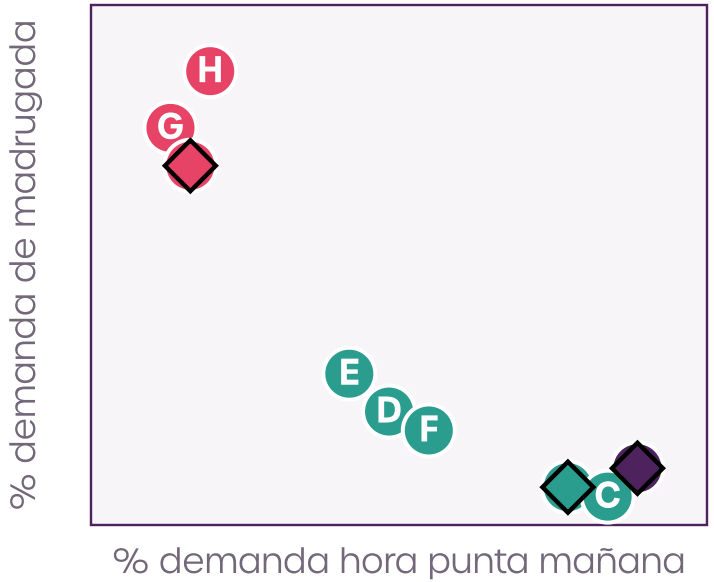


Datos sintéticos. Uber no publica sus modelos: aquí se usa una media ponderada estacional con ajustes, la forma más sencilla de una serie temporal.

Clustering: ¿qué tipo de zona es?

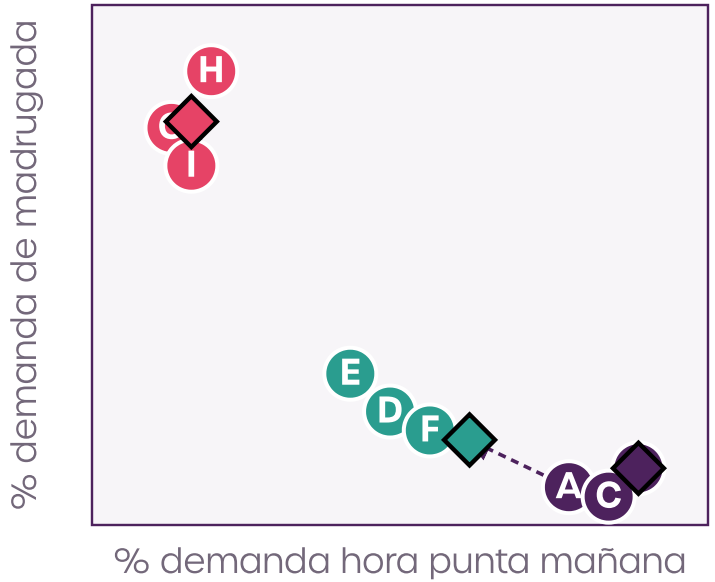
Algoritmo 2/4 k-means agrupa zonas por su perfil de demanda (k = 3)

1 · Centros iniciales



Dos centros caen en la misma zona de negocios. Cada zona pasa al centro más cercano.

2 · Mover y reasignar



Cada centro pasa a la media de sus zonas. A y C cambian de grupo.

3 · Se repite hasta converger



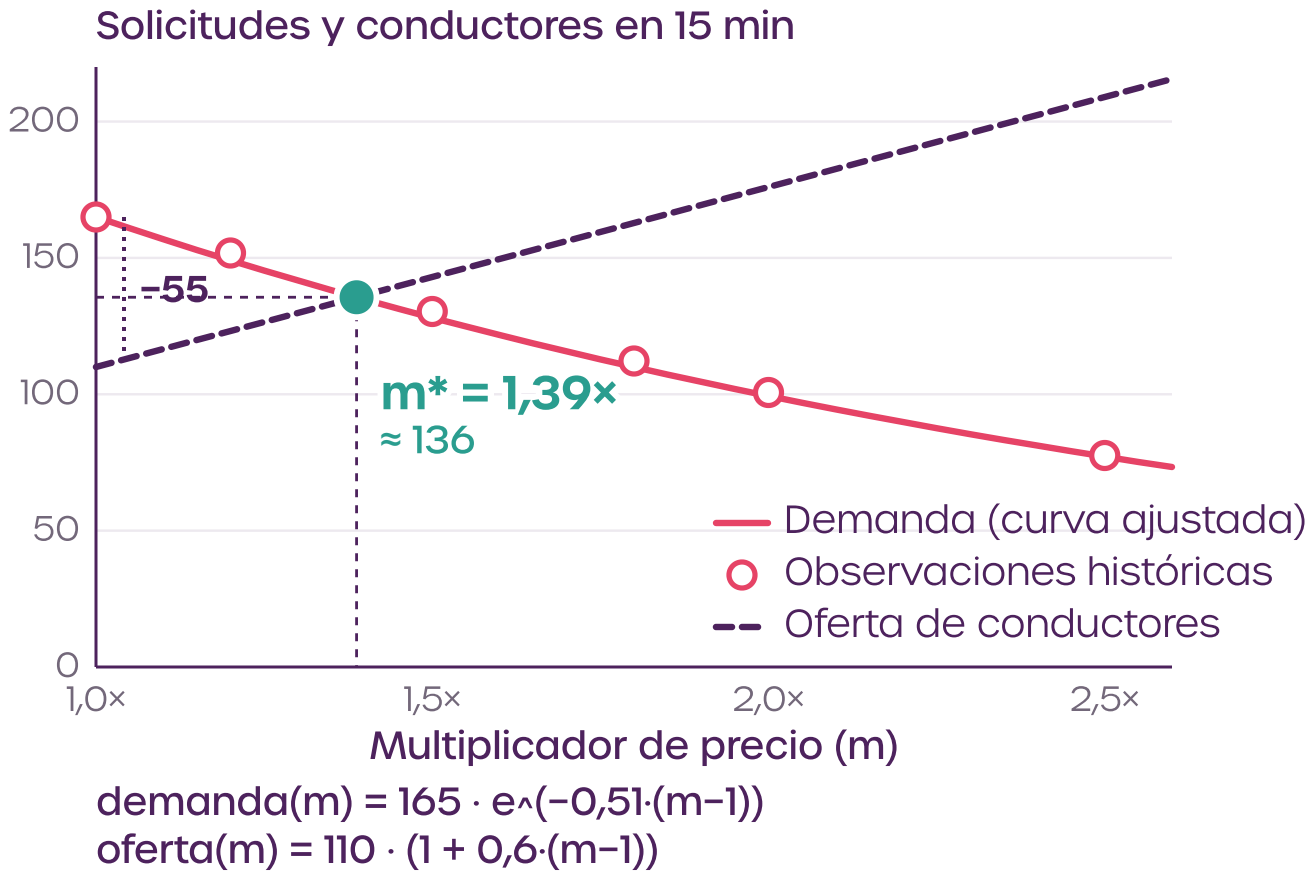
Ninguna zona cambia: quedan 3 grupos. Centro (C) es una zona de negocios.

Datos sintéticos de nueve zonas (A–I). Cada zona se describe con dos números; los grupos nacen de los datos, sin etiquetas previas. Zonas del mismo grupo comparten patrón: se pronostican juntas y se anticipa dónde enviar conductores.

Regresión: demanda frente al precio

Algoritmo 3/4 Sensibilidad de la demanda al precio y precio de equilibrio

1. **Reunir pares (precio, demanda).** Seis niveles históricos: a 1,0× la demanda es el 100 %; a 1,5×, el 79 %; a 2,5×, el 47 %.
2. **Elegir la forma.** La demanda cae de forma exponencial: `demanda(m) = base · e^(−β·(m−1))`.
3. **Ajustar por mínimos cuadrados** sobre ln(demanda): **β = 0,51**, R^2 = 0,999. Cada +1,0× quita ≈40 % de la demanda.
4. **Buscar el equilibrio.** Demanda(m) = oferta(m): 165·e^(−0,51(m−1)) = 110·(1 + 0,6(m−1)) → **m* = 1,39×**, unos 136 viajes.



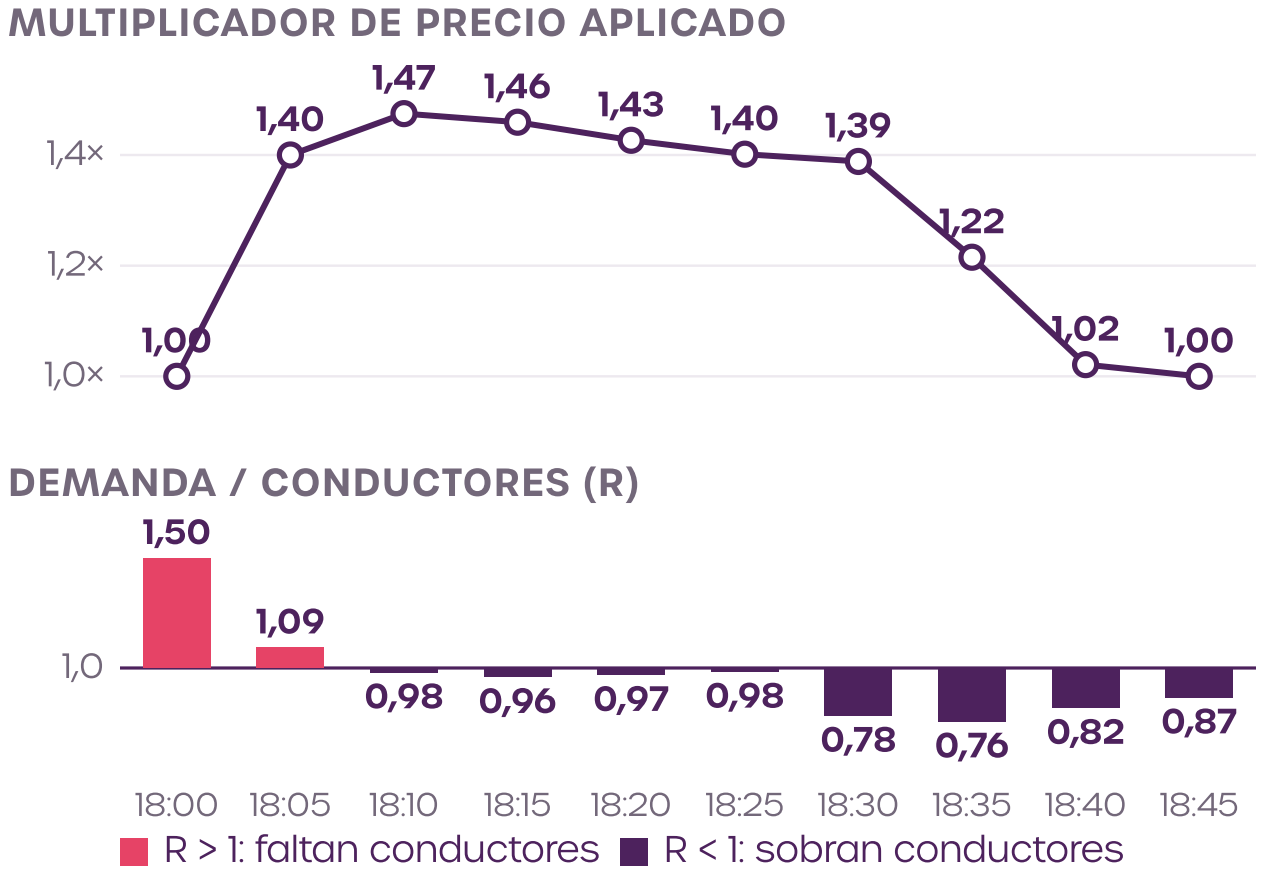
demanda(m) = 165 · e^(−0,51·(m−1))
oferta(m) = 110 · (1 + 0,6·(m−1))

Datos sintéticos. La respuesta de la oferta (+60 % de conductores por cada +1,0×) es una hipótesis didáctica; en la práctica también se estima con datos.

Bucle de precio: ajustar cada 5 minutos

Algoritmo 4/4 Control con realimentación: el precio se corrige cada 5 minutos hasta equilibrar

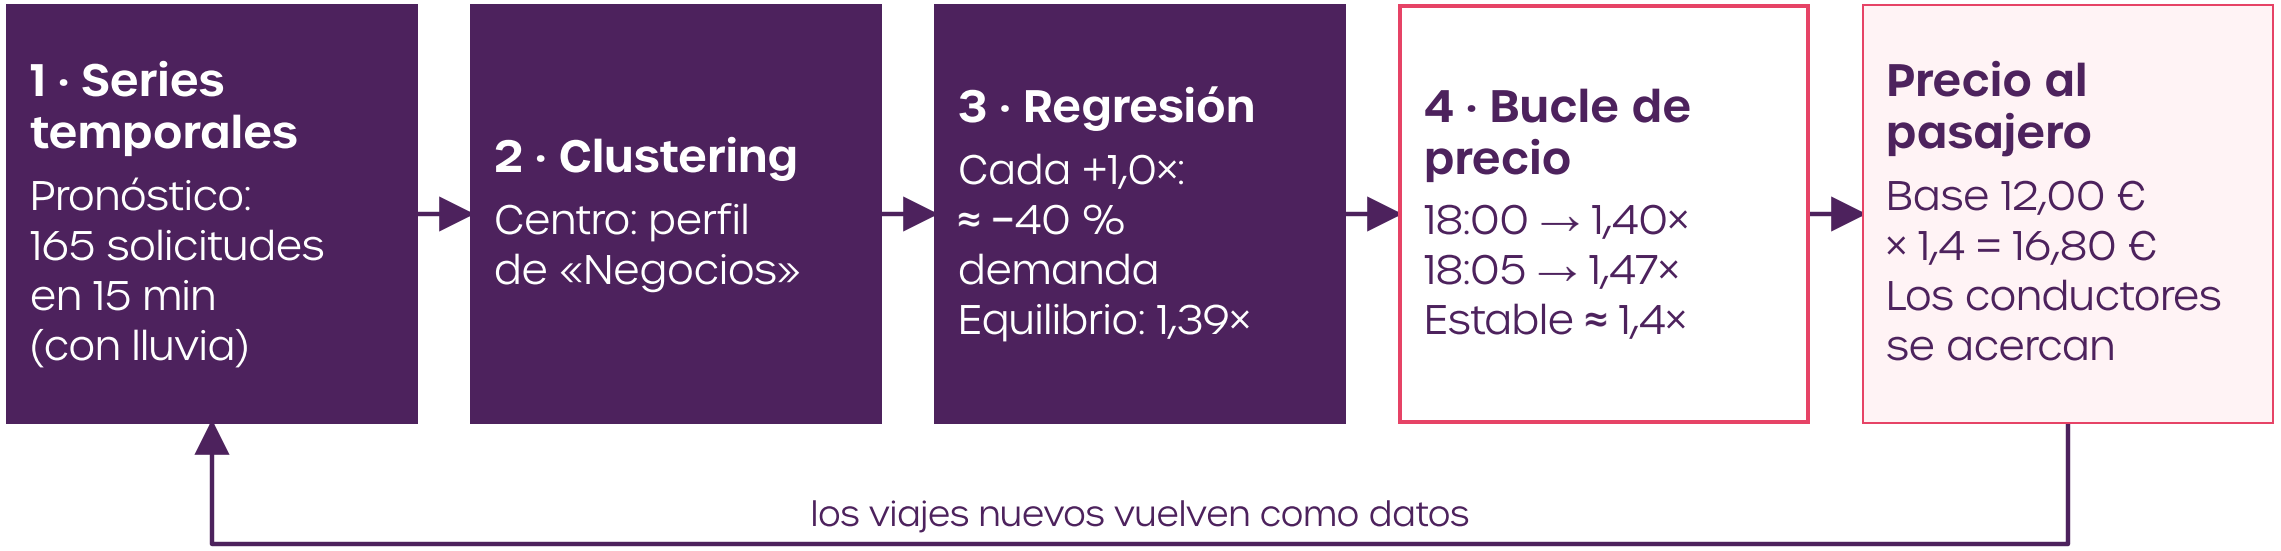
1. **Medir.** Cada 5 min: R = demanda / conductores. A las 18:00, 165 / 110 = **1,50**.
2. **Corregir el precio.** $m \leftarrow m + 0{,}8 \cdot (R - 1)$, entre 1,0× y 3,0×: 1,00 + 0,8·0,50 = **1,40×** desde las 18:05.
3. **Dejar reaccionar.** Algunos pasajeros esperan y los conductores se acercan. A las 18:05, R = 1,09 → **1,47×**.
4. **Repetir y relajar.** Se estabiliza en ≈1,4×. Al caer la demanda (R < 1) el precio baja a 1,00× a las 18:45.



Simulación sintética con la demanda y la oferta del ejemplo. Cuando la demanda baja a las 18:30, el multiplicador vuelve solo a 1,00×.

Un viernes a las 18:00, de principio a fin

Centro, viernes 18:00, con lluvia: los cuatro algoritmos encadenados con las cifras del ejemplo



Cifras sintéticas y coherentes con las diapositivas anteriores: no son datos de Uber.

Fuente: Shuaib Ullattil, Medium (5 feb 2026)

Retos y ética

Privacidad

Ubicaciones en tiempo real de pasajeros y conductores: exigen consentimiento, seguridad y gobierno del dato.

Percepción de justicia

Subir precios en emergencias o con mal tiempo se vive como abusivo, aunque equilibre el sistema.

Escala técnica

Flujos de millones de usuarios con baja latencia; los modelos se vigilan y se reentrenan.

Ideas para mitigar

Tope al multiplicador, precio visible antes de confirmar y avisos claros al usuario.

Conclusiones y próximos pasos

Conclusiones

Regresión estima un número, pero no garantiza un precio de venta.

Clustering descubre grupos sin etiquetas, y los grupos hay que validarlos.

Los sistemas reales combinan técnicas: Uber encadena series temporales, clustering, regresión y un bucle de control.

Próximos pasos

Notebooks de Jupyter para simular cada caso paso a paso.

Una aplicación web que simule el comportamiento del precio dinámico de Uber.

Probar las ideas con datos propios y medir el impacto en una decisión concreta.

Fuentes

idealista/data Análisis de regresión

idealista/data · 17 feb 2021

Spotify Clustering

Spotify Engineering · 5 dic 2023

Uber Precio dinámico y demanda

Shuaib Ullattil, Medium · 5 feb 2026

Fuentes divulgativas o de las propias empresas. Los datos de las demostraciones y del ejemplo de Uber son sintéticos. Consultadas del 19 de octubre al 10 de noviembre de 2026.

Gracias

¿Qué decisión de tu empresa podría apoyarse en uno de estos tres enfoques?

www.inno-it.es

Andrés Herencia · AI Engineer en InnoIT
Diseño y construyo soluciones de IA y machine learning aplicadas a casos reales.
linkedin.com/in/andres-herencia

Prueba los simuladores
Uber · idealista, desde el móvil

Innoit