Spotify
descubrir grupos

UMAP y HDBSCAN recursivos, explicados paso a paso

InnoIT · Caso de uso de ML

Innoit

Spotify: el problema

Millones de oyentes se comportan distinto, pero nadie sabe qué grupos existen

EL PROBLEMA

Millones de oyentes

Muchos comportamientos, sin grupos predefinidos



¿Quiénes son?

CÓMO FUNCIONA

1 · Hallar grupos

UMAP + HDBSCAN, repetido dentro de un grupo elegido

etiquetas de grupo

2 · Explicar grupos

XGBoost uno contra todos y SHAP sobre las variables originales

QUÉ SE OBTIENE



Grupos hallados

Oyentes con comportamiento parecido. Algunos quedan como ruido.



Grupos explicados

SHAP muestra qué comportamientos definen cada grupo, para que los investigadores lo validen.

El clustering propone los grupos. Las personas deciden cuáles merece la pena trabajar.

Fuente: Spotify Engineering

Clustering

Spotify (Suecia)

Método documentado de investigación de usuarios

Concepto

Descubrir grupos con comportamiento similar sin etiquetas de grupo predefinidas.

Ventaja

Encuentra segmentos inesperados y apoya la investigación dirigida de usuarios.

Caso de uso real

Spotify combina UMAP con HDBSCAN recursivo para descubrir segmentos más finos de usuarios.

Limitación

La elección de variables condiciona los grupos. Los clusters estables siguen necesitando validación humana.

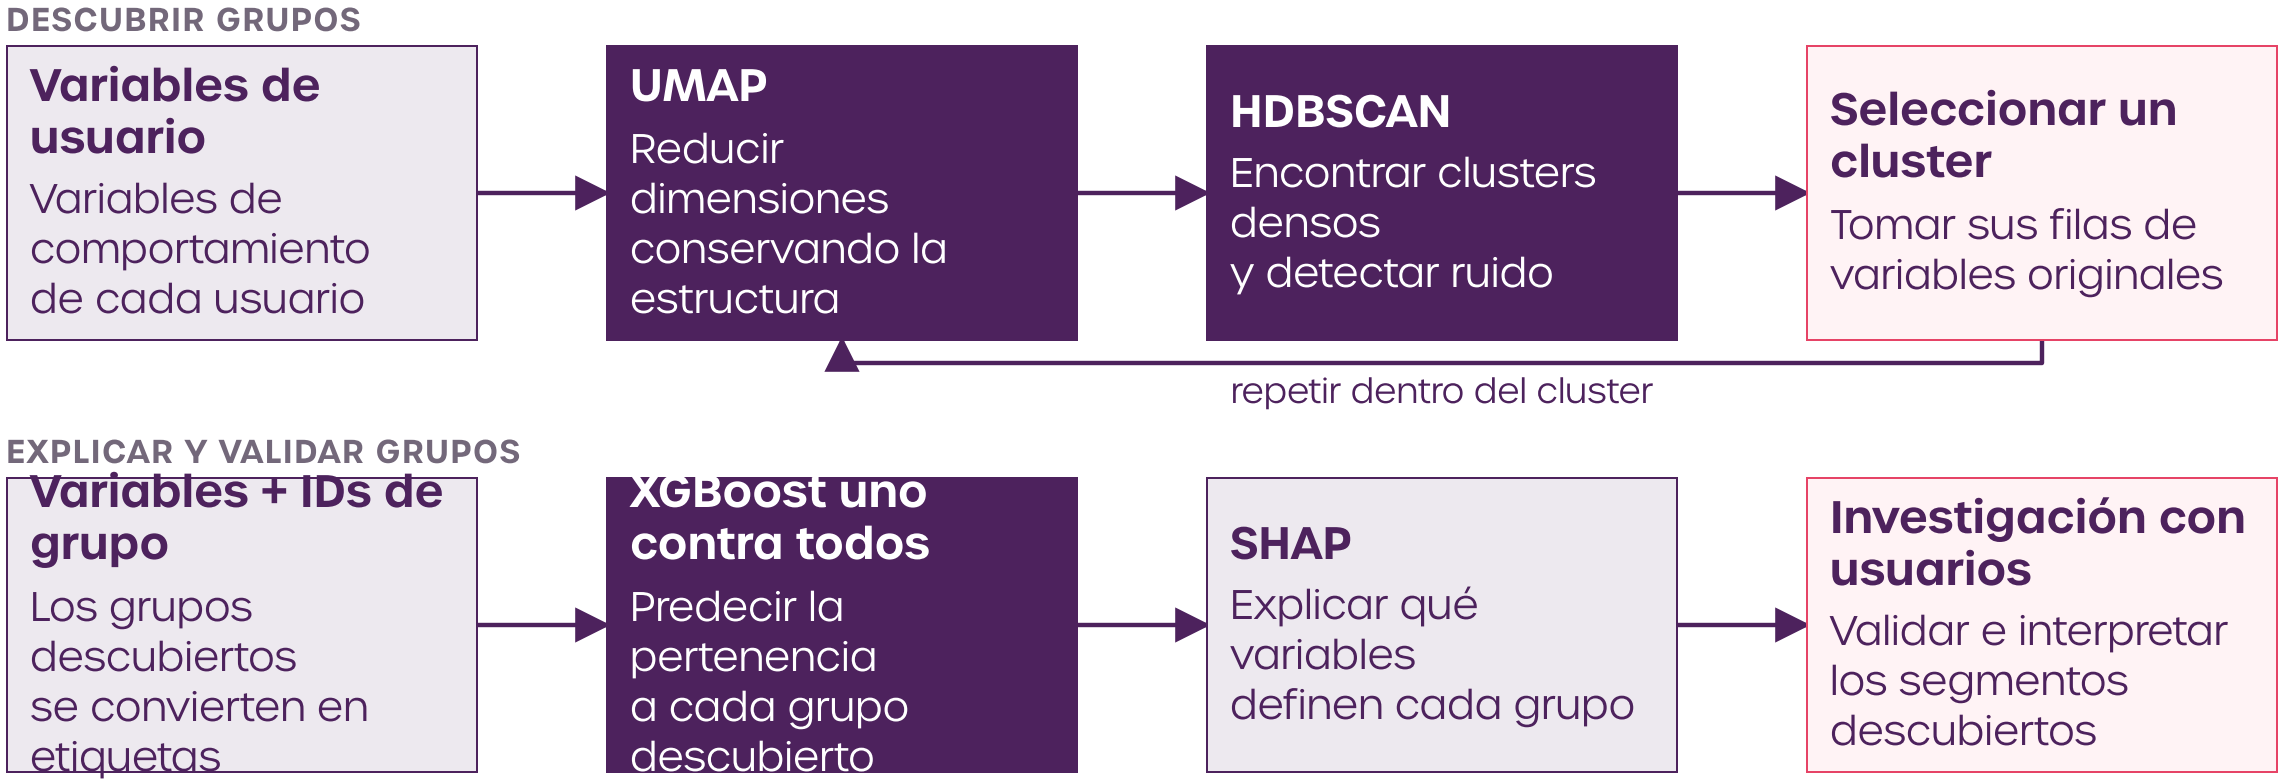
Spotify usa XGBoost y SHAP para explicar los segmentos resultantes.

El clustering descubre grupos que los investigadores pueden analizar después.

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado



Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Las personas detrás del caso de uso

Personas	Ana y Luis escuchan a AC/DC y a Metallica. Marta escucha a Taylor Swift.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de rock y metal como la señal principal del grupo.
Uso posible	Sugerir Iron Maiden a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

1 / 9

Detalles técnicos

Un ejemplo concreto de escucha

Ana y Luis comparten artistas. ¿Podemos descubrir su grupo y explicar qué lo hace diferente?

Sigue a las mismas personas

Cada paso siguiente explica qué supondría el algoritmo para Ana, Luis y Marta.

Historia ilustrativa. Los gráficos calculados usan variables de comportamiento sintéticas, sin recuentos de artistas ni usuarios con nombre.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Variables originales

$X \in \mathbb{R}^{684 \times 6}$

Observaciones sin etiquetar

Oyente	Minutos	Sesiones	Saltos	Descubrimiento	Listas	Noche
L001	222	11.4	10%	17%	52%	72%
L002	124	6.6	46%	64%	41%	29%
L003	32	1.8	28%	27%	75%	8%
L004	127	6.6	42%	66%	32%	36%

Variables numéricas, sin etiquetas de segmento predefinidas

684 filas × 6 variables

StandardScaler $z_{ij} = (x_{ij} - \mu_j) / \sigma_j$ Se ajusta una vez con toda la población de la demo

Demo calculada · oyentes sintéticos

2 / 9

Detalles técnicos

Un vector de variables original para cada oyente

La escucha de Ana se convierte en una fila numérica. Aquí calculamos seis variables de comportamiento. Los recuentos de artistas serían entradas adicionales.

Oyente L001

Minutos	222	Sesiones	11.4
Saltos	10%	Descubrimiento	17%
Listas	52%	Noche	72%

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

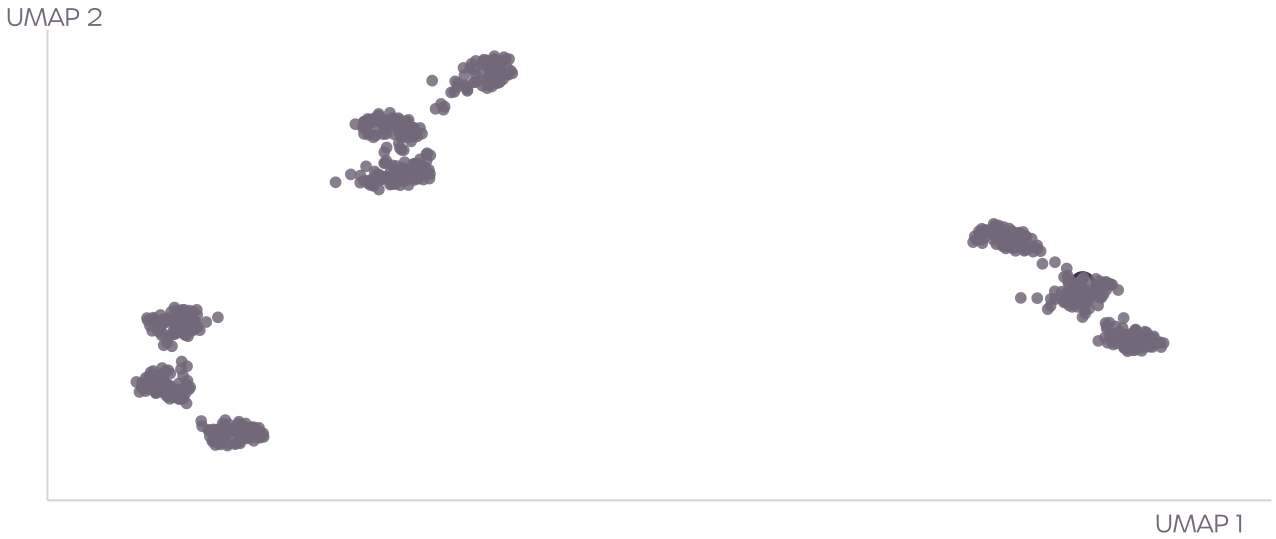
Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Coordenadas UMAP calculadas

3 clusters · 0 ruido · 684 oyentes



Solo es una transición visual. El movimiento de los puntos no reproduce las iteraciones del optimizador.

3 / 9

Detalles técnicos

UMAP hace visibles los vecindarios

Con variables de artistas adecuadas, Ana y Luis podrían aparecer cerca porque comparten artistas. UMAP muestra similitud, no una etiqueta de género.

$684 \times 6 \rightarrow 684 \times 2$

Fiabilidad (trustworthiness) con 10 vecinos: 0.975

Diagnóstico de vecindad local, no validez del segmento.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

1 Ejemplo | 2 Variables | 3 UMAP | 4 HDBSCAN | 5 Re-embedding | 6 Jerarquía | 7 XGBoost | 8 SHAP | 9 Explicabilidad

Coordenadas UMAP calculadas

3 clusters · 0 ruido · 684 oyentes



C1 221 | C2 241 | C3 222 | Ruido 0

Demo calculada · oyentes sintéticos

4 / 9

Detalles técnicos

HDBSCAN descubre grupos basados en densidad

Un grupo denso podría contener a Ana y a Luis, mientras que Marta queda en otro sitio. Los colores muestran los grupos descubiertos. Nuestro gráfico usa datos de comportamiento sintéticos.

Inspeccionar grupo: C1 · 221 oyentes

32.3% de este nodo

Ruido: 0 / 684

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

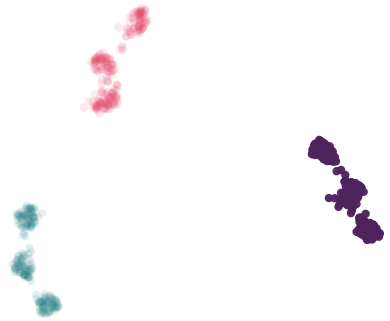
Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

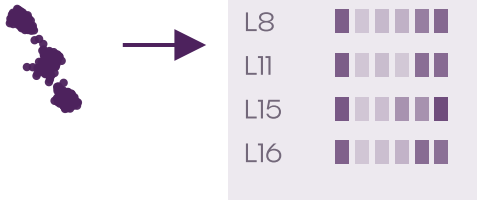
La recursión usa las variables originales dentro de un cluster seleccionado

Un nuevo ajuste, no un gráfico ampliado

1. Seleccionar C1

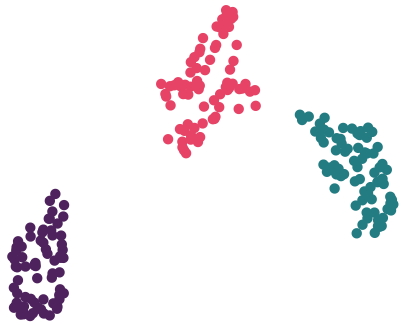


2. Filas X originales



221 × 6 variables

3. Reajustar ambos modelos



3 grupos · 0 ruido

Las nuevas coordenadas proceden de un nuevo ajuste de UMAP sobre las filas originales seleccionadas.

5 / 9

Detalles técnicos

La recursión parte de las filas de variables originales

Analiza de nuevo el grupo de Ana con sus filas originales. Esto podría revelar hábitos más finos dentro de su grupo más amplio.

Cluster padre: C1 · 221 filas

Inspeccionar ajuste hijo de C1

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Spotify

1 Ejemplo · 2 Variables · 3 UMAP · 4 HDBSCAN · 5 Re-embedding · **6 Jerarquía** · 7 XGBoost · 8 SHAP · 9 Explicabilidad

Jerarquía de clusters calculada



El ruido queda sin asignar. Los recuentos de los hijos pueden sumar menos que el padre.

6 / 9

Detalles técnicos

La jerarquía registra cada paso de descubrimiento

El grupo amplio de Ana podría dividirse en subgrupos. El árbol registra qué usuarios entran en cada nuevo ajuste. Haz clic en una rama para inspeccionar su población calculada.

4 ajustes calculados

Cada hijo tiene sus propias coordenadas UMAP y asignaciones HDBSCAN.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

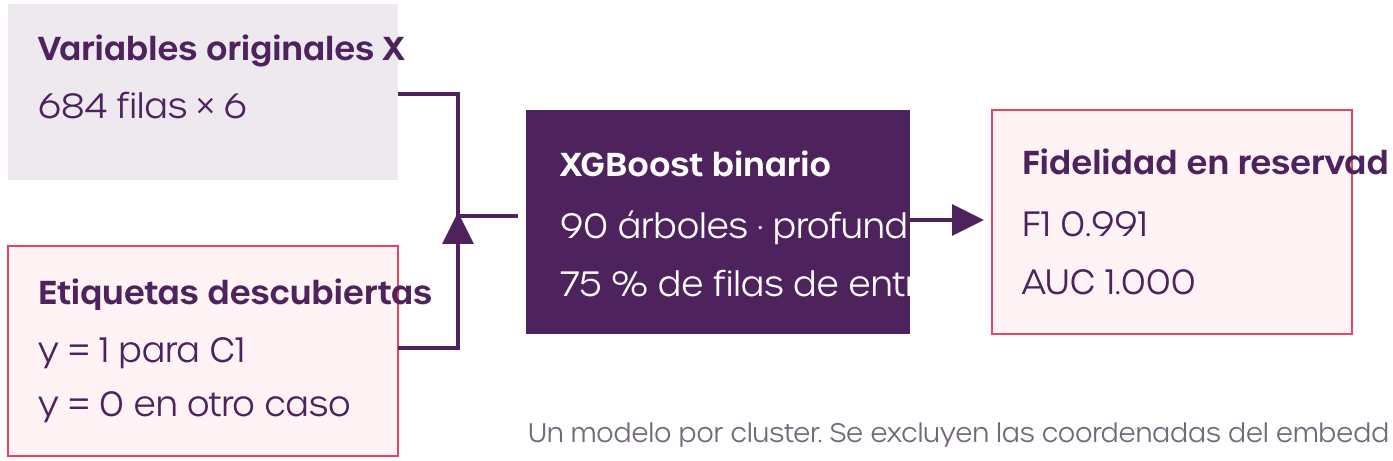
Fuente: Spotify Engineering

Innoit

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Entrenamiento uno contra el resto



Un modelo por cluster. Se excluyen las coordenadas del embedd

7 / 9

Detalles técnicos

Un modelo supervisado aprende la pertenencia descubierta

XGBoost aprende a predecir el grupo de Ana frente al resto, usando las variables originales y las etiquetas descubiertas.

Modelo de pertenencia: C1 contra el resto

513 entrenamiento / 171 reservados

La partición prueba la reproducción de etiquetas, no el descubrimiento de clusters con usuarios nuevos.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Contribuciones TreeSHAP calculadas

Este oyente | Mean |SHAP| — Contribución con signo al log-odds de pertenencia



Base -0.80 + Σ SHAP 6.55 = log-odds 5.75

P(C1) = 99.7%

Demo calculada · oyentes sintéticos

8 / 9

Detalles técnicos

SHAP explica el predictor de pertenencia

SHAP explica la puntuación de grupo de un oyente. La escucha indie podría importar con variables de artistas. Estas barras explican el comportamiento.

Explicar la pertenencia a: C1

Oyente: L001 · reservado

Oyente reservado. Las puntuaciones binarias independientes no tienen por qué sumar 1.

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Spotify: descubrir y explicar grupos

La recursión usa las variables originales dentro de un cluster seleccionado

Por qué hace falta interpretar

Personas	Ana y Luis escuchan a AC/DC y a Metallica. Marta escucha a Taylor Swift.
Grupo	Los recuentos de reproducciones por artista podrían agrupar a Ana y a Luis, separados de Marta.
Por qué	Una explicación podría identificar la escucha de rock y metal como la señal principal del grupo.
Uso posible	Sugerir Iron Maiden a Ana si Luis los escucha.

Ejemplo ilustrativo con artistas. La demo calculada usa comportamiento, no recuentos de artistas.

9 / 9

Detalles técnicos

Qué significan los resultados

Grupo C1 Oyente L001

En todos los oyentes

Minutos / día y Escucha nocturna tienen los mayores efectos medios.

Este oyente

Minutos / día = 222 es el empuje más fuerte hacia C1.

Las explicaciones del modelo no prueban causas ni validan segmentos.

Demo calculada · oyentes sintéticos

← / → pasos · los colores identifican grupos locales · sin datos ni parámetros internos de Spotify

Fuente: Spotify Engineering

Debate

¿Qué grupos podrías descubrir en tus propios datos?

¿Y quién los investigaría?

www.inno-it.es